

# 의사결정 — 지능을 빌릴 것인가, 소유할 것인가 — 숫자로 결정한다

1강 클라우드 vs 온프레미스 손익분기점 + 2강 6/12/24개월 도입 로드맵 (총 120분)

|      |                                                                                                            |
|------|------------------------------------------------------------------------------------------------------------|
| 코스   | Course 02 · 사내 AI 구축·운영 종합 가이드                                                                             |
| 강의   | 1강(60분) + 2강(60분) = 총 120분                                                                                 |
| 대상   | 중소기업 경영진·IT 담당자·관리자                                                                                        |
| URL  | <a href="http://visionc.co.kr/ai-solution/academy/build-ai">visionc.co.kr/ai-solution/academy/build-ai</a> |
| 비밀번호 | visioncDown (대소문자 구분)                                                                                      |
| 형식   | 사내 출강 / 워크숍                                                                                                |

INTRO · TITLE

## 지능을 빌릴 것인가, 소유할 것인가

1강 — 클라우드 API vs 온프레미스: 규모별 손익분기점

 3분 · 시작·환영

SAY

“반갑습니다. ‘사내 AI 구축·운영’ 1편, 의사결정 편입니다. 오늘 1강에서는 딱 하나만 끝냅니다 — ‘우리 회사는 AI를 클라우드로 빌려 쓰지, 우리 서버에 직접 구축할지, 숫자로 답을 내는 것’입니다.”

SAY

“막연히 ‘좋다더라’가 아니라, 오늘 끝나면 여러분 손에 ‘우리 회사 월 토큰량 → 클라우드 월 00만원 vs 자체구축 월 00만원 → 손익분기 N개월’이라는 숫자가 적힌 종이 한 장이 남습니다.”

STORY

구체적 인물로 시작하면 좋습니다. ‘경기도 시화공단의 자동차 부품사, 직원 35명. IT 담당은 김 대리 한 명. 사장님이 묻습니다 — 클라우드가 싸요, 우리가 사는 게 싸요? 김 대리가 견적을 뽑습니다. 오늘 우리는 김 대리가 뽑아야 할 그 견적서를 같이 만듭니다.’

Q

“지금 회사에서 ChatGPT, Claude, 제미나이 같은 거 업무에 쓰는 분 손 들어보세요.” → 보통 절반 이상 손 듭니다. “그 편리함의 대가로 매달 얼마를 내고, 무슨 데이터를 밖으로 보내고 있는지 — 오늘 그 청구서를 같이 들여다봅시다.”

TIP

강사 메모: 이 강의의 목표는 ‘자체 구축 영업’이 아니다. 대부분의 경량 사용은 클라우드가 더 싸다는 걸 숫자로 정직하게 보여주고, 자체구축이 정당화되는 ‘조건’(중량·상시·민감)을 분별하게 하는 게 핵심. 그래야 신뢰를 얻는다.

## OBJECTIVES

## 60분 후, 이 3가지를 한다

- ① 우리 회사 월 토큰량을 추정한다 — 직원수 × 일 사용횟수 × 평균 토큰
- ② 손익분기(BEP)를 계산한다 — 클라우드 월 비용 vs 자체구축 회수기간
- ③ 5가지 질문으로 ‘무엇은 사내·무엇은 클라우드’ 경계선을 긋는다

## 🕒 3분 · 학습목표

## SAY

“오늘 끝나면 세 가지를 직접 하게 됩니다. 첫째, 우리 회사 한 달 토큰 사용량을 추정합니다. 토큰이 뭔지는 잠시 후 설명합니다. 둘째, 그 숫자로 클라우드 월 비용과 자체구축 회수기간을 계산합니다. 셋째, 다섯 개 질문으로 우리 회사 데이터 경계선을 그립니다.”

## NOTE

강사 배경지식 — ‘토큰’이란: AI가 글자를 처리하는 단위. 대략 한글 1글자 ≈ 1.5~2토큰, 영어 1단어 ≈ 1.3토큰. A4 한 장(공백 포함 약 1,800자) ≈ 약 3,000토큰. 질문+답변 1회 왕복이 보통 1,000~3,000토큰. 이 환산 값을 외워두면 청중 질문에 즉답할 수 있다.

## SAY

“미리 말씀드립니다 — 오늘 가격표나 GPU 모델명을 외우게 하지 않습니다. 그건 6개월이면 바뀝니다. 대신 ‘계산하는 법’과 ‘판단하는 5질문’을 가져가시면 됩니다.”

## BRIDGE

“그럼 왜 이 결정이 단순 비용 문제가 아닌지부터 보겠습니다.”

## REFRAME · 본질

## ‘싸요 비싸요?’는 절반의 질문

## ■ 불변층 — 두 선택의 본질

- 지능을 빌린다 (클라우드 API) — 월 구독·사용량 과금. 질문(=회사 데이터)이 외부 서버로 전송돼 처리된다.
- 지능을 소유한다 (온프레미스(자체구축)) — 초기 장비 투자·운영 부담. 데이터가 사내망을 벗어나지 않는다.

SAY

“선택지는 둘입니다. 클라우드 API는 OpenAI·엔트로픽·구글의 AI를 인터넷으로 빌려 쓰는 겁니다 — 쓴 만큼 돈을 내고, 내 질문은 그 회사 서버로 갑니다. 온프레미스는 우리 회사 서버에 오픈소스 AI를 설치해 직접 돌리는 겁니다 — 장비를 사야 하지만, 데이터가 회사 밖으로 안 나갑니다.”

STORY

앞 슬라이드의 시화공단 부품사로 이어갑니다: ‘김 대리네 영업팀이 H자동차 1차 협력사 단가표를 ChatGPT에 붙여넣고 견적 초안을 만들었다. 편하다. 그런데 그 단가표 — 원청도 모르는 우리 납품 단가가 이제 OpenAI 서버를 거쳤다. 계약상 학습엔 안 쓴다지만, 로그엔 남고, 우리 통제 밖이다. 만약 그게 새서 경쟁사 손에 들어가면? 같은 작업을 사내 서버 AI로 했다면 단가표는 회사 건물을 한 발짝도 안 나갔다.’ — 김 대리가 사장님께 ‘싸요 비싸요’만 답하면 안 되는 이유가 여기 있습니다.

NOTE

강사 배경지식: 상용 API는 보통 ‘API로 들어온 데이터는 모델 학습에 쓰지 않는다’고 약관에 명시(기업 등급). 하지만 ① 운영 로그 보관(수십일) ② 해외 서버 경유(국외이전) ③ 약관은 언제든 바뀔 — 이 셋은 남는다. ‘학습 안 함 = 완전 안전’이 아님을 정확히 전달.

SAY

“그래서 ‘어느 게 싸냐’는 절반의 질문입니다. 나머지 절반은 ‘우리 데이터가 밖으로 나가도 되느냐’입니다. 오늘은 이 두 절반을 다 계산합니다.”

BRIDGE

“이 고민, 사실 100년 전 공장들이 똑같이 했습니다.”

HISTORY · 평행이론

## 100년 전, 공장의 ‘자가발전 논쟁’

■ 불변증 — 역사는 반복된다

- 1900년대 초: 공장마다 자가발전기 → 중앙 발전소 생기자 대부분 ‘사 쓰기’로 전환
- 지금도 병원·반도체·데이터센터는 자가발전을 함께 둔다 — 끊기면 안 되니까
- 전기 → 지능으로 단어만 바뀌었을 뿐, 편의성 ↔ 통제권의 거래는 동일

SAY

“1900년대 초, 미국 공장들은 저마다 자가발전기를 돌렸습니다. 그러다 에디슨·웨스팅하우스가 중앙 발전소와 전력망을 깔자, 대부분 ‘발전소에서 사 쓰는’ 쪽으로 넘어갔어요. 직접 발전기 관리하는 것보다 그게 싸고 편했으니까요.”

SAY

“그런데 100년이 지난 지금도, 병원 수술실·반도체 공장·데이터센터는 자가발전기를 ‘함께’ 둡니다. 왜? 단 몇 초만 정전돼도 사람이 죽거나 수억짜리 웨이퍼가 날아가니까. 편의보다 통제권이 중요한 영역이 분명히 있다는 겁니다.”

NOTE

강사 배경지식: 이 평행이론이 강좌 전체의 ‘앵커’다. 뒤에서 가격·GPU 얘기로 청중이 헛갈리기 시작하면 ‘자, 전기 살까 발전기 둘까 — 그 질문으로 돌아갑시다’ 하고 끌어오면 즉시 정리된다.

SAY

“AI도 똑같습니다. 일상 업무는 클라우드로 ‘사 쓰는’ 게 싸고 편합니다. 하지만 회사 생존이 걸린 데이터, 끊지면 안 되는 업무는 ‘자가발전’이 답일 수 있습니다. 오늘은 우리 회사의 그 경계가 어디인지 찾습니다.”

BRIDGE

“그 경계를 가르는, 변하지 않는 3가지 원리부터 못 박겠습니다.”

PRINCIPLES · 3대 원리

## 변하지 않는 3대 원리

■ 불변층 — 도구가 바뀌어도 그대로

- ① 의존성 비용 — 제공자가 값 올리거나 정책 바꾸면 회사는 끌려간다
- ② 데이터 비가역성 — 한 번 나간 정보는 로그·캐시에 남아 회수 불가
- ③ 통제권의 가치 — 단가는 매년 내려가도, 주권의 답은 회사가 정한다
- ✦ 결론 — 비용은 변수, 주권은 상수

SAY

“첫째, 의존성 비용. 가격표엔 안 적히지만 분명히 있는 비용입니다. 예를 들어 작년에 어떤 AI API가 가격을 올리거나, 무료 등급을 없애거나, 특정 기능을 막으면 — 거기에 업무를 다 맞춰둔 회사는 그대로 끌려갑니다. 외주의 숙명입니다.”

SAY

“둘째, 데이터 비가역성. ‘삭제했다’는 약속은 약속일 뿐입니다. 한 번 외부로 나간 데이터는 운영 로그, 백업, 캐시 어딘가에 남을 수 있고, 우리는 그걸 확인할 방법이 없습니다. 종이를 태우는 건 우리가 보지만, 남의 서버에서 지웠다는 건 안 보입니다.”

SAY

“셋째, 통제권의 가치. AI 단가는 지난 2년간 10분의 1 수준으로 떨어졌고 앞으로도 내려갑니다. 즉 비용은 변수입니다. 하지만 ‘우리 설계도면을 남의 서버에 줘도 되는가’의 답은 회사마다 영구히 다릅니다. 이건 상수입니다.”

STORY

🏢 비전솔루션 관점: 우리는 고객사에 ‘무조건 자체구축’도 ‘무조건 클라우드’도 권하지 않는다. 먼저 그 회사의 데이터 민감도와 사용량을 숫자로 본다. 작은 회사일수록 데이터 한 건의 유출이 신뢰·생존과 직결되기에, 주권을 비용보다 앞에 두는 경우가 많다 — 그러나 그것도 ‘숫자로 확인한 뒤’ 내리는 결론이다.

TIP

이 슬라이드는 사진 찍어가게 허락하라. 가격표(뒤 슬라이드)는 ‘외우지 마세요’, 이 3원리는 ‘기억하세요’ — 이 대비가 강의 메시지를 각인시킨다.

ANALOGY · 비유

## 택시 vs 자가용으로 이해하기

■ 불변층 — 쉽게

- 초기비용 0, 탈 때마다 요금 (택시 = 클라우드) — 가끔 타면 이득. 기사가 내 목적지(=의도·데이터)를 안다.
- 차값·정비, 그러나 내 통제 (자가용 = 온프레미스) — 매일 타면 이득. 아무도 내 동선을 모른다.

SAY

“헛갈리면 택시와 자가용으로 생각하세요. 클라우드는 택시입니다. 초기비용 0, 필요할 때 부르고, 탄 만큼 냅니다. 한 달에 두세 번 타면 택시가 훨씬 쌉니다. 대신 기사님이 내가 어디 가는지 다 압니다.”

SAY

“자가용은 온프레미스입니다. 차값·보험·기름·정비가 듭니다. 대신 매일 출퇴근하면 택시보다 훨씬 쌉니다. 그리고 내가 어디 가는지 아무도 모릅니다.”

SAY

“핵심은 두 축입니다. ‘얼마나 자주 타는가(사용량)’와 ‘무엇을 싣는가(민감도)’. 가끔·일반 짐이면 택시. 매일·귀중품이면 자가용. 이게 오늘 계산의 전부입니다.”

TIP

비율을 먼저 깔고 숫자(BEP)로 넘어가면 숫자 거부감이 큰 경영진도 따라온다. ‘아까 택시 얘기, 이제 진짜 요금으로 계산해봅시다’로 연결.

BRIDGE

“그럼 2026년 6월 현재, 택시(클라우드)와 자가용(장비) 가격이 실제로 얼마인지 보겠습니다.”

LANDSCAPE 2026.6

## 지금은 ‘무료 AI’가 쏟아진다

■ 가변층 — 2026.6 예시 · 업데이트 대상

- Llama (Meta) — 범용 강자, 한국어 준수, 상업이용 가능
- Qwen (알리바바) — 한국어·코딩 우수, 32B/72B 인기
- DeepSeek — 추론·코딩 특화, 가성비 최상위
- Mistral / GPT-OSS — 경량·고속, 사내 챗봇용으로 충분
- → 5년 전 불가능했던 ‘회사 서버에 내 AI’가 현실이 됨

#### SAY

“자체구축이 갑자기 현실이 된 이유는 ‘쓸 만한 무료 모델’이 쏟아졌기 때문입니다. 메타의 라마, 알리바바의 쿼원, 딥시크, 미스트랄 — 다 무료로 받아서 우리 서버에 깔 수 있고, 대부분 상업 이용도 됩니다.”

#### NOTE

강사 배경지식 — ‘파라미터(B)’란: 모델 크기 단위. 7B=70억개, 70B=700억개. 클수록 똑똑하지만 더 큰 장비가 필요. 중소기업 사내 챗봇은 보통 7B~32B로 충분하고, 70B면 상용 중급 API에 근접한 품질. 숫자 뒤 ‘Instruct’는 대화용으로 튜닝된 버전이라는 뜻.

#### SAY

“중요한 건 ‘우리가 가장 비싼 모델이 필요하나’입니다. 사내 문서 검색이나 이메일 초안 정도는 작은 모델로 충분합니다. 인간 변호사 수준의 추론이 필요한 게 아니면, 무료 모델로 업무의 80%는 해결됩니다.”

#### TIP

청중이 모델 이름을 받아적기 시작하면 멈춰라. ‘이 이름들은 내년이면 절반이 바뀝니다. 외우지 말고, 무료로 깔 수 있는 모델이 매년 좋아진다는 흐름만 기억하세요.’ — 이게 미래대응형 강의의 핵심.

#### BRIDGE

“무료 모델을 돌리려면 장비가 필요합니다. 등급별로 얼마인지 표로 보겠습니다.”

#### HARDWARE · 장비표

### 장비 등급표 — 무엇으로 시작하나

■ 가변층 — 2026.6 한국 시세 예시

- 입문 · 중고 RTX 3090 / Mac mini M4 Pro · 24GB / 통합 · 90~250만원 · ~14B 쾌적, 32B 가능
- 본격 · RTX 4090 / 5090 워크스테이션 · 24~32GB · 250~400만원 · 32B 쾌적
- 팀용 · Mac Studio M4 Max 128GB · 통합 128GB · 약 600만원 · 70B 가능
- 부서 · RTX 4090 × 2 / A6000 48GB · 48GB · 약 700만원 · 70B 쾌적
- 전사 · 서버 GPU(H100 80GB 등) · 80GB+ · 3,000만원~ · 100B+



#### SAY

“표를 보세요. 핵심은 딱 하나 — VRAM(그래픽카드 메모리)이 ‘돌릴 수 있는 모델 크기’를 결정합니다. 메모리가 모델을 담는 그릇이라고 보면 됩니다.”

#### NOTE

강사 배경지식 — VRAM 계산법(Q4 양자화 기준): 모델 파라미터 수  $\times$  약 0.6GB. 즉 8B $\approx$ 5GB, 14B $\approx$ 9GB, 32B $\approx$ 20GB, 70B $\approx$ 42GB, 405B $\approx$ 240GB. ‘양자화(Quantization)’는 모델을 압축해 메모리를 절반 $\sim$ 1/4로 줄이는 기술. Q4는 4비트 압축으로, 품질 손실은 거의 없이 용량을 1/4로 줄여 4090 한 장에 32B가 들어가게 해준다. 이 한 줄이 자체구축 진입장벽을 무너뜨린 핵심 기술.

#### SAY

“중소기업 현실적 출발점은 두 가지입니다. 하나, 중고 RTX 3090 24GB — 90만원이면 14B 모델이 쾌적하게 돌립니다. 사내 챗봇 시범용으로 충분합니다. 둘, 맥 미니나 맥 스튜디오 — 통합 메모리가 커서 조용하고 전기도 적게 먹어 사무실에 두기 좋습니다.”

#### SAY

“70B급, 그러니까 상용 중급 API에 근접한 품질을 사내에서 돌리려면 48GB가 필요하고, 4090 두 장이나 맥 스튜디오 128GB면 됩니다. 700만원 안쪽이죠. H100 같은 수천만원짜리는 전사 대규모 전에는 필요 없습니다.”

#### TIP

‘우리는 H100 사야 하나요?’ 질문 자주 나옴. 답: ‘아닙니다. 그건 수백 명이 동시에 쓰거나 모델을 직접 학습할 때. 1~2편 단계에선 90~700만원 범위에서 시작합니다.’

#### BRIDGE

“장비값을 봤으니, 이제 클라우드 ‘택시 요금’을 보겠습니다.”

#### CLOUD · 단가표

### 클라우드 단가 — 택시 요금표

■ 가변층 — 2026.6 예시 · 환율 1,400원/\$

- 최고급 · 고난도 추론·법률·코딩 자동화 · 약 \$5 (7,000원) · 약 \$25 (35,000원)
- 표준급 · 일반 업무·문서·요약·메일 · 약 \$1 (1,400원) · 약 \$5 (7,000원)
- 저가/오픈 · 사내 챗봇·대량 처리 · 약 \$0.2 (280원) · 약 \$0.6 (840원)

SAY

“클라우드는 ‘입력 토큰’과 ‘출력 토큰’을 따로 셉니다. 보통 출력이 4~5배 비쌉니다. AI가 글을 쓰는 게 읽는 것보다 비싼 거죠.”

SAY

“숫자에 겁먹지 마세요. 표준급으로 보면, 입력 100만 토큰이 1,400원입니다. A4 300장 분량을 읽히는 데 1,400원이라는 뜻입니다. 생각보다 쌉니다. 이게 ‘경량 사용은 클라우드가 이긴다’의 근거입니다.”

NOTE

강사 배경지식: ‘100만 토큰’ 감 잡기 — 질문+답변 1왕복  $\approx$  2,000토큰. 즉 100만 토큰  $\approx$  500번 대화. 표준급 기준 500번 대화에 입력+출력 합쳐 대략 1만~2만원 선. 직원 한 명이 하루 30번 쓰면 월 약 660회  $\rightarrow$  월 1~2만원대. 이 감각을 강사가 쥐고 있어야 BEP 계산이 막히지 않는다.

SAY

“그런데 함정이 있습니다. 코딩 에이전트나 사내 문서 전체를 뒤지는 작업은 한 번에 수십만 토큰을 씁니다. 이런 ‘중량 사용’으로 가면 청구서가 갑자기 폭발합니다. 다음 두 장에서 경량과 중량을 실제로 계산해 보겠습니다.”

BRIDGE

“자, 이제 진짜 계산입니다. 경량 사용 시나리오부터.”

BEP · 계산 ①

## 계산 ① 경량 — 사내 챗봇

■ 시화공단 부품사 35명 사내 Q&A

- 사용량: 35명  $\times$  하루 30회  $\times$  22일  $\times$  2,000토큰  $\approx$  월 4,600만 토큰
- 클라우드(표준급): 입력 3,500만 $\times$ 1,400원 + 출력 1,100만 $\times$ 7,000원  $\approx$  월 약 13만원
- 자체구축: 중고 3090 90만원 + 전기·관리 월 약 5만원
- $\rightarrow$  결론: 순수 비용은 클라우드 압승 (자체구축 회수 1년 반+). 경량은 빌려라

SAY

“김 대리네 첫 시나리오부터. 직원 35명이 사내 규정·휴가 절차·제품 매뉴얼을 묻는 챗봇입니다. 한 명이 하루 30번, 한 달 22일 근무, 한 번에 2,000토큰. 곱하면 월 약 4,600만 토큰입니다.”

SAY

“표준급 클라우드로 계산하면 — 입력이 약 3,500만 토큰이니 100만당 1,400원 곱하면 약 5만원, 출력 1,100만 토큰에 100만당 7,000원이면 약 8만원. 합쳐서 한 달 13만원입니다. 1년에 156만원.”

SAY

“자체구축은요? 중고 3090 90만원짜리 한 대면 이 정도 사용량은 충분히 돌아갑니다. 거기에 전기랑 관리 품 월 5만원. 그럼 90만원을 회수하는 데 1년 반 넘게 걸립니다. 게다가 누군가 서버를 관리해야 하죠.”

SAY

“그래서 결론은 명확합니다. 이런 경량·일반 업무는 클라우드가 싸고 편합니다. 굳이 서버 사지 마세요. — 자체 구축 영업하는 강의가 아니라고 말씀드린 이유입니다.”

TIP

여기서 솔직하게 ‘클라우드가 이긴다’고 인정하면 청중 신뢰가 확 올라간다. 그 신뢰 위에서 다음 장(중량은 역전)이 설득력을 가진다.

BRIDGE

“그런데 사용량이 폭발하면? 정반대가 됩니다.”

BEP · 계산 ②

## 계산 ② 중량 — 코딩·문서 자동화

■ 같은 회사 설계팀 10명 상시 에이전트

- 사용량: 10명 × 하루 300만 토큰(에이전트) × 22일 ≈ 월 6.6억 토큰
- 클라우드(표준급): 입력 4.6억 × 1,400원 + 출력 2억 × 7,000원 ≈ 월 약 205만원 (연 2,460만원)
- 최고급 모델이면 → 월 1,000만원 이상으로 폭증
- 자체구축: 4090 워크스테이션 2대 ≈ 1,400만원 + 운영 → 회수 약 7개월. 중량은 소유하라

SAY

“그런데 김 대리네 회사엔 설계팀이 있습니다. 같은 회사, 다른 부서죠. 설계·개발 10명이 CAD 사양서 자동 작성, 도면 검토, 코딩 보조 에이전트를 ‘상시’ 씁니다. 에이전트는 한 작업에 파일 수십 개를 읽고 쓰기 때문에 한 사람이 하루 300만 토큰을 우습게 씁니다. 10명이면 월 약 6.6억 토큰 — 아까 챗봇의 14배입니다.”

SAY

“표준급으로 계산해도 한 달 약 205만원, 1년이면 2,460만원입니다. 만약 최고급 모델을 쓰면? 출력이 100만 당 35,000원이니, 월 1,000만원을 가볍게 넘깁니다. 연 1억이 넘죠.”

SAY

“반면 자체구축은 4090 워크스테이션 두 대면 70B급 모델을 충분히 돌립니다. 1,400만원. 전기·관리 더해도, 표준급 클라우드 기준 약 7개월이면 본전을 뽑고, 그 뒤로는 토큰을 아무리 써도 추가 요금이 0원입니다.”

NOTE

강사 배경지식 — 왜 에이전트는 토큰을 폭발적으로 쓰나: 에이전트는 ‘파일 읽기 → 생각 → 수정 → 다시 읽기’를 수십 번 반복(루프)한다. 한 번 대화하는 챗봇과 달리, 한 작업에 수백 번 모델을 호출한다. 그래서 ‘상시·자동화’로 가는 순간 토큰이 수백 배가 된다. 이게 BEP를 뒤집는 결정적 변수. (자세한 건 5편 에이전트에서.)

SAY

“정리하면 — 경량은 클라우드, 중량·상시는 자체구축. 우리 회사가 어느 쪽인지는 ‘토큰을 얼마나 쓰느냐’가 가릅니다. 그래서 실습에서 우리 숫자를 직접 넣어볼 겁니다.”

BRIDGE

“비용 외에, 돈으로 환산 안 되는 변수가 하나 더 있습니다 — 데이터 주권. 5질문으로 점검합니다.”

#### CHECKLIST · 5질문

### 도입을 가르는 5가지 질문

■ 불변증 — 2026년에도 2030년에도 유효

- ① 주권 — 계약서·고객정보·도면이 밖에 나가도 되는가
- ② 규모 — 월 토큰이 손익분기를 넘는 ‘중량·상시’인가
- ③ 규제 — 개인정보·국외이전 규제 대상 데이터인가
- ④·⑤ 역량·연속성 — 운영할 사람이 있는가 / 제공자 끊겨도 버티는가

SAY

“돈 계산이 끝났으면 다섯 질문으로 마무리합니다. 하나라도 ‘예’가 강하면 자체구축 쪽에 무게가 실립니다.”

SAY

“①주권 — 우리가 AI에 넣을 데이터가 고객 계약서, 개인정보, 설계도면입니까? 그렇다면 비용과 무관하게 사내에 두어야 할 수 있습니다. ②규모 — 아까 계산에서 ‘중량·상시’로 나왔습니까? 그럼 비용으로도 자체구축이 이깁니다.”

SAY

“③규제 — 개인정보보호법상 개인정보를 국외 서버로 보내려면 정보주체 동의나 별도 조치가 필요합니다. 고객 개인정보를 다루면 클라우드(특히 해외) 사용에 제약이 생깁니다. ④역량 — 서버를 관리할 사람이 있습니까? 없으면 클라우드나 ‘혼합’이 현실적입니다. ⑤연속성 — 그 API 회사가 한국 서비스를 접거나 값을 3배 올려도 회사가 버팁니까?”

NOTE

강사 배경지식: 개인정보보호법 제28조의8(국외이전)은 ‘정보주체 동의·고지’ 등을 요구. 즉 고객 개인정보를 해외 클라우드 AI에 그냥 보내면 위반 소지가 있다. ‘민감정보(건강·생체 등)’는 더 엄격. 이 한 줄이 제조·의료·금융 고객에겐 결정타가 된다. (정확한 적용은 법무 검토 권고로 안내.)

Q

“다섯 질문에 ○/△/× 매겨보세요. ○가 두 개 이상이면, 최소한 ‘민감 데이터만이라도 사내’로 분리하는 걸 검토할 때입니다.”

TIP

이 5질문 슬라이드는 사진 찍게 허락. 이게 실습의 채점표가 된다.

## CONCLUSION + 실습

## 대개의 정답은 ‘경계선’이다

## ■ 결론 + 워크숍

- 민감 + 중량·상시 (사내에 둘 것) — 고객정보·계약·도면 / 코딩·문서 자동화 → 자체구축
- 비민감 + 경량 (클라우드에 보낼 것) — 아이디어·번역·일반 검색 → 최고급 모델 빌려쓰기

🕒 8분 · 결론·실습

## SAY

“여기서 오늘의 핵심 논리가 완성됩니다. 김 대리네 ‘한 회사’가 답이 두 개입니다. 사내 챗봇(경량·비민감)은 클라우드가 싸니 빌려 쓰고, 설계팀 자동화(중량·민감·도면)는 사내 서버에 둡니다. 즉 정답은 ‘우리 회사는 클라우드냐 자체구축이냐’가 아니라 ‘우리 회사 안에서 어디에 경계선을 긋느냐’입니다. 대부분의 중소기업 정답이 이 혼합입니다.”

## STORY

김 대리의 결말: 사장님께 ‘싸요/비싸요’ 대신 A4 한 장을 냈다. ‘왼쪽 칸 — 사내 서버(설계 도면·납품 단가·고객 개인정보), 오른쪽 칸 — 클라우드(번역·아이디어·일반 검색). 챗봇은 당장 클라우드로 3명 시범, 설계 자동화는 6개월 뒤 검증되면 700만원 워크스테이션으로.’ 사장님이 결재했다. 막연한 ‘AI 도입’이 ‘숫자와 경계선이 있는 계획’으로 바뀐 순간이다.

## DO

실습(8분, 3인 1조). 배포한 워크시트에: ① 우리 직원 수 × 하루 사용 횟수 × 2,000토큰으로 월 토큰량 추정. ② 슬라이드 10·11 방식으로 클라우드 월 비용 계산 → 경량인가 중량인가 판정. ③ 5질문에 ○/△/× → ‘사내에 둘 데이터/업무’와 ‘클라우드에 보낼 것’을 한 장에 두 칸으로 나눈다.

## SAY

“완벽한 숫자가 목표가 아닙니다. ‘우리는 경량이라 클라우드구나’ 또는 ‘우리는 도면을 다루니 사내가 맞구나’를 숫자 근거로 스스로 말하게 되는 게 목표입니다.”

## TIP

1~2개 조 발표시켜라. ‘설계도면을 클라우드에’ 같은 위험 결정이 나오면 5질문으로 그 자리에서 짚어준다 — 가장 기억에 남는 학습 순간.

“‘자체구축을 하기로’ 정한 회사는 그럼 무엇부터? 2강, 6/12/24개월 로드맵입니다.”

## INTRO · TITLE

## 무엇부터 — 6 / 12 / 24개월 로드맵

2강 — 단계별 도입 로드맵: 90일 안에 1차 가동

🕒 3분 · 시작

## SAY

“1강 끝에서 김 대리는 사장님 결재를 받았습니다. 경계선도 그었고 예산도 잡혔어요. 그런데 진짜 문제는 지금 부터입니다 — ‘그래서 다음 주 월요일에 뭘 하지?’ 2강은 김 대리가 받아든 이 빈 종이를 채우는 시간입니다. 가장 많이 실패하는 답이 ‘종다니까 전사에 한 번에 깔기’이고요.”

## STORY

구체 실패담: ‘한 중소기업이 전 직원에게 AI 도구 계정을 깔아줬다. 3개월 뒤 실제 쓰는 사람은 5%. 왜? 뭘 해야 할지 아무도 안 알려줬고, 효과를 아무도 안 잰으니까. 다음 해 예산에서 AI 항목이 삭제됐다.’ — 도구를 깔 게 아니라 습관을 안 심은 결과.

## Q

“과거에 ERP나 그룹웨어 도입했다가 직원들이 안 써서 묻힌 경험 있으신 분?” → 대부분 손 뚫. “AI도 똑같이 실패합니다. 오늘은 그걸 피하는 법입니다.”

## PRINCIPLE · 근본

## 도입의 본질 = 습관의 이식

■ 불변층 — 기술이 아니라 사람

- 도구를 ‘깎았다’가 아니라 ‘쓴다’가 성공 — 안 쓰면 효과 0원
- 작은 성공 → 신뢰 → 확산의 순서 (건너뛰면 실패)
- 측정 없는 도입은 ‘종다더라’로 끝나고 예산이 깎인다
- 그래서 0단계는 ‘도구 선택’이 아니라 ‘측정할 업무 1개 고르기’

🕒 6분 · 근본 원리

## SAY

“변하지 않는 원리 세 가지. 첫째, 도구는 깎 게 아니라 쓰는 게 성공입니다. 둘째, 사람은 작은 성공을 직접 봐야 신뢰하고, 신뢰해야 옆으로 퍼집니다. 셋째, 측정 안 하면 ‘좋은 것 같긴 한데’로 끝나고, 다음 예산 회의에서 잘립니다.”

## SAY

“그래서 진짜 0단계는 도구 고르기가 아닙니다. ‘측정할 업무 한 개’를 고르는 겁니다. 예를 들어 견적서 작성 시간. 도입 전에 ‘1건당 평균 40분’이라고 숫자를 찍어둬야, 나중에 ‘15분으로 줄었다, 62% 단축’이라고 증명할 수 있습니다.”

## STORY

김 대리의 선택: 씨앗으로 ‘영업팀 견적서 작성’을 골랐다. 가장 반복적이고 시간 측정이 쉬웠으니까. 2주간 측정 → 건당 평균 38분, 월 120건. 도입 후 → 건당 14분. 월 48시간 절감 = 영업사원 0.3명분 시간을 되찾음. 김 대리는 이 ‘48시간’ 한 줄로 6개월 뒤 설계팀 자동화 예산을 따냈다. 측정이 곧 다음 단계의 입장권이다.

## TIP

경영진 청중에게는 ‘ROI를 증명할 숫자 한 개를 먼저 정하라’가 가장 잘 먹힌다. 기술 얘기보다 ‘무엇을 측정할 것인가’로 대화를 끌어라.

## BRIDGE

“이 원리를 시간 측에 올리면 — 씨앗·뿌리·숲, 3단계가 됩니다.”



MODEL · 3단계

## 씨앗 → 뿌리 → 숲

■ 불변층 — 변하지 않는 3단계

- 0-6 씨앗 (개월) — 1개 부서·1개 업무·측정
- 6-12 뿌리 (개월) — 수평 확장·사내 챗봇/RAG·최소 규칙
- 12-24 숲 (개월) — 에이전트·자체 호스팅·보안/감사
- ∞ 원칙 — 작게 증명 → 넓게 정착 → 깊게 자동화

🕒 5분 · 3단계 모델

SAY

“로드맵의 뼈대는 단순합니다. 씨앗을 심고, 뿌리를 내리고, 숲을 만듭니다. 0~6개월 씨앗은 딱 한 부서 한 업무에서 효과를 증명하는 단계. 6~12개월 뿌리는 그 성공을 옆으로 넓히고 사내 공용 도구를 세우는 단계. 12~24개월 숲은 자동화와 자체 호스팅으로 회사 고유 인프라를 완성하는 단계입니다.”

SAY

“이 순서를 건너뛰면 거의 실패합니다. ‘숲’부터, 즉 처음부터 자율 에이전트와 자체 서버를 욕심내는 회사가 가장 크게 넘어집니다. 신뢰와 역량이 안 쌓였으니까요.”

NOTE

강사 배경지식: 이 3단계는 1강의 결론과 연결된다. 씨앗·뿌리는 보통 클라우드(경량)로 빠르게, 숲(중량·민감·자동화)에서 자체 호스팅으로 넘어간다. 즉 ‘처음부터 서버 사라’가 아니라 ‘검증되면 옮겨라’가 정석.

BRIDGE

“각 단계에서 구체적으로 무엇을 하는지, 실제 도구와 숫자로 보겠습니다.”

PHASE 1 · 씨앗

## 0-6개월: 씨앗 — 작게 증명

■ 원리 + ■ 2026.6 실행 예시

- 업무 1개 선정: 가장 반복적·측정 쉬운 것 (견적 초안·문의 1차응답·회의록)
- 베이스라인 2주 측정: ‘건당 시간·월 건수’를 숫자로 박제
- 도구: ChatGPT Team(1인 월 약 3만원) 또는 사내 시범 Open WebUI — 민감데이터 제외
- 4주 뒤 효과 측정 → 성공 1건이 다음 예산의 근거

🕒 8분 · 1단계

SAY

“씨앗 단계의 황금률은 ‘욕심내지 마라’입니다. 딱 한 부서, 한 업무. 가장 반복적이고 시간 측정이 쉬운 걸 고르세요. 견적서 초안, 고객 문의 1차 응답, 회의록 정리 — 이런 게 좋습니다.”

SAY

“먼저 2주간 베이스라인을 잡니다. ‘견적 1건에 평균 38분, 월 120건’ 이렇게요. 그다음 도구를 붙입니다. 이 단계는 택시를 타는 단계입니다 — 서버 사지 말고, ChatGPT Team 같은 클라우드를 1인 월 3만원에 몇 명만 써서 빠르게 검증하세요. 단, 민감 데이터는 절대 안 넣는 선에서.”

DO

워크시트: ‘우리 회사에서 가장 반복적인 업무 Top 3’를 적고, 그중 ‘시간 측정이 가장 쉬운 1개’에 동그라미. 그게 여러분의 씨앗. 측정 지표(예: 건당 분, 월 건수)도 그 자리에서 한 줄 정의.

NOTE

강사 배경지식 — Open WebUI: 무료 오픈소스 사내 챗봇 UI. Docker로 5분이면 설치되고, 뒤에 클라우드 API든 사내 Ollama든 붙일 수 있다. 시범 단계엔 클라우드 API를 붙여 빠르게, 검증되면 사내 모델로 교체하는 식. (자세한 설치는 4편.)

TIP

씨앗 단계에서 ‘전사 보안 규정부터 만들자’고 하면 6개월이 회의로 증발한다. ‘거버넌스는 2단계 일’이라고 선을 그어라. 지금은 증명이 전부.

“씨앗이 자랐으면, 옆으로 뿌리를 내립니다.”

## PHASE 2 · 뿌리

## 6-12개월: 뿌리 — 넓게 정착

■ 원리 + ■ 2026.6 실행 예시

- 성공 패턴을 옆 부서로 수평 확장 (영업 → 구매 → CS)
- 사내 공용 챗봇 + 문서검색(RAG): Open WebUI + Ollama + bge-m3 임베딩
- 최소 거버넌스: 데이터 3분류(공개/내부/기밀) + 사용규칙 A4 1~2장
- 민감도 상승 → 여기서부터 ‘자체 호스팅’ 본격 검토 (1강 5질문 재적용)

🕒 7분 · 2단계

## SAY

“뿌리 단계는 ‘한 부서의 성공’을 ‘회사의 일하는 방식’으로 바꾸는 단계입니다. 영업에서 통한 걸 구매·CS로 넓히고, 직원 모두가 매일 쓰는 사내 공용 챗봇을 만듭니다.”

## SAY

“여기서 RAG가 등장합니다. RAG는 쉽게 말해 ‘우리 회사 문서를 AI에게 읽혀서, 우리 회사 전용 비서로 만드는 기술’입니다. 사규·제품 매뉴얼·과거 견적을 넣어두면, 직원이 ‘작년 A사 납품 단가 얼마였지?’ 하고 물으면 우리 문서에서 찾아 답합니다.”

## NOTE

강사 배경지식 — RAG 구성요소(2026.6 예시): ① 사내 챗봇 UI = Open WebUI ② 모델 구동 = Ollama ③ 문서를 숫자로 바꿔 검색하는 ‘임베딩 모델’ = bge-m3(한국어 우수, 무료) ④ 그 숫자를 저장·검색하는 ‘벡터 DB’ = Qdrant. 이 네 개가 한 세트. (실제 구축은 4편에서 단계별로.) 핵심 함정은 다음 TIP 참고.

## SAY

“이 단계에서 비로소 최소한의 규칙이 필요합니다. 데이터를 공개·내부·기밀 세 가지로 나누고, ‘기밀은 사내 AI에만, 공개는 클라우드도 OK’ 같은 규칙을 A4 한두 장으로 만드세요. 처음부터 100페이지 규정집 만들지 마세요. 안 지켜집니다.”

#### TIP

뿌리 단계 실패 1순위: '정리 안 된 문서를 RAG에 통째로 넣기'. 옛날 버전·중복·오류 문서를 넣으면 AI가 틀린 답을 자신 있게 한다. '쓰레기를 넣으면 쓰레기가 나온다(garbage in, garbage out)' — 문서 정리가 먼저라고 못 박아라.

#### BRIDGE

“정착이 끝나면, 이제 우리 회사만의 ‘숲’을 만들 차례입니다.”

#### PHASE 3 · 숲

## 12-24개월: 숲 — 깊게 자동화

■ 원리 + ■ 2026.6 실행 예시

- 반복 업무를 '자율 에이전트'로 자동화 (메일→사양→견적서 초안 자동 생성)
- 민감·중량 업무를 자체 호스팅으로 이전 → 1강 BEP가 여기서 역전
- 필수 안전장치: 권한 분리·변경 로깅·백업·재해복구(DR)
- 도구 예: 공식 에이전트 Claude Code / 자체 개발 Claude Agent SDK

🕒 6분 · 3단계

#### SAY

“숲 단계는 'AI가 묻는 말에 답하는' 걸 넘어 'AI가 일을 대신 처리하는' 단계입니다. 이게 에이전트입니다. 예를 들어 고객 메일이 오면 → 사양을 뽑고 → 부품표(BOM)를 만들고 → 견적서 초안까지 자동으로 만들어 담당자에게 '확인하세요' 하고 올리는 식이죠.”

#### SAY

“바로 이 단계에서 1강의 손익분기가 현실이 됩니다. 에이전트는 토큰을 폭발적으로 쓰니까, 클라우드로 돌리면 월 수백만원이 나옵니다. 그래서 '중량·상시·민감' 업무를 사내 서버로 옮기는 겁니다. 1강에서 계산한 그 7개월 회수가 여기서 적용됩니다.”

#### SAY

“대신 이 단계엔 안전장치가 필수입니다. AI가 회사 핵심 업무에 손을 대니까요. 부서별로 권한을 나누고, AI가 뭘 바꿨는지 다 기록하고, 백업과 복구 체계를 갖춰야 합니다. 이걸 본 강좌 6편부터 10편에서 깊게 다룹니다.”

#### NOTE

강사 배경지식: ‘에이전트’와 ‘챗봇’의 차이 — 챗봇은 한 번 묻고 한 번 답한다. 에이전트는 목표를 주면 스스로 도구를 써서(파일 읽기, 메일 보내기, 시스템 입력) 여러 단계를 자율 수행한다. 그래서 강력하지만 위험도 크다. ‘권한을 어디까지 줄 것인가’가 6·7편의 핵심 주제.

#### TIP

‘우리도 에이전트부터 하면 안 되나요?’ 질문 자주 나옴. 답: ‘안 됩니다. 씨앗·뿌리에서 신뢰와 역량, 그리고 깨끗한 데이터가 쌓인 다음입니다. 기초 없이 자동화하면 틀린 걸 빠르게 대량으로 틀립니다.’

LAWS · 성공/실패

## 변하지 않는 성공·실패 법칙

### ■ 불변증

- ☒ 작게 증명 → 측정 → 확산 (순서 엄수)
- ☒ 경영진 후원자 1명 + 현장에서 직접 쓰는 ‘챔피언’ 1명
- ☒ 전사 일괄 도입 · ☒ 측정 없는 도입 · ☒ 시작 전 거버넌스 과잉
- ☒ 도구만 깔고 교육·후속 관리 없음

🕒 5분 · 법칙

#### SAY

“2년 로드맵에서 변하지 않는 법칙입니다. 성공하는 회사는 작게 증명하고, 숫자로 재고, 옆으로 넓힙니다. 그리고 반드시 두 사람이 있습니다 — 예산을 지켜주는 경영진 후원자 한 명, 현장에서 매일 직접 쓰며 동료들 가르치는 챔피언 한 명.”

#### SAY

“실패하는 회사는 정반대입니다. 한 번에 전사 도입, 측정 없이 ‘좋겠지’, 시작도 전에 완벽한 규정부터, 그리고 계정만 깔아주고 교육도 후속관리도 없음. 이 네 가지만 피해도 성공 확률이 확 올라갑니다.”

#### Q

“우리 회사에서 ‘AI 챔피언’이 될 만한 사람, 떠오르는 이름 있으세요?” → 이름이 바로 나오면 좋은 신호. 안 나오면 ‘그 사람을 찾는 게 진짜 0단계’라고 짚어준다.

TIP

이 슬라이드는 경영진의 ‘각오’를 받아내는 자리. ‘후원자 없이는 6개월 안에 무조건 흐지부지됩니다’라고 단호하게 말해도 좋다.

WORKSHOP + 마무리

## 실습 — 우리 회사 90일 계획 1장

■ 적용 + 1편 정리

- ① 씨앗 업무 1개 + 측정 지표 1개 + 현재 베이스라인 숫자
- ② 90일 목표: ‘\_\_\_를 \_\_\_% 단축/개선’ (숫자로)
- ③ 챔피언 1명 + 경영진 후원자 1명 (실명)
- 불변: 주권·3원리·5질문·3단계 / ■ 가변: 가격·GPU·도구명 → 다음 2편 인프라

🕒 10분 · 워크숍·마무리

DO

조별로 한 장을 채운다. (1) 우리의 씨앗 업무는 \_\_\_\_, 측정 지표는 \_\_\_\_, 현재 베이스라인은 \_\_\_\_ . (2) 90일 목표: \_\_\_\_, \_\_\_\_, \_\_\_\_% 단축/개선. (3) 챔피언: \_\_\_\_ (실명), 경영진 후원자: \_\_\_\_ (실명) . — 빈칸이 다 채워지면 그게 다음 주에 시작할 실행계획서다.

SAY

“이 한 장이 오늘 강의의 결과물입니다. 완벽하지 않아도 됩니다. ‘다음 주 월요일에 누가, 무엇을, 어떻게 측정하며 시작할지’가 적혀 있으면 성공입니다. 김 대리도 딱 이 한 장으로 시작했습니다 — 견적서, 38분→목표 15분, 챔피언 박 과장, 후원자 사장님. 그게 2년 뒤 회사 전체로 퍼진 ‘숲’의 첫 씨앗이었습니다.”

SAY

“1편을 한 문장으로 정리하면 — ‘AI 도입은 비용이 아니라 지능과 데이터의 주권 문제이고, 그 답은 우리 회사 토큰량과 5질문으로 숫자로 낸다. 그리고 작게 증명해 크게 키운다.’ 가격과 도구 이름은 잊으셔도 됩니다. 계산하는 법과 5질문, 3단계만 가져가세요.”

BRIDGE

“다음 2편은 ‘인프라’입니다 — 자체구축을 택했다면 어떤 GPU·서버·네트워크가 필요한지, 오늘 본 장비표를 실제 구축 절차로 풀어드립니다. 오늘 만든 ‘경계선 1장’과 ‘90일 계획 1장’ 꼭 챙겨 경영진과 공유하세요. 수고하셨습니다.”