

인프라 — 클라우드냐 자체 호스팅이냐 — 4가지 질문으로 결정한다

1강 인프라 결정 4질문 + 2강 하드웨어·OS·컨테이너 + 3강 네트워크·보안·격리 (총 120분)

코스	Course 02 · 사내 AI 구축·운영 종합 가이드
강의	1강(60분) + 2강(60분) + 3강(60분) = 총 180분
대상	IT 담당자·시스템 운영자 (초보자 톤 유지)
URL	visionc.co.kr/ai-solution/academy/build-ai
비밀번호	visioncDown (대소문자 구분)
형식	사내 출강 / 워크숍

INTRO · TITLE

인프라 결정의 4가지 질문

1강 — 클라우드냐 자체 호스팅이나, 4질문으로 결정한다

 3분 · 시작·환영

SAY

“반갑습니다. 사내 AI 구축·운영 가이드 2편 ‘인프라’입니다. 2편은 3강으로 구성됩니다. 1강은 ‘인프라를 클라우드냐 자체 호스팅이나 어떻게 결정하나’, 2강은 ‘자체 호스팅한다면 어떤 하드웨어·OS·컨테이너가 필요하나’, 3강은 ‘네트워크·보안·격리를 어떻게 설계하나’입니다. 오늘 3강이 끝나면 ‘우리 회사 인프라 설계서 한 장’이 손에 남습니다.”

SAY

“2편의 약속도 1편과 동일합니다. 모든 수치·사례는 Anthropic 공식 블로그에서만 가져왔습니다. 출처 없는 ‘카더라’ 한 줄도 없습니다. 가격이나 GPU 모델명 같은 ‘1년 후 바뀔 정보’는 ‘가변층’으로 명시해 외우지 마시라고 표시했습니다. 대신 ‘5년 후에도 그대로’인 결정 프레임은 ‘불변층’으로 표시했습니다.”

SAY

“오늘 1강 60분은 가장 큰 결정 — ‘우리 회사가 클라우드를 쓸지, 자체 서버를 쓸지’ — 를 4가지 질문으로 정리합니다. 이 결정이 잘못 되면 6개월 뒤 ‘다시 결정’해야 합니다. 신중하게.”

Q

도입 질문 1: “2편 듣는 분 중 ‘1편을 들으셨고 1편 워크시트의 90일 계획서를 만드셨다’는 분 손 들어주세요.”
→ 보통 다수. → ‘좋습니다. 2편은 그 90일 계획서의 ‘인프라 부분’을 채우는 강의입니다. 1편 안 들으신 분은 2편 끝나고 1편 복습 권장.’

Q

도입 질문 2: “여러분 회사에서 ‘우리 서버에 직접 깔아야 할까, 클라우드를 써야 할까’ 고민하시는 분 손 들어주세요.” → 보통 다수. → ‘오늘 1강 60분이 그 답을 줍니다. 결론을 미리 드리면 — 처음 90% 회사는 클라우드가 정답입니다. 자체 호스팅은 ‘특정 조건’에서만 정답이에요. 그 조건이 무엇인지 4질문으로 명확하게.’

NOTE

★ 강사 핵심 배경지식 — 2편의 청중 대상: 2편은 1편과 달리 IT 담당자·시스템 운영자가 주요 대상. 다만 ‘기술 전문가’만 듣는 게 아니라 ‘기술 잘 모르는 의사결정자’도 함께 들을 수 있게 초보자 톤 유지. 전문용어(VRAM, mTLS 등) 등장 시 매번 풀이. 강사 입장: ‘초중급 IT 담당자와 의사결정자가 함께 듣는다’ 가정.

NOTE

강사 배경지식 — 2편 인용 출처 8건: 본 2편 자료의 1차 출처. (1) Anthropic 2026 Enterprise Report. (2) AI Transformation. (3) Cowork Deployment Guide. (4) Managed Agents. (5) How Anthropic teams use Claude Code. (6) Building AI Agents for Enterprise. (7) Self-Service Data Analytics. (8) Self-hosted sandboxes (Managed Agents 자체 호스팅 옵션). URL은 강의 자료 마지막에 모두.

NOTE

강사 배경지식 — 1강 60분 시간 배분 미리 알기: 0~5분 인사·복습. 5~20분 인프라 3가지 선택지 + 4질문 소개. 20~50분 4질문 각 5분씩 + 매트릭스. 50~58분 실제 회사 사례 2~3건. 58~60분 실습 + 마무리. 시간 압박 큼 — 질문에 길게 머물지 말 것.

TIP

강사 함정 — ‘기술 자랑’ 금지: 2편에서는 강사가 ‘저는 GPU 잘 압니다’ 같은 권위 호소 함정. 청중은 ‘배우러 왔지 자랑 들으러 안 왔다’. 정확한 톤: ‘여러분이 GPU 선택할 때 막히는 부분을 4질문으로 정리해드립니다’.

BRIDGE

“오늘 1강 60분 후 무엇을 할 수 있게 되는지 — 학습 목표부터 약속드립니다.”

OBJECTIVES

60분 후, 이 3가지를 한다

- ① 인프라 3가지 선택지(클라우드/자체/하이브리드)의 차이를 설명한다
- ② 4가지 결정 질문으로 우리 회사 인프라 방향을 짚는다
- ③ ‘우리 회사 인프라 결정서 1페이지’ 워크시트를 채운다

SAY

“오늘 1강 60분이 끝나면 다음 셋을 할 수 있게 됩니다. 첫째, 클라우드·자체 호스팅·하이브리드 — 세 가지 선택지의 정확한 차이와 장단점을 동료에게 설명할 수 있게 됩니다. ‘우리는 클라우드만 쓰자’, ‘무조건 자체 호스팅’ 같은 흑백 논리가 아니라 ‘이런 조건이면 클라우드, 저런 조건이면 자체’ 같은 분석적 답이 가능해집니다.”

SAY

“둘째, 4가지 결정 질문 — 데이터 민감도·토큰 사용량·운영 인력·연속성 요구 — 으로 우리 회사 인프라 방향을 짚어냅니다. 4질문은 ‘5년 후에도 유효’한 결정 프레임이에요. 도구·가격이 바뀌어도 이 질문은 그대로.”

SAY

“셋째, 가장 중요한 결과물 — ‘우리 회사 인프라 결정서 한 장’ 워크시트를 채웁니다. 1편에서 만든 ‘90일 계획서’와 함께 쓰면 사장님 결재용 ‘AI 도입 완전판 보고서’가 됩니다.”

SAY

“2편 전체로 보면 1강은 ‘무엇으로 갈지(방향)’, 2강은 ‘자체 호스팅이라면 어떤 장비(하드웨어)’, 3강은 ‘안전하게 어떻게 깔지(보안)’입니다. 셋이 합쳐지면 ‘우리 회사 인프라 설계서’ 한 장 완성.”

NOTE

★ 강사 핵심 배경지식 — 인프라 결정의 시간 가치: 인프라 결정은 한 번 하면 1~2년 영향. 잘못된 결정은 비용 큼. ‘잘못된 클라우드 → 자체로 이전’ 약 6개월 + 3,000만 원+. ‘잘못된 자체 → 클라우드로 이전’ 약 3개월 + 1,000만 원+. 즉 결정 30분 vs 수정 6개월. 신중함이 비용 절감.

NOTE

강사 배경지식 — 1편 90일 계획서와 연결: 1편 청중이 만든 90일 계획서엔 ‘챔피언·파일럿 업무·측정 지표·보고’ 4칸. 거기에 인프라 칸이 빠져 있음. 2편 1강이 그 ‘인프라 칸’을 채우는 데 도움. 1편 + 2편 1강이면 ‘완전한 90일 계획서’ 완성.

NOTE

강사 배경지식 — 4질문이 ‘불변총’인 이유: 데이터 민감도·사용량·인력·연속성 — 이 네 가지는 1980년대 IT 도입에도, 2000년대 SaaS 도입에도, 2026년 AI 도입에도 동일하게 작동. 변하는 건 ‘각 답이 어떤 도구를 가리키느냐’뿐. 4질문 자체는 5년 후에도 유효.

Q

도입 질문 (선택): “여러분 회사에서 이미 ‘인프라 결정 회의’를 한 번 이상 한 분 손 들어주세요.” → 보통 절반 미만. → “좋습니다. 결정 회의를 하지 않은 분이 더 많은 게 정상이에요. 오늘 1강이 그 회의의 ‘구조’를 줍니다. 회의 자체는 회사에 가서 하시면 되고, 오늘은 ‘회의 자료’를 만듭니다.”

TIP

강사 진행 팁 — 학습 목표 슬라이드 시간 초과 금지: 3분 안에 끝낸다. 학습 목표는 ‘약속’이지 ‘본문’이 아니다. 빠르게 다음 슬라이드로.

BRIDGE

“2강·3강 진도 안 빠지게 1강 핵심 5건만 빠르게 복습합니다. 그 다음 본격 4질문으로 들어갑니다.”

RECAP · 1편

1편 복습 — 5단계 모델과 90일 계획

■ 불변증 — 1편의 5개 핵심

- 1편 5개 산업 사례 — Novo Nordisk 10주→10분, L'Oréal 99.9%, Doctolib 40% ↑, eSentire 5h→7min, Thomson Reuters CoCounsel
- ★ 5단계 성숙도 모델 — L1 챗 Q&A → L2 파일럿 → L3 부서 확산/RAG → L4 자동화 → L5 부서별 플러그인
- ★ 4가지 성공 요인 — 구체적 병목 + 챔피언 + 성과 측정 + 엔터프라이즈급 보안
- ★ 90일 액션 플랜 — W1-4 준비 → W5-8 도입 → W9-10 측정 → W11-12 보고
- ★ ‘안 도입’이 ‘마구 도입’보다 위험 — 작게 시작 + 안전장치

🕒 5분 · 1편 복습

SAY

“2편 본문 들어가기 전에 1편 핵심 5건을 30초씩만 빠르게 다시 보겠습니다. 1편 안 들으신 분도 따라갈 수 있게.”

SAY

“첫째, 5개 산업 사례. Novo Nordisk가 임상 보고서 10주→10분, L'Oréal이 직원 44k명 데이터 분석 99.9%, Doctolib이 기능 출시 40% 빨라짐, eSentire가 보안 분석 5시간→7분, Thomson Reuters CoCounsel이 150년 판례 1분 검색. 모든 산업에서 도입 가능합니다.”

SAY

“둘째, 5단계 성숙도 모델. L1 직원이 ChatGPT에 묻기 → L2 한 부서 파일럿 → L3 부서 확산 + 사내 챗봇 · RAG → L4 자동화 에이전트 → L5 부서별 플러그인. 우리 강좌가 다루는 전체 여정.”

SAY

“셋째, 4가지 성공 요인. 구체적 병목 타킷 + 챔피언 네트워크 + 성과 측정 + 엔터프라이즈급 보안. 네 가지가 다 갖춰진 회사가 80% ROI를 봤습니다.”

SAY

“넷째, 90일 액션 플랜. Week 1-4 준비, 5-8 도입, 9-10 측정, 11-12 보고. 1편 워크시트가 이 4칸을 채우는 거였죠.”

SAY

“다섯째, ‘안 도입’이 ‘마구 도입’보다 위험. 안 도입은 ‘조용한 침몰’, 마구 도입은 ‘즉시 사고이지만 회복 가능’. 답은 ‘작게 시작 + 안전장치’.”

STORY

1편 인용 출처 8건 다시 (강사 신뢰성). (1) Anthropic 2026 Enterprise Report. (2) AI Transformation. (3) Cowork Deployment Guide. (4) Managed Agents. (5) How Anthropic teams use Claude Code. (6) Building AI Agents for Enterprise. (7) Self-Service Data Analytics. (8) Introducing Agent Skills. 모든 사례 1차 출처 명시. 2편도 동일 원칙.

NOTE

★ 강사 핵심 배경지식 — 1편 청중과 2편 청중 차이: 1편 청중은 의사결정자·일반 직원·관리자가 많음. 2편 청중은 IT 담당자가 늘어남. ‘1편 안 들으신 IT 담당자’ 가능성 높음. 이 슬라이드(5분 복습)가 그분들을 위한 다리. 5분에 1편 핵심 정리.

NOTE

강사 배경지식 — 5단계와 인프라 관계: 5단계마다 인프라 요구가 다름. L1 클라우드 무료 등급. L2 클라우드 유료 5계정. L3 사내 RAG 인프라 (작은 서버 1대). L4 본격 에이전트 인프라 (서버 + 보안). L5 부서별 인프라 + 통합 인증. 즉 ‘우리 회사가 L1·L2면 자체 호스팅 불필요’가 정답일 가능성 높음.

NOTE

강사 배경지식 — 1편 4가지 성공 요인 중 ‘엔터프라이즈급 보안’이 2편의 본질: 4가지 중 ‘보안’이 인프라와 직결. 1편에선 ‘처음부터 설계’만 강조하고 끝났는데, 2편이 그 ‘처음부터 어떻게 설계’를 자세히 다룸. 본 강좌 9편 (보안·권한·감사)은 보안만 다루는 별도 편.

Q

발표 요청: “1편 5단계 모델에서 ‘우리 회사 현재 단계’를 적었던 분 — 우리는 몇 단계인지 한 줄로 답해보세요.” → 보통 L0/L1. → ‘좋습니다. L0/L1이면 ‘인프라 결정’이 아직 급하지 않을 수도 있어요. 오늘 1강은 ‘L3 진입 시점에 할 결정’을 미리 준비하는 강의이기도 합니다.’

TIP

강사 진행 팁 — 5분 복습 시간 배분: 5개 핵심을 30초씩 $\times 5 = 2.5$ 분. 나머지 2.5분 ‘1편과 2편 연결’ + 청중 질문. 복습이 5분 넘으면 본문 시간 부족.

BRIDGE

“좋습니다. 복습 끝. 본격적으로 — 인프라 결정의 첫 단계는 ‘3가지 선택지’를 정확히 아는 것입니다.”

3 OPTIONS

인프라 3가지 선택지

■ 불변증 — 5년 후에도 같은 3개

- Cloud 클라우드 API — Anthropic·OpenAI·Google 등의 API를 인터넷으로 사용. 초기 비용 0, 쓴 만큼 지불. 가장 빠르고 편함. L1·L2·L3 시작점.
- On-Prem 자체 호스팅 — 회사 서버에 오픈소스 AI(Llama·Qwen 등) 직접 설치. 초기 장비 투자. 데이터가 회사 밖으로 안 나감. 민감 데이터 + 대량 사용에 정당화.
- Hybrid 하이브리드 (혼합) — 민감한 부분만 자체, 일반은 클라우드. 80% 중대형 기업이 도달하는 모습. ‘처음부터 하이브리드’ X — L1~L2 클라우드로 시작 후 진화.
- Managed Managed Agents (자체 호스팅 옵션) — Anthropic 클라우드 인프라 + 자체 호스팅 sandbox 결합. 2026년 등장 신규 옵션. 운영 부담 최소화하면서 일부 데이터 격리 가능.

🕒 6분 · 3가지 선택지

SAY

“인프라 선택지는 본질적으로 3개입니다 — 클라우드, 자체 호스팅, 하이브리드. 2026년 들어 ‘Managed Agents 자체 호스팅 sandbox’라는 네 번째 옵션이 등장했지만 본질적으로는 하이브리드의 변형이에요.”

SAY

“첫째 — 클라우드. Anthropic Claude API, OpenAI ChatGPT API, Google Gemini API를 인터넷으로 사용. 초기 비용 0, 쓴 만큼 지불. 시작 1분에 가능. L1·L2·L3는 클라우드로 충분합니다. 90% 한국 회사가 여기서 시작해야 합니다.”

SAY

“둘째 — 자체 호스팅 (On-premises, 줄여서 온프레임). 회사 서버에 Llama·Qwen 같은 오픈소스 AI를 직접 설치. 초기 장비 투자 1,000~5,000만 원. 데이터가 회사 밖으로 안 나가요. 두 조건일 때만 정당화 — ① 민감 데이터 외부 송신 절대 금지, ② 사용량이 매월 1,000만 토큰+로 폭증.”

SAY

“셋째 — 하이브리드. 민감 부분만 자체, 일반 업무는 클라우드. 80% 중대형 기업이 도달하는 모습이에요. 중요한 — ‘처음부터 하이브리드’는 X. 처음엔 클라우드 → L3·L4에서 ‘이 부분만 자체’ 결정 → 하이브리드로 진화.”

SAY

“넷째 — Managed Agents 자체 호스팅 sandbox. 2026년 Anthropic이 새로 추가한 옵션. Claude API는 클라우드, 에이전트가 실행하는 ‘작업 환경(sandbox)’만 회사 서버. 운영 부담을 줄이면서 민감 작업은 자체 격리. 하이브리드의 새로운 형태.”

STORY

Managed Agents 자체 호스팅 sandbox 출처. Anthropic ‘New in Claude Managed Agents: self-hosted sandboxes and MCP tunnels’. URL: claude.com/blog/claude-managed-agents-updates. 2026년 발표. 기존 ‘완전 클라우드’와 ‘완전 자체’의 중간 — ‘AI 모델은 Anthropic 클라우드, 작업 환경은 회사 서버’ 분리.

STORY

한국 회사 인프라 선택 분포 (강사 대응용 추정). 2026년 기준 한국 중소·중견기업 약 70%가 클라우드만 사용. 약 20%가 하이브리드. 약 10%가 자체 호스팅 (주로 대기업). 신규 도입 시 95% 클라우드부터 시작.

NOTE

★ 강사 핵심 배경지식 — ‘API’ 풀이: API = Application Programming Interface. 회사·서비스가 ‘우리 기능을 다른 프로그램이 쓸 수 있게 열어둔 문’. ‘Claude API’ = Anthropic이 Claude 모델 기능을 다른 회사가 쓸 수 있게 연 문. 회사 시스템에서 ‘Claude API 호출’ → ‘인터넷으로 Anthropic에 질문 전송’ → ‘응답 받음’. 즉 ‘회사 → 인터넷 → Anthropic 서버 → 응답’ 경로.

NOTE

강사 배경지식 — 클라우드 데이터 흐름의 정확한 이해: ‘클라우드 = 데이터 사는 거’ 오해 흔함. 정확히는 (1) 회사 → API 요청에 데이터 포함. (2) Anthropic 서버가 데이터로 답 생성. (3) 답 반환. (4) 운영 로그로 일정 기간(보통 30일) 보관 후 삭제. (5) 학습에 사용 X (엔터프라이즈 약관). 즉 ‘일정 기간 외부 보관’은 사실. ‘영원히 저장 또는 학습 사용’은 아님.

NOTE

강사 배경지식 — 온프레미스 + 오픈소스 LLM: 자체 호스팅 시 사용하는 모델 (1) Meta Llama 3.3 — 가장 인기, 한국어 준수. (2) Alibaba Qwen 2.5 — 한국어·코딩 우수. (3) DeepSeek V3 — 추론·코딩 강점, 가성비 1위. (4) Mistral — 경량, 사내 챗봇용. (5) Korea 특화 — Solar (Upstage), EXAONE (LG), KULLM (고려대). 모두 무료 + 상업 이용 가능. 본 강좌 3편이 자세하.

NOTE

강사 배경지식 — 하이브리드 패턴 3가지: (1) 데이터 기반 — 민감 데이터는 자체, 공개 데이터는 클라우드. 가장 흔함. (2) 시간 기반 — 평시 클라우드, 야간 자체 (비용 절감). (3) 사용자 기반 — 임원·법무는 자체, 일반 직원은 클라우드. 회사 정책에 따라 다양.

Q

예상 청중 질문 1: ‘처음부터 하이브리드 만들면 안 되나?’ → 답: ‘안 됩니다. ‘처음부터 하이브리드’는 가장 큰 함정. 클라우드만 + 자체 호스팅만 — 각각 단순. 둘 다 운영하면 복잡도 2배+, 비용 2배+, 운영 부담 3배. L1·L2 클라우드로 시작 → 검증 후 ‘이 부분만 자체’ 진화가 정석.’

Q

예상 청중 질문 2: ‘Managed Agents sandbox 옵션 우리 회사 맞나?’ → 답: ‘조건 두 가지. (1) 이미 L4(에이전트) 진입했거나 진입 예정. (2) 일부 작업 환경(예: 사내 DB 접근)을 격리하고 싶음. 둘 다 해당 안 되면 일반 Managed Agents 충분. L1~L3 회사는 sandbox 옵션 검토 불필요.’

Q

예상 청중 질문 3: ‘외부 클라우드 안 쓰고 100% 자체 호스팅 가능?’ → 답: ‘가능합니다. 단 가능과 권장은 다름. 100% 자체는 — (1) 모든 모델·인프라 직접 관리, (2) 모델 업데이트도 직접, (3) 비용·시간 가장 큼. ‘우리는 외부 의존 절대 없다’는 회사(예: 일부 방산·정부)만 권장.’

TIP

강사 함정 — ‘우리는 자체 호스팅이 좋겠다’ 청중 우려 정면 반박: 청중이 ‘우리는 데이터 보안 때문에 자체’라고 미리 결정 채 들어오는 경우 다수. 답: ‘결정은 4질문 보고 하셔도 늦지 않습니다. 4질문 다 ‘예’ 나오면 자체 호스팅이고, 아니면 다른 답일 수 있어요.’ 청중 결정 미루기.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘3+1 선택지’. 1~5분 각 선택지 60초씩. 5~6분 ‘처음부터 하이브리드 함정’ + 청중 질문. 첫 번째 클라우드 설명에 가장 많은 시간 (1분 30초) — 대부분 회사의 정답이므로.

BRIDGE

“그렇다면 어떻게 결정하나? 4가지 결정 질문으로 정리됩니다. 이 4질문이 오늘 1강의 핵심 도구입니다.”

Q1 · DATA SENSITIVITY

결정 질문 ① 데이터 민감도

■ 불변증 — 외부 송신 가능한 데이터인가?

- 공개·일반 업무 데이터 (가능 데이터 (클라우드 OK)) — 회의록 초안, 이메일 작성, 일반 보고서, 외국어 번역, 공개된 기술 문서. 외부 송신해도 회사 손해 없음. 90%의 일상 업무.
- 외부 송신 절대 금지 (민감 데이터 (자체 호스팅 검토)) — 고객 개인정보, 신용카드·계좌, 도면·BOM, 신약·신기술 개발 자료, M&A 정보, 법무 계약서. 외부 송신 시 법적·재무적·평판 손해.

🕒 6분 · 데이터 민감도

SAY

“첫 번째 질문 — 데이터 민감도. ‘우리가 AI에 넣을 데이터가 외부 송신 가능한가?’입니다. 이게 4질문 중 가장 결정적이에요.”

SAY

“민감 vs 비민감 구분이 핵심. 비민감 데이터 — 회의록 초안, 이메일 작성, 일반 보고서, 외국어 번역, 공개된 기술 문서. 이런 건 외부 클라우드에 보내도 회사 손해 없습니다. 90%의 일상 업무가 여기에 해당해요.”

SAY

“민감 데이터 — 고객 개인정보, 신용카드·계좌, 도면·BOM, 신약·신기술 개발 자료, M&A 정보, 법무 계약서. 외부 송신 시 법적·재무적·평판 손해 발생. 한국 개인정보보호법 위반, 영업비밀 노출 등.”

SAY

“핵심 메시지 — ‘회사 전체’가 민감한 게 아니에요. ‘일부 데이터만’ 민감합니다. 우리 회사 데이터 100건 중 — 일반 업무 80건은 클라우드 OK, 민감 데이터 20건은 자체 호스팅 검토. 이 80:20 패턴이 ‘하이브리드’ 선택의 근거입니다.”

STORY

한국 개인정보보호법 제28조의8 (개인정보 국외이전). 개인정보를 해외 클라우드로 보내려면 (1) 정보주체 동의 또는 (2) 법령에 근거 또는 (3) 별도 보호 조치 필요. 즉 ‘고객 이름·전화번호’ 같은 개인정보를 Claude·ChatGPT(미국 서버)에 그냥 넣으면 위반 소지. 정확한 적용은 법무 검토 권고. 본 강좌 9편(보안·권한·감사)에서 자세히.

STORY

삼성전자 2023년 4월 사고 (강사 대응용). 엔지니어가 사내 반도체 코드를 ChatGPT에 입력 → 데이터 유출 확인 → 회사 전사 ChatGPT 사용 금지. 이후 자체 호스팅 ‘Gauss’ 개발 → 사내 사용 허용. 약 9개월 단절. ‘일단 외부에 넣고 회수 안 됨’의 대표 사례. 출처: Bloomberg 2023-05, Korean Times 2023-05.

NOTE

★ 강사 핵심 배경지식 — 데이터 민감도 6가지 등급: 한국 보안업계 표준. (1) 공개 — 홈페이지, 카탈로그. (2) 내부 — 사내 매뉴얼, 회의록. (3) 기밀 — 견적·단가, 고객 일반 정보. (4) 극비 — 신기술, 도면, 핵심 알고리즘. (5) 개인정보 — 이름·전화번호·이메일. (6) 민감정보 — 건강·신용·생체. ‘1~2 단계’는 클라우드 OK, ‘3 단계’는 익명화 후 OK, ‘4~6 단계’는 자체 호스팅 강력 검토.

NOTE

강사 배경지식 — Anthropic 엔터프라이즈 약관의 ‘데이터 보호’ 약속: Claude API 엔터프라이즈 등급 약관 명시. (1) 입력 데이터를 모델 학습에 사용 X. (2) 운영 로그 일정 기간(약 30일) 보관 후 삭제. (3) 한국 서비스라면 서울 리전 옵션 (단 일부만). 단 한계 — (a) 30일 동안 외부 서버 보관됨. (b) 약관 변경 가능. 출처: Anthropic Privacy Policy.

NOTE

강사 배경지식 — ‘익명화’의 한계: ‘고객 이름 지워서 보내면 OK 아닌가?’ 흔한 질문. 답: 부분 해결. (1) 단순 이름·번호 제거는 부족 — 다른 정보 조합으로 식별 가능 (재식별 위험). (2) 진정한 익명화는 ‘k-익명성’ 같은 통계 기법 필요. (3) 가장 안전 — 익명화 + 자체 호스팅 결합. 본 강좌 9편 보안편이 익명화 기법 다룸.

NOTE

강사 배경지식 — Q1 답에 따른 분기: (1) 우리 데이터 모두 비민감 → 클라우드만으로 충분 (50% 회사). (2) 일부 민감 (20:80) → 하이브리드 검토 (30% 회사). (3) 대부분 민감 (50:50 이상) → 자체 호스팅 강력 검토 (20% 회사). 우리 회사 데이터 비율을 파악하는 게 Q1 답.

Q

예상 청중 질문 1: ‘우리는 고객 정보 다루는데 무조건 자체 호스팅인가?’ → 답: ‘아닙니다. 정확히는 ‘고객 정보를 AI에 넣을 일이 있나’가 기준. 만약 ‘영업 메일 작성’만 한다면 고객 정보 안 넣어도 됨 — 클라우드 OK. ‘고객 데이터 분석’이라면 익명화 후 OK 또는 자체 호스팅.’

Q

예상 청중 질문 2: ‘Anthropic이 학습에 안 쓴다고 약속해도 약관 바뀌면?’ → 답: ‘좋은 질문. 약관 변경 가능성 자체는 0이 아님. 따라서 ‘외부 송신 절대 금지’ 데이터는 자체 호스팅 정답. ‘약관 변경되면 6개월 안에 대응 가능’ 데이터는 클라우드 OK. 위험 회수 시간이 기준.’

Q

예상 청중 질문 3: ‘우리는 어느 정도 민감한지 모르겠는데?’ → 답: ‘회사 보안팀에 ‘우리 데이터 6단계 분류 있나요’ 물어보세요. 보통 있어요. 없으면 본 강좌 9편 보안편이 분류 가이드 제공.’

TIP

강사 함정 — ‘우리는 다 민감하다’ 청중 과장 정면 반박: 청중이 ‘우리 회사 모든 데이터가 민감’이라 주장하는 경우 자주. 답: ‘회의록 초안도 민감입니까? 외국어 번역도? 정말 ‘모든’ 데이터가 민감하면 우리 회사 직원 노트북·메일도 못 쓰는 거예요. 비현실적.’ 청중 과장 깨주기.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘Q1이 가장 결정적’. 1~3분 민감 vs 비민감 구분. 3~4분 ‘80:20 패턴’ 메시지. 4~5분 한국 법규 + 삼성 사고. 5~6분 청중 질문. 한국 법규는 매우 중요 — 시간 충분히.

“민감도가 정리됐다면 — 두 번째 질문 ‘얼마나 많이 쓸 거냐’입니다. 사용량이 폭증하면 비용 구조가 뒤집힙니다.”

Q2 · USAGE VOLUME

결정 질문 ② 토큰 사용량

■ 가변층 — 2026.6 손익분기점 예시

- 100만 토큰/월 이하 (소형) — 직원 5~10명 일상 사용. 클라우드 월 비용 약 1~5만 원. 자체 호스팅 정당화 X. 95% 한국 중소기업이 여기.
- 500만 토큰/월 (중형) — 직원 30~50명 일상 사용. 클라우드 월 비용 약 30~100만 원. 자체 호스팅 손익분기 12개월+. 여전히 클라우드 권장.
- 1,000만 토큰/월 (대형) — 직원 100명+ 또는 챗봇·RAG 본격 사용. 클라우드 월 비용 100~500만 원. 자체 호스팅 손익분기 약 6개월. 검토 시작.
- 5,000만+ 토큰/월 (초대형) — 직원 500명+ 또는 에이전트 본격 운영. 클라우드 월 비용 500만~수천만 원. 자체 호스팅 손익분기 3~6개월. 자체 호스팅 권장.

🕒 6분 · 토큰 사용량

SAY

“두 번째 질문 — 토큰 사용량. ‘우리 회사 월 사용량이 얼마나 될 거냐’입니다. 사용량이 작으면 클라우드 압승, 폭증하면 자체 호스팅이 정답입니다.”

SAY

“숫자로 감 잡아봅시다. 토큰 1만 개 = A4 약 3.3페이지 분량. 직원 1명이 하루 30번 ChatGPT 같은 거 쓴다면 약 6만 토큰/일. 월 22일 근무라면 약 130만 토큰/월. 즉 1명 = 약 130만 토큰. 10명이면 1,300만 토큰. 50명이면 6,500만 토큰.”

SAY

“구간별로 봅시다. 100만 토큰/월 이하 — 직원 5~10명 일상 사용. 클라우드 월 1~5만 원. 95% 한국 중소기업이 여기. 자체 호스팅 정당화 X.”

SAY

“500만 토큰/월 — 30~50명 사용. 클라우드 월 30~100만 원. 자체 호스팅 손익분기 12개월+. 여전히 클라우드 권장.”

SAY

“1,000만 토큰/월 — 100명+ 또는 RAG 본격 사용. 클라우드 월 100~500만 원. 자체 호스팅 손익분기 약 6개월. 본격 검토 시작.”

SAY

“5,000만+ 토큰/월 — 500명+ 또는 에이전트 본격. 클라우드 월 500만~수천만 원. 자체 호스팅 손익분기 3~6개월. 자체 호스팅 권장.”

STORY

토큰 가격 출처 (2026년 6월 기준). Claude 3.5 Sonnet 입력 \$3/100만 토큰, 출력 \$15/100만 토큰. ChatGPT GPT-4o 입력 \$2.5, 출력 \$10. 평균 입력:출력 1:0.3 비율로 가정 시 1,000만 토큰 = 약 \$50~80 = 약 7~12만 원. 출처: Anthropic Pricing, OpenAI Pricing 공식. URL: anthropic.com/pricing, openai.com/api/pricing.

STORY

자체 호스팅 비용 추정 (2026년 6월 기준, 강사 대응용). 초기 GPU 워크스테이션 (4090×2장) 약 1,500만 원. 서버 + 네트워크 약 500만 원. 합 2,000만 원 초기. 월 운영 (전기+관리) 약 50만 원. 토큰 비용 0. 즉 ‘초기 2,000만 원 + 월 50만 원’ vs ‘클라우드 월 N만 원’. N>200만이면 12개월 손익분기. N>500만이면 4~6개월.

NOTE

★ 강사 핵심 배경지식 — ‘토큰’이 정확히 무엇: AI가 글자를 처리하는 단위. 한글 1글자 $\approx$ 1.5~2 토큰. 영어 1 단어 $\approx$ 1.3 토큰. A4 한 장 (1,800자) $\approx$ 3,000 토큰. 한 번 질문+답변(왕복) $\approx$ 1,000~3,000 토큰. 한국어가 영어보다 ‘토큰 비용’ 2~3배. 즉 ‘한국 회사가 영어권 회사보다 비용 부담 큼’.

NOTE

강사 배경지식 — 토큰 사용량 추정 방법: 회사 전체 토큰 예측 어려움. 단순 공식 — 직원수 $\times$ 월 130만 토큰 $\times$ 사용률. ‘사용률’이 키. 챔피언 5명 시작이면 5명 $\times$ 100% = 5명 분 = 650만 토큰/월. 부서 확산 시 30명 $\times$ 50% = 15명 분 = 약 2,000만 토큰/월. 전사 100명 $\times$ 50% = 50명 분 = 약 6,500만 토큰/월. 단계별 예측.

NOTE

강사 배경지식 — RAG·에이전트 토큰 폭증: 일반 사용 토큰량의 5~20배 빠르게 늘어남. 이유 — (1) RAG는 ‘검색 결과 + 답’ 두 번 처리. (2) 에이전트는 ‘여러 단계’ 자율 수행. 즉 ‘직원 1명 일반 사용 130만 $\rightarrow$ RAG 사용 500만 $\rightarrow$ 에이전트 사용 2,000만’ 식. L3 진입 시 토큰량 급증, 자체 호스팅 검토 시점.

NOTE

강사 배경지식 — Q2 답에 따른 분기: (1) 100만 토큰/월 이하 — 클라우드 확정. 자체 호스팅 비현실. (2) 100~1,000만 — 클라우드 권장. (3) 1,000~5,000만 — 하이브리드 또는 자체 호스팅 검토 시작. (4) 5,000만+ — 자체 호스팅 강력 권장. 단 Q1(데이터 민감도) 답이 ‘비민감’이면 클라우드 유지 가능.

Q

예상 청중 질문 1: ‘우리 회사 토큰량 모르는데 어떻게 추정?’ → 답: ‘쉽게 — 직원수 × 130만 × 사용률. 100명 회사 + 챔피언 5명만 사용 = 650만/월. 100명 + 50% 사용 = 6,500만/월. 본 강좌 1편의 90일 플랜대로 L2부터 측정 시작하면 정확.’

Q

예상 청중 질문 2: ‘월 5만 원 vs 자체 호스팅 2,000만 원이면 자체는 영원히 손해 아닌가?’ → 답: ‘100만 토큰/월이라면 그렇습니다. 자체 호스팅 정당화 X. 다만 1편 5단계에서 L3·L4 진입 시 토큰량 폭증 — 그때 손익분기점 도달. 지금 결정이 아니라 ‘언제 갈아탈지’ 결정.’

Q

예상 청중 질문 3: ‘토큰 비용이 매년 떨어진다는데 자체 호스팅도 같이 손해 아닌가?’ → 답: ‘맞아요. 토큰 가격은 2년간 약 10배 떨어졌습니다. 앞으로도 떨어질 것. 즉 ‘클라우드 비용 줄어서 손익분기점 이동’ 가능. 자체 호스팅 결정은 ‘비용’만이 아니라 ‘데이터 통제권’도 같이.’

TIP

강사 함정 — ‘토큰 가격 외우게 만들기’ 금지: 가격은 가변층. ‘외우지 마세요. 손익분기점이 1,000만 토큰/월 근처라는 감만 가지세요’ 메시지. 가격표 디테일에 시간 쓰지 말 것.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘토큰 = 무엇’ 풀이. 1~2분 4구간 빠르게. 2~3분 회사 토큰량 추정 공식. 3~4분 RAG·에이전트 폭증. 4~5분 손익분기점. 5~6분 청중 질문. 추정 공식이 가장 실용적 — 시간 충분히.

BRIDGE

“민감도와 사용량을 봤다면 — 세 번째 질문 ‘서버 운영할 사람이 있나’입니다. 운영 인력이 없으면 자체 호스팅 X.”

Q3 · OPERATIONS STAFF

결정 질문 ③ 운영 인력

■ 불변증 — 사람이 없으면 자체 호스팅 X

- ★ 핵심 원칙 — ‘서버 24시간 운영 가능한 사람’ 있나?
- 필요 역량 — Linux + Docker + Network + Security 기초
- 최소 인력 — 자체 호스팅 운영 1명 + 백업 1명 (총 2명)
- 옵션 1 — 사내 IT팀 풀타임 (대형사)
- 옵션 2 — 외주 운영 (MSP) — 월 100~300만 원 (중소기업 현실적)
- 옵션 3 — 인력 없음 → 클라우드 (자체 호스팅 X)

🕒 5분 · 운영 인력

SAY

“세 번째 질문 — 운영 인력. ‘우리 회사에 서버 운영할 사람이 있나’입니다. 가장 잇기 쉬운 질문인데 가장 결정적이에요.”

SAY

“원칙 — 자체 호스팅한다는 건 ‘24시간 서버 운영’이라는 뜻입니다. 새벽 3시에 서버 다운되면 누가 일어나 고치나요? 그 사람이 있어야 자체 호스팅 가능.”

SAY

“필요 역량 4가지 — (1) Linux 운영 (Ubuntu 등). (2) Docker 컨테이너. (3) 네트워크 기초. (4) 보안 기초. 본 강좌 2강·3강이 이 4가지를 다룹니다.”

SAY

“최소 인력 — 1명으로는 불가능. 1명이 휴가·아프면 끝. 최소 2명 — 운영 1명 + 백업 1명. 또는 외주 운영 (MSP) — Managed Service Provider — 위탁.”

SAY

“옵션 3가지. 옵션 1 사내 IT팀 풀타임 — 대형사. 옵션 2 외주 MSP — 월 100~300만 원, 중소기업 현실적. 옵션 3 인력 없음 — 자체 호스팅 X, 클라우드 선택. 자기 현실 솔직히 답하세요.”

STORY

한국 IT 인력 현황 (강사 대응용). 한국 IT 인력 약 90만 명. 그중 '서버·인프라 운영자' 약 15만 명. 평균 연봉 5,500만 원, 시니어 1억+. 인력 부족 — 매년 8천 명+ 부족. '우리 회사에 적임자 영입' 어려움. 외주 MSP가 현실적 옵션. 한국 MSP 시장 약 1.2조 원, 주요 사업자 KT cloud·NHN cloud·삼성SDS·LG CNS·메가존 클라우드 등.

STORY

MSP(Managed Service Provider) 풀이 — 회사가 직접 서버 운영 안 하고 외부 전문 회사에 위탁. 월 100~300만 원에 24시간 운영·모니터링·장애 대응. 자체 인력 없는 중소기업의 가장 현실적 옵션. 단 '데이터 접근권'이 MSP에 가니까 보안 약관 꼼꼼히. 본 강좌 9편(보안)에서 다룸.

NOTE

★ 강사 핵심 배경지식 — '서버 운영'이 정확히 무엇 하는 일: (1) 일상 — 모니터링, 로그 확인, 백업, 보안 패치, 모델 업데이트. (2) 장애 대응 — 서버 다운, 디스크 가득, 네트워크 끊김 24시간 대응. (3) 보안 — 침입 탐지, 외부 공격 차단, 권한 관리. (4) 성능 — 응답 느림 진단, 리소스 부족 시 증설. (5) 사용자 지원 — 직원 '안 돼요' 응답. 1명이 다 못함.

NOTE

강사 배경지식 — Linux/Docker/Network/Security 기초 학습 시간: 0에서 시작하면 — Linux 기초 2~4주, Docker 1~2주, Network 1~2주, Security 2~4주. 합 약 6~12주. 이미 IT 담당자면 1~3주. '우리 IT 담당이 이 학습에 시간 낼 수 있나' 확인 필요. 본 강좌 2강·3강이 이 학습의 기초.

NOTE

강사 배경지식 — MSP 선정 기준: 한국 MSP 사용 시 확인 (1) AI 서버 운영 경험 — GPU·CUDA 다룬 적. (2) 24/7 SLA — 응답 시간 약속. (3) 데이터 접근 약관 — 우리 데이터 MSP가 어디까지 보나. (4) 한국 데이터센터 — 국외 이전 회피. (5) 비용 — 월 100~300만 원이 평균, 1,000만 원+면 과도.

NOTE

강사 배경지식 — Q3 답에 따른 분기: (1) 사내 IT 풀타임 가능 — 자체 호스팅 OK. (2) 외주 MSP 예산 있음 — 자체 호스팅 OK (단 데이터 접근권 확인). (3) IT 1명, 외주 예산 X — 클라우드 권장. (4) IT 없음 — 클라우드 강제. 약 60% 한국 중소기업이 (3) 또는 (4)에 해당.

Q

예상 청중 질문 1: ‘우리 IT 1명인데 자체 호스팅 가능?’ → 답: ‘솔직히 어렵습니다. 24/7 불가. 휴가·병가 시 멈춤. 옵션 — (1) MSP 위탁 (월 100만+). (2) 클라우드 유지. (3) IT 인력 1명 추가 채용. (3)이 가장 비싼 옵션 (연 5,500만 원+).’

Q

예상 청중 질문 2: ‘MSP에 위탁하면 우리 데이터 보안 문제?’ → 답: ‘MSP가 데이터 접근권 가져요. 약관에 ‘우리 데이터 어떻게 보호하는지’ 명시되어야 합니다. (1) 데이터 격리. (2) 접근 권한 제한. (3) 감사 로그. 셋 다 약관에 있어야 신뢰. 본 강좌 9편 보안편이 가이드 제공.’

Q

예상 청중 질문 3: ‘외주 안 쓰고 우리 직접 운영 시 학습은?’ → 답: ‘본 강좌 2강·3강이 시작점. 추가 학습 — Linux Academy, Docker Mastery, 한국 패스트캠퍼스·코드스테이츠 등. 약 3개월 집중하면 운영 가능 수준. 단 ‘운영하면서 학습’이 가장 좋고, ‘학습 다 끝낸 뒤 운영’ X.’

TIP

강사 함정 — ‘우리 직원 다 컴퓨터 잘 함’ 청중 과장 정면 반박: ‘컴퓨터 잘 한다’와 ‘서버 운영 가능’은 완전히 다름. 청중 IT 부서가 ‘우리 서버 운영 가능’이라 자신하면 ‘좋습니다. 단 새벽 3시 서버 다운 대응 가능한지 확인하세요’ 메시지.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘24/7 운영’ 의미. 1~2분 4가지 역량. 2~3분 3옵션. 3~4분 한국 MSP 현황. 4~5분 청중 질문. 옵션별 비용 명시 — 청중이 현실 직시.

BRIDGE

“운영 인력 답이 정리됐다면 — 마지막 네 번째 질문 ‘인터넷 끊기면 어떻게?’입니다. 연속성 요구가 핵심.”

Q4 · CONTINUITY

결정 질문 ④ 연속성·내구성

■ 불변증 — 인터넷 끊기면 업무 멈추나?

- 일반 업무 (연속성 요구 낮음 (클라우드 OK)) — 이메일·문서·보고서·번역. 인터넷 끊겨도 1~2시간은 다른 일 가능. 인터넷은 보통 99.5% 안정 (월 평균 3.6시간 끊김). 클라우드 OK.
- 회사 핵심 운영 (연속성 요구 높음 (자체 호스팅 검토)) — 생산 라인·고객 응대·실시간 거래·의료 응급. 1시간 끊겨도 큰 손해. 인터넷 99.5% 불충분 — 99.99% 필요 (월 평균 4분). 자체 호스팅 또는 이중화.

🕒 5분 · 연속성

SAY

“네 번째 — 마지막 질문. 연속성·내구성. ‘인터넷이 끊기면 업무가 멈추나?’입니다.”

SAY

“대부분 회사는 ‘인터넷 잠깐 끊겨도 다른 일 함’입니다. 이메일·문서·보고서·번역 같은 일반 업무. 1~2시간 끊겨도 차 마시며 기다리면 됨. 한국 인터넷 평균 가용성 99.5% — 월 평균 약 3.6시간 끊김. 이 정도면 클라우드 OK.”

SAY

“그런데 일부 회사·일부 업무는 다릅니다. 생산 라인 — 멈추면 분당 수천만 원 손해. 고객 응대 — 1시간 멈춤이 평판 사고. 실시간 거래 — 1초 지연이 손실. 의료 응급 — 멈춤이 인명. 이런 회사는 99.5%로 불충분 — 99.99% 필요. 월 평균 4분 끊김 허용.”

SAY

“99.99% 가능한 방법 두 가지. (1) 자체 호스팅 + 사내망 — 인터넷 끊겨도 사내망은 작동. (2) 클라우드 + 다중 리전 + 로컬 캐시 — 비용 큼. 일반적으로 자체 호스팅이 더 경제적.”

STORY

한국 인터넷 가용성 (강사 대응용). KT·SKT·LGU+ 평균 99.5% (2024 KISA 통신 안정성 보고서). 즉 월 약 3~4시간 끊김. 거대 회사일수록 ‘이중 회선’으로 99.9%~99.99% 달성. 단 회선 두 개 = 비용 두 배. 자체 호스팅도 동일 문제 — 사내 서버 정전·고장 시 끊김 발생.

STORY

Anthropic·OpenAI 자체 가용성 (강사 대응용). Anthropic Claude API 가용성 — 약 99.9% 보장 (SLA 약관 기준). OpenAI ChatGPT API — 약 99.5%. 즉 클라우드 자체도 100% 보장은 X. 출처: Anthropic API SLA, OpenAI API SLA 공식 약관.

NOTE

★ 강사 핵심 배경지식 — ‘가용성 99.X%’ 정확한 의미: 시스템이 작동하는 시간 비율. (1) 99% = 월 7.3시간 끊김. (2) 99.5% = 월 3.6시간. (3) 99.9% = 월 43분. (4) 99.99% = 월 4분. (5) 99.999% (‘파이버 나인’) = 월 26초. 가용성 보장이 한 단계 올라갈 때마다 비용 약 2~5배 증가. ‘100% 가용성’은 이론적 불가능.

NOTE

강사 배경지식 — 한국 회사 ‘업무 중단’ 비용: 일반 사무직 — 시간당 약 50만 원 손실 (직원 인건비 + 기회 비용). 제조 생산 라인 — 시간당 수천만~수억 원. 고객 응대 — 분당 수십만 원 + 평판 손해. 즉 ‘일반 사무직 1시간 끊김 OK’지만 ‘생산·고객응대 1시간 끊김 X’.

NOTE

강사 배경지식 — 자체 호스팅도 100% 가용 X: 자체 호스팅이 ‘인터넷 의존 안 함’이지 ‘100% 가용’은 아님. 사 내 서버 정전·하드 고장·네트워크 장애도 발생. 자체 호스팅 평균 가용성 99.0~99.5% (잘 운영 시). 즉 ‘인터넷 보다 살짝 좋음’ 수준. ‘99.99% 절대 필요’면 자체 + 클라우드 백업 이중화 필요.

NOTE

강사 배경지식 — Q4 답에 따른 분기: (1) 일반 사무 업무 — 클라우드 OK (99.5% 충분). (2) 부분적 실시간 업무 — 클라우드 + 로컬 캐시. (3) 핵심 생산/고객 운영 — 자체 호스팅 권장 + 이중화. (4) 의료·금융 등 미션 크리티컬 — 자체 호스팅 + 이중화 + DR 계획. 본 강좌 10편(백업·재해복구)에서 다룸.

Q

예상 청중 질문 1: ‘우리는 인터넷 잘 안 끊기는 회사인데?’ → 답: ‘평균 99.5%면 잘 안 끊기는 거 맞아요. 핵심은 ‘끊겼을 때 손해가 얼마인가’입니다. 사무직이면 OK, 생산이면 X. 부서별로 다를 수 있어요.’

Q

예상 청중 질문 2: ‘자체 호스팅도 정전·고장 나는데 어떻게 99.99%?’ → 답: ‘옳은 지적. 자체 호스팅 + 이중화 (서버 2대, 정전 방지 UPS, 백업 전기) 다 갖춰야 99.99% 가능. 보통 자체 호스팅만 99.0% 수준. 100% 절대 불가능 — 항상 위험 인정.’

Q

예상 청중 질문 3: ‘우리는 99.9%면 충분한 것 같은데 클라우드?’ → 답: ‘Anthropic·OpenAI 클라우드 SLA가 99.5~99.9%입니다. 충분합니다. ‘99.9%로 충분’이면 클라우드 OK. ‘99.99% 필요’면 자체 호스팅 + 이중화 검토.’

TIP

강사 함정 — ‘우리는 100% 필요해’ 청중 과장 반박: ‘100% 가용성’ 절대 불가능 메시지. 99.999%도 비용 천문학적. 청중에게 ‘우리 회사 1시간 끊김이 정말 100% 못 견디나? 5분은? 1분은?’ 단계별 질문.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘인터넷 끊기면?’. 1~2분 99.5 vs 99.99 차이. 2~3분 가용성 비용. 3~4분 자체 호스팅도 100% X. 4~5분 청중 질문. 가용성 숫자가 추상적 — 시간으로 변환해서 직관.

BRIDGE

“4질문 다 봤습니다. 이제 매트릭스로 — 우리 회사 답 조합이 어느 선택지를 가리키는지 정리합니다.”

DECISION MATRIX

4질문 매트릭스 — 어느 답이 어디로?

■ 불변층 — 4질문 → 인프라 선택

- 0~1개 'Yes' 클라우드 100% — Q1~Q4 중 0~1개만 ‘민감/대량/인력/연속성 필요’. 95% 한국 중소기업. 클라우드 시작. 자체 호스팅 검토 1~2년 후.
- 2개 'Yes' 클라우드 → 하이브리드 진화 — L1·L2는 클라우드. L3 진입 시 ‘민감 부분만 자체 호스팅’ 하이브리드로 진화. 검증된 패턴.
- 3개 'Yes' 자체 호스팅 본격 검토 — 민감 + 대량 + 인력 또는 민감 + 인력 + 연속성. 자체 호스팅 도입 강력 검토. 본 강좌 2강·3강 자세히.
- 4개 'Yes' 자체 호스팅 확정 — 민감 + 대량 + 인력 + 연속성 모두. 자체 호스팅 외 옵션 없음. 본 강좌 2~10편 전체 활용.

🕒 5분 · 결정 매트릭스

SAY

“4질문을 다 던졌다면 — 답 조합으로 인프라 방향이 나옵니다. 이 매트릭스가 결정의 핵심 도구예요.”

SAY

“0~1개 ‘예’ — 95% 한국 중소기업. 민감 데이터 적고, 사용량 적고, IT 인력 부족, 연속성 요구 낮음. 클라우드 100%. 자체 호스팅 검토는 1~2년 후 L3·L4 진입 시점.”

SAY

“2개 ‘예’ — 일부 민감 + 사용량 증가, 또는 인력 있음 + 연속성 일부. L1·L2 클라우드로 시작 → L3 진입 시 ‘민감 부분만 자체 호스팅’으로 진화. 가장 흔한 ‘하이브리드 패턴’.”

SAY

“3개 ‘예’ — 민감 + 대량 + 인력 또는 민감 + 인력 + 연속성. 자체 호스팅 본격 검토. 본 강좌 2강·3강의 하드웨어·OS·네트워크 결정이 직접 적용.”

SAY

“4개 ‘예’ — 다 ‘예’. 민감 + 대량 + 인력 + 연속성. 자체 호스팅 외 옵션 없음. 본 강좌 2~10편 전체 적용. 다음 슬라이드 두 회사 사례가 이 패턴.”

STORY

한국 중소기업 실제 분포 (강사 대응용 추정). 0~1개 ‘예’ — 약 70%. 2개 — 약 20%. 3개 — 약 7%. 4개 — 약 3%. 즉 한국 회사 대다수가 ‘클라우드 100%’ 정답. 자체 호스팅이 정답인 회사는 소수 — 보안 회사·금융·의료 일부.

STORY

1편 5개 사례 회사들의 4질문 답 (강사 대응용). Novo Nordisk — 4개 ‘예’ (제약 민감, 대량 사용, 글로벌 IT, 24/7) → 자체 호스팅 + 일부 클라우드 하이브리드. L'Oréal — 2~3개 ‘예’ → 하이브리드. Doctolib — 2개 ‘예’ → 하이브리드. Palo Alto Networks — 3~4개 ‘예’ (보안 회사) → 자체 호스팅. Thomson Reuters — 3개 ‘예’ → 하이브리드. IG Group — 3개 ‘예’ → 하이브리드.

NOTE

★ 강사 핵심 배경지식 — 매트릭스의 함의: 한국 회사 대다수(약 90%)가 ‘클라우드 또는 하이브리드’ 정답. ‘100% 자체 호스팅’이 정답인 회사는 약 10%. 즉 ‘자체 호스팅 = 진보, 클라우드 = 후진’ 같은 오해 깨주기. 클라우드가 ‘대부분 회사의 정답’이라는 메시지 강조.

NOTE

강사 배경지식 — 매트릭스 한계: 4질문 매트릭스가 100% 정확하지는 않음. 실제 결정에는 추가 고려 — (1) 산업 규제 (의료·금융·방산 특수). (2) 회사 전략 (디지털 트랜스포메이션 적극). (3) 예산. (4) 경영진 선호. 매트릭스는 ‘시작점’이지 ‘완결’ 아님.

NOTE

강사 배경지식 — ‘하이브리드 진화’ 패턴 디테일: 가장 흔한 경로 — (1) L1 클라우드 무료. (2) L2 클라우드 유료. (3) L3 ‘대부분 클라우드 + 사내 RAG 인프라’. (4) L4 ‘민감 에이전트만 자체’. (5) L5 ‘민감 부서 전체 자체, 일반은 클라우드’. 자연스러운 진화. ‘처음부터 하이브리드 설계’ X.

Q

예상 청중 질문 1: ‘우리는 1~2개 ‘예’인데 자체 호스팅 검토 안 해도 되나?’ → 답: ‘지금은 안 됨. 1~2개 ‘예’면 클라우드 비용·운영 부담 압도적 적음. 6개월 후 ‘예’ 늘어나면 그때 재검토.’

Q

예상 청중 질문 2: ‘3개 ‘예’인데 자체 호스팅 확정해야?’ → 답: ‘본격 검토하지만 확정 X. 본 강좌 2강의 하드웨어 결정 후 ‘비용·인력 가능한가’ 다시 봐야. 결정은 ‘기술 + 비용 + 인력’ 셋 다 갖춰질 때.’

Q

예상 청중 질문 3: ‘우리는 ‘예/아니오’ 모호한 질문 있다.’ → 답: ‘정상이에요. ‘부분적 예’로 표시. Q1 ‘데이터 일부만 민감’ — 0.5개 ‘예’. 종합 점수 1.5~2 정도면 ‘클라우드 → 하이브리드 진화’ 권장.’

TIP

강사 함정 — 매트릭스를 ‘절대 진리’로 제시 금지: ‘이 매트릭스는 시작점입니다. 우리 회사 특수 상황 고려해서 조정하세요.’ 메시지. 청중이 ‘매트릭스만 보고 결정’하면 위험.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 매트릭스 전체. 1~3분 각 구간 디테일. 3~4분 한국 회사 분포 + 1편 5사례 매핑. 4~5분 매트릭스 한계 + 청중 질문. 분포 알려주면 청중이 ‘우리만 0~1개라 부끄러운 거 아님’ 안심.

BRIDGE

“매트릭스를 봤다면 — 실제 회사가 어떻게 적용했는지 두 사례를 보겠습니다. 클라우드와 자체 호스팅 양극단 사례입니다.”

CASE · SELF-HOSTED

사례 ① 자체 호스팅 — 삼성전자 Gauss

■ 검증 사례 · 한국 대기업, 자체 호스팅 결정

- ChatGPT 사용 → 사고 (Before · 2023.04) — 삼성 DS 부문 엔지니어가 사내 반도체 설계 코드를 ChatGPT에 입력. 데이터 유출 확인 → 회사 전사 생성 AI 금지. 9개월 단절.
- 자체 LLM ‘Gauss’ 개발 (After · 2023.11+) — Samsung Research가 자체 한국어 LLM ‘Gauss’ 공개. 사내 자체 서버에서 운영. 4질문 답 — 4개 ‘예’ (반도체 보안+대량+IT+연속성).

⌚ 4분 · 자체 호스팅 사례

SAY

“첫 번째 사례 — 한국 대기업 삼성전자. 2023년 사고 → 자체 호스팅 결정 과정.”

SAY

“2023년 4월. 삼성 반도체 DS 부문 엔지니어가 사내 코드를 ChatGPT에 입력해서 디버깅 시도. 회사가 모니터링하다가 사고 확인. 즉시 전사 생성 AI 사용 금지. 약 9개월 동안 삼성 직원들은 ChatGPT·Claude 못 씀.”

SAY

“그동안 삼성은 자체 LLM ‘Gauss’를 개발했어요. 한국어 특화. 사내 자체 서버에서 운영. 2023년 11월 공개. 이후 사내 직원이 ChatGPT 대신 Gauss 사용 허용.”

SAY

“삼성의 4질문 답을 보세요. Q1 데이터 민감도 — 반도체 설계 기술은 회사 최고 영업비밀. ‘예’. Q2 토큰 사용량 — 직원 26만 명, 매일 사용하면 막대한 양. ‘예’. Q3 운영 인력 — 삼성 IT 인력 수만 명. ‘예’. Q4 연속성 — 24시간 글로벌 운영. ‘예’. 4개 다 ‘예’. 자체 호스팅 외 옵션 없음.”

STORY

삼성 ChatGPT 사고 출처. Bloomberg ‘Samsung Bans Staff’s AI Use After Spotting ChatGPT Data Leak’, 2023-05-02. Korea Herald ‘Samsung Workers Have Made a Few Costly Mistakes by Typing Confidential Data into ChatGPT’, 2023-05. 1차 출처 다수.

STORY

Samsung Gauss 출처. Samsung Research 공식 발표, 2023-11-08. URL: research.samsung.com. 한국어·영어 멀티링구얼 LLM. 코드 생성 모델 'Code Gauss' + 이미지 생성 'Vision Gauss' + 언어 모델 'Language Gauss' 3종. 2024년부터 사내 사용 본격.

NOTE

★ 강사 핵심 배경지식 — 삼성 사례의 교훈 4가지: (1) '대기업이 자체 호스팅'이 일반 회사에는 적용 불가. 자원 차원 다름. (2) '일단 외부 사용 → 사고 → 자체 전환' 패턴은 비효율적. '처음부터 정책 + 도입' 정석. (3) 9개월 단절 — 큰 손해. 직원이 'ChatGPT 못 쓰는 시간'의 비용. (4) Gauss 같은 '회사 전용 LLM' 만드는 회사는 한국에 5~10개 정도 — 매우 소수.

NOTE

강사 배경지식 — '우리도 자체 LLM 만들자' 위험: 삼성 사례를 보고 '우리도 자체 LLM 만들어야겠다'는 환상 흔함. 자체 LLM 개발 — 최소 100명 AI 연구자 + 수년 + 수백억 원. 대기업도 어려움. 99% 회사는 '오픈소스 모델 (Llama·Qwen) 사용'이 현실적. 본 강좌 3편이 오픈소스 모델 선택 가이드.

NOTE

강사 배경지식 — 삼성과 우리 회사 다른 점: 삼성 4질문 답 '4개 예' — 우리 회사 '0~2개 예'일 가능성 높음. '삼성이 자체 호스팅했으니 우리도' 잘못된 추론. 우리 회사 4질문 답을 보고 결정. 99% 한국 중소기업은 '클라우드 또는 하이브리드' 정답.

Q

예상 청중 질문 1: '우리도 자체 LLM 만들면 되지 않나?' → 답: '만들 수 있어요. 단 비용 — 최소 100억 원, 100명 연구자, 2~3년. 99% 회사는 비현실적. 대신 '오픈소스 모델 + 자체 호스팅' 옵션이 현실적. 본 강좌 3편이 자세히.'

Q

예상 청중 질문 2: '삼성 사고 같은 일 우리에게도?' → 답: '충분히 가능합니다. '처음부터 정책' 강조 이유. 직원에게 '이 데이터는 외부 AI 입력 금지' 명확히 + 사내 도구 제공. 본 강좌 9편 보안편에서 다룸.'

Q

예상 청중 질문 3: '삼성 Gauss 외부에서 사용 가능?' → 답: '아닙니다. Gauss는 사내 전용. 외부 공개 X. 우리가 비슷한 자체 모델 원하면 (1) Llama·Qwen 같은 오픈소스 미세조정, (2) 솔루션 (Upstage Solar 등) 라이선싱. 본 강좌 3편에서 자세히.'

TIP

강사 함정 — ‘삼성 따라하기’ 압박 금지: 청중에게 ‘대기업이 했으니 우리도’ 환상 깨주기. 우리 회사 4질문 답이 다르면 다른 답.

TIP

강사 진행 팁 — 4분 시간 배분: 0~1분 사고 + 9개월 단절. 1~2분 Gauss 개발. 2~3분 4질문 답. 3~4분 청중 질문 + ‘우리에게 의미’. 4질문 답 보여주는 게 핵심 — 매트릭스 적용 예시.

BRIDGE

“대기업 자체 호스팅 사례를 봤다면 — 정반대 사례. 글로벌 회사가 클라우드를 어떻게 활용하는지. Doctolib과 Palo Alto Networks 두 회사 사례입니다.”

CASE · CLOUD/HYBRID

사례 ② 클라우드/하이브리드 — Doctolib · Palo Alto

■ 검증 사례 · Anthropic 공식 발표

- 클라우드 + 일부 자체 (Doctolib · 의료 (EU)) — EU 의료 데이터 규제(GDPR + MDR) 가장 엄격. 그럼에도 Claude API(클라우드) 전사 배포. 환자 데이터는 익명화 후 처리. 결과 — 기능 출시 40% ↑.
- 클라우드 + 검증 후 도입 (Palo Alto Networks · 보안) — 사이버보안 회사. 자체 보안팀이 Claude 안전성 직접 검증 후 도입. ‘우리도 검증해 본 회사’가 ‘예’ 했다는 의미 큼. 결과 — 개발 속도 20-30% ↑.

🕒 5분 · 클라우드 사례

SAY

“두 번째 사례 — 클라우드/하이브리드 패턴. 두 회사 동시에 보겠습니다.”

SAY

“첫 번째 — Doctolib. 1편에서 봤어요. 프랑스 의료 예약 플랫폼 1위. EU 의료 데이터 규제 — GDPR(개인정보 보호규정) + MDR(의료기기 규제) — 가장 엄격한 환경. 그럼에도 Claude API 전사 배포 결정.”

SAY

“Doctolib의 4질문 답 — Q1 데이터 민감도 환자 정보 ‘예’이지만 ‘익명화 후 AI 처리’ 패턴. Q2 사용량 ‘예’. Q3 인력 ‘예’(엔지니어팀 큼). Q4 연속성 ‘예’(의료 서비스). 그래도 클라우드 + 일부 자체 ‘하이브리드’ 선택. 이유 — Anthropic 엔터프라이즈 약관 + 익명화 + GDPR 컴플라이언스 통합 설계.”

SAY

“두 번째 — Palo Alto Networks. 사이버보안 글로벌 1위. ‘우리도 안전 검증 안 하면 고객에게 추천 못 한다’는 회사. 자체 보안팀이 Claude의 데이터 처리 방식·약관·격리 메커니즘 모두 검증. ‘안전하다’ 결론 후 도입.”

SAY

“핵심 메시지 — 가장 보수적인 의료·보안 회사도 클라우드를 ‘조건 검증 후’ 사용. ‘무조건 클라우드 위험’ 오해 깨주는 사례. 단, 두 회사 모두 ‘보안 검증·익명화·엔터프라이즈 약관’ 3단 안전장치를 구축한 후 도입.”

STORY

Doctolib 클라우드 도입 디테일 (강사 대응용). Anthropic ‘How enterprises driving AI transformation with Claude’ 인용. URL: claude.com/blog/driving-ai-transformation-with-claude. Doctolib은 EU의 ‘Sovereign Cloud(주권 클라우드)’ 옵션 활용 — 데이터가 EU 안에서만 처리. 한국 회사가 ‘서울 리전’ 옵션 활용하는 것과 유사 패턴.

STORY

Palo Alto Networks 검증 과정 (강사 대응용). Anthropic 2026 Enterprise Report 인용. URL: claude.com/blog/how-enterprises-are-building-ai-agents-in-2026. 자체 보안팀이 약 3개월 검증. (1) Anthropic 엔터프라이즈 약관 분석. (2) Claude 데이터 처리 메커니즘 점검. (3) 격리·로그·감사 옵션 확인. (4) 자체 침투 테스트. 통과 후 도입. ‘보안 회사가 검증한 신뢰성’ 큰 의미.

NOTE

★ 강사 핵심 배경지식 — 두 회사 사례 합의 4가지: (1) 가장 보수적인 산업(의료·보안)도 클라우드 사용 가능 — 안전장치 갖추면. (2) ‘무조건 클라우드 = 위험’ 오해 정면 반박 사례. (3) 안전장치 3단 — 약관 + 익명화 + 컴플라이언스. (4) 검증 후 도입 — ‘일단 쓰고 나중에 검증’ X.

NOTE

강사 배경지식 — Sovereign Cloud (주권 클라우드): EU에서 발전한 개념. ‘데이터가 특정 국가/지역 안에서만 처리’되도록 보장하는 클라우드 옵션. 한국에도 비슷한 옵션 — AWS 서울 리전, Anthropic 한국 데이터센터 (예정). 데이터 국외 이전 우려 해소. 본 강좌 9편 보안편 자세히.

NOTE

강사 배경지식 — Doctolib + Palo Alto에서 우리 회사 교훈: 두 회사 패턴 따라가는 한국 회사 권장 시작 패턴 — (1) Anthropic 엔터프라이즈 약관 검토. (2) ‘이 데이터는 외부 송신 금지’ 명확 정책. (3) 한국 리전·데이터 격리 옵션 활용. (4) 사내 검증 3개월. (5) 단계적 도입. 본 강좌 9편 보안편이 가이드.

NOTE

강사 배경지식 — Doctolib 약 1,400만 명 환자 데이터 처리 — 어떻게 GDPR 통과: 핵심 4가지 — (1) 환자 식별 정보(이름·주민번호)는 AI에 안 보냄, 다른 시스템에서 처리. (2) AI에 보내는 데이터는 ‘증상·진단 코드’ 같은 익명화된 형태. (3) EU 안에서 처리. (4) 데이터 보호 책임자(DPO) 감사. 즉 ‘설계 시점 보안 통합’이 핵심.

Q

예상 청중 질문 1: ‘Doctolib도 의료 데이터인데 클라우드 OK면 우리도 OK?’ → 답: ‘Doctolib도 ‘환자 식별 정보’는 AI에 안 보냅니다. 익명화된 데이터만. 우리 회사도 ‘민감 데이터 그대로 외부 송신’이 아니라 ‘익명화/일부만 송신’이면 클라우드 OK 가능.’

Q

예상 청중 질문 2: ‘Palo Alto는 보안 회사라 검증 했지만 우리는 자체 검증 어렵다.’ → 답: ‘본 강좌 9편(보안)이 그 검증 체크리스트 제공합니다. ‘약관 검토 + 데이터 흐름 분석 + 위험 평가’ 3단계. 외주 보안 컨설팅 (월 200~500만 원) 옵션도.’

Q

예상 청중 질문 3: ‘우리 회사도 Sovereign Cloud 옵션 있나?’ → 답: ‘한국에 — AWS 서울 리전 + Microsoft Azure 한국 리전. Anthropic은 미국 리전이 주력, 한국 옵션 발전 중. 데이터 국외이전 우려 큰 회사는 한국 리전 옵션 우선 검토.’

TIP

강사 함정 — ‘Doctolib·Palo Alto만 가능’ 분위기 금지: ‘우리 회사도 같은 패턴 가능’ 메시지. 단계별 검증 가이드 제공. 단 ‘무조건 클라우드’도 X — 4질문 답에 맞춰.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 Doctolib 의료 환경. 1~2분 4질문 답 + 익명화 패턴. 2~3분 Palo Alto 검증 과정. 3~4분 두 회사 공통 — 3단 안전장치. 4~5분 청중 질문. 안전장치 3단이 핵심 메시지.

“1강 마지막 — 우리 회사 인프라 결정서 한 장 워크시트 채우기. 4질문 답으로 인프라 방향 정합니다.”

WORKSHOP 1

실습 — 우리 회사 인프라 결정서 1페이지

■ 적용 + 1강 정리 (워크시트)

- Q1 · 우리 회사 데이터 민감도? (비민감 / 일부 민감 / 대부분 민감)
- Q2 · 예상 월 토큰 사용량? (직원수 × 130만 × 사용률)
- Q3 · 서버 운영 인력? (사내 / 외주 / 없음)
- Q4 · 연속성 요구? (일반사무 / 핵심운영 / 미션크리티컬)
- ★ 4질문 답 종합 → 우리 회사 인프라 방향 = ____
- ★ 다음 액션 — 우리 회사 4질문 답을 회사에 가져가서 사장님·임원과 검증

🕒 9분 · 실습·마무리

SAY

“1강 마지막 — 실습입니다. 60분 동안 들은 내용을 한 장에 응축합니다. 인프라 결정서 1페이지.”

DO

조별 실습 (5분, 3~4인 1조). 4질문 + 종합 + 다음 액션 6칸 채우기. Q1~Q4 각각 짧게 답. 종합은 ‘0~1개 예 → 클라우드 100% / 2개 → 하이브리드 진화 / 3~4개 → 자체 호스팅 검토’ 매트릭스 적용. 다음 액션은 ‘이번 주에 누가, 무엇’ 1줄.

SAY

“이 한 장이 사장님·임원께 보고하는 ‘인프라 결정서 초안’입니다. 1편 90일 계획서와 합쳐서 ‘AI 도입 완전판’이 완성됩니다.”

SAY

“완벽한 답이 목표가 아니에요. ‘우리 회사가 어느 방향인지’ 짚는 게 목표. 답이 안 나오는 질문이 가장 중요한 ‘다음 과제’입니다.”

Q

발표 요청: “1~2조 발표하시겠어요? Q1~Q4 종합 결과만 한 줄로.” → ‘저희는 0개 예, 클라우드 100%’ 식. → 다양한 답이 나오는 게 정상이라고 강조.

Q

발표 요청 2: “종합이 ‘자체 호스팅 검토’ 나온 조 있어요?” → 보통 1~2조. → ‘좋습니다. 그 조는 2강·3강이 특히 중요합니다. 다른 조는 2강·3강이 ‘우리 미래 결정 자료.’

NOTE

★ 강사 핵심 배경지식 — 결정서 6칸 작성 가이드. (1) Q1 — ‘우리 데이터 100건 중 민감 N건’ 식 추정. (2) Q2 — 직원수 × 130만 × 챔피언 5명 사용률. (3) Q3 — 현재 IT 인력 명수 + 외주 MSP 예산 가능 여부. (4) Q4 — 부서별 다를 수 있음, 대표값. (5) 종합 — 매트릭스 적용. (6) 다음 액션 — ‘이번 주 사장님 회의 안건에 추가’ 같은 구체.

NOTE

강사 배경지식 — 다음 주 액션 권장 3가지: (1) 인프라 결정서 1페이지 사진 찍어 부서장·사장님께 메시지 (5분). (2) 사장님·임원께 ‘인프라 결정 회의’ 30분 잡기 (1주 안). (3) 회의에서 4질문 답 검증 + 인프라 방향 합의 (30분). 셋 다 1주일 안에 가능.

NOTE

강사 배경지식 — 결정 후 ‘재검토 주기’: 인프라 결정은 한 번이 아니라 6~12개월마다 재검토. 이유 — (1) 회사 성장으로 4질문 답 변화. (2) 가격·기술 변화. (3) 도입 단계 변화 (L1→L2→L3). 6개월마다 ‘우리 회사 4질문 답이 바뀌었나?’ 점검.

Q

예상 청중 질문 1: ‘Q1 답이 부서마다 다른데 어떻게?’ → 답: ‘대표 답을 적되 ‘부서별 차이’ 메모. 영업팀 비민감, 법무팀 민감 식. 종합 결정 시 가장 민감한 부서 기준으로 ‘하이브리드’ 답.’

Q

예상 청중 질문 2: ‘Q3 인력 답이 ‘없음’인데 자체 호스팅 갖고 싶다.’ → 답: ‘옵션 — (1) 인력 채용 (연 5,500만원+). (2) MSP 위탁 (월 100~300만 원). (3) 클라우드 유지. 보통 (2) 또는 (3)이 현실적.’

Q

예상 청중 질문 3: ‘4질문 다 ‘아니오’인데 그래도 인프라 결정 회의 해야 하나?’ → 답: ‘회의는 ‘우리 인프라 방향 = 클라우드 100%, 1년 후 재검토’로 정리하면 끝. 30분 안에 끝나요. ‘결정 안 함’이 가장 위험.’

TIP

강사 함정 — ‘작성 완벽 추구’ 금지: 5분 안에 6칸 채우는 게 목표. 완벽한 답 X. ‘60% 답으로 시작 → 회사 가서 보완’ 메시지.

TIP

강사 진행 팁 — 9분 시간 배분: 0~5분 개별 작성. 5~7분 1~2조 발표. 7~9분 ‘다음 주 액션 3가지’ + 마무리. 5분 작성 시간 충분히. 강사는 작성 중 조별로 돌며 ‘어디 막혔는지’ 확인.

BRIDGE

“1강 끝. 잠깐 쉬고 2강 ‘하드웨어·OS·컨테이너’에서 만나요. ‘인프라 결정서’에 ‘자체 호스팅 검토’ 나온 분께 특히 중요. 클라우드 결정 분도 2강이 미래 자료입니다.”

INTRO · TITLE

하드웨어·OS·드라이버·컨테이너

2강 — 자체 호스팅한다면 어떤 장비가 필요한가

🕒 3분 · 시작

SAY

“2강입니다. 1강에서 ‘우리 회사가 자체 호스팅을 검토할지’ 결정했죠. 이제 ‘만약 자체 호스팅한다면 무엇을 사야 하는가’입니다.”

SAY

“2강 60분 동안 다섯 가지를 봅니다 — (1) VRAM 계산법, (2) 모델 선택, (3) GPU 선택, (4) PC 형태 선택, (5) OS·Docker 표준. 다섯이 결합되면 ‘우리 회사 장비 구매서 한 장’이 나옵니다.”

SAY

“2강 약속 — 모든 가격·모델명은 ‘2026년 6월 기준 예시’입니다. 1년 후엔 가격이 30% 떨어지고 새 GPU가 나옵니다. 그래도 ‘파라미터 × 0.6GB = VRAM’ 같은 공식은 5년 후에도 그대로예요. 공식은 외우고, 가격은 비교용으로만 보세요.”

Q

도입 질문: “GPU 직접 설치해 본 분 손 들어주세요.” → 보통 1~2명. → ‘좋습니다. 1~2명만 직접 해보셨다면 정상이에요. 오늘 2강 60분이 끝나면 모두가 ‘구매 검토 회의에 들어가서 똑같은 언어로 토론’할 수 있게 됩니다. ‘직접 설치’가 아니라 ‘제대로 발주’가 목표.’

Q

도입 질문 2: “‘GPU·VRAM·CUDA’ 셋 다 정확히 설명하실 수 있는 분?” → 보통 거의 없음. → ‘오늘 2강이 그 셋을 정확히 풀이합니다. 안 두려워하세요.’

NOTE

★ 강사 핵심 배경지식 — 2강이 가장 어려움: 4질문(1강)·네트워크(3강)는 ‘의사결정’ 중심이라 톤 비슷. 2강만 ‘구체적 기술’이라 톤 다름. 초보 청중에게 압도되지 않도록 — (1) 전문용어 풀이 매번 반복. (2) 비유 적극 사용 (‘VRAM = AI의 작업 책상’ 식). (3) 가격은 ‘구체 숫자’ 들어 직관. (4) 외울 것 5개 이하.

NOTE

강사 배경지식 — 2강의 5가지 결정점: (1) VRAM 얼마? — 사용할 모델 크기에 좌우. (2) 어떤 모델? — Llama·Qwen·DeepSeek 중. (3) 어떤 GPU? — RTX 4090·H100·A6000. (4) 어떤 PC? — 미니PC·워크스테이션·서버. (5) 어떤 OS·Docker? — Ubuntu + NVIDIA + Docker 표준. 5개가 연쇄적 결정.

NOTE

강사 배경지식 — 2강 60분 시간 배분: 0~3분 인트로. 3~6분 목표. 6~16분 VRAM·모델·GPU (각 3분). 16~28분 PC 형태 결정. 28~38분 OS·드라이버. 38~50분 Docker. 50~58분 실습. 58~60분 마무리. 가장 압축적인 강.

TIP

강사 함정 — 기술 자랑 절대 금지: 청중에게 ‘저는 직접 4090 5장 설치했어요’ 같은 자랑 X. ‘이걸 알면 발주서 통과시킬 수 있어요’ 실용 가치 중심.

OBJECTIVES

60분 후, 이 3가지를 한다

- ① VRAM 계산법으로 ‘우리는 어느 모델 가능한가’ 답한다
- ② GPU·PC 형태·OS·Docker — 4단계 발주서 칸을 채운다
- ③ ‘우리 회사 장비 구매서 1페이지’ 완성

🕒 3분 · 학습목표

SAY

“60분 후 셋. 첫째, ‘파라미터 $\times$ 0.6GB = VRAM’ 공식으로 ‘우리는 7B 모델 가능, 70B는 불가’ 같은 답을 직접 내릴 수 있게 됩니다. 견적서 받기 전에 자기 판단이 서요.”

SAY

“둘째, 발주서 4칸 — GPU·PC·OS·Docker — 채웁니다. 이 4칸이 채워지면 견적 의뢰서 즉시 가능.”

SAY

“셋째, ‘우리 회사 장비 구매서 1페이지’ 완성. 1강 ‘인프라 결정서’와 합쳐 ‘자체 호스팅 도입 완전판’이 됩니다.”

NOTE

★ 강사 핵심 배경지식 — 2강의 성공 기준: 청중이 ‘견적서 보고 어디가 맞는지 파악’ 가능. ‘완벽한 구매 결정’이 아니라 ‘똑똑한 토론 가능’. 발주서 한 장 손에 남기면 성공.

NOTE

강사 배경지식 — 2강과 3강 연결: 2강 ‘장비’, 3강 ‘네트워크·보안’. 둘 합쳐야 자체 호스팅 완성. 2강 끝에 ‘장비는 갖췄지만 보안이 빠지면 사고난다’ 메시지 — 3강 동기.

TIP

강사 진행 팁 — 학습 목표 3분 안에 끝. ‘본문이 더 중요’ 메시지.

BRIDGE

“본문 시작. 가장 중요한 공식 ‘VRAM 계산’입니다.”

VRAM FORMULA

VRAM 계산법 — ‘파라미터 × 0.6GB’

■ 불변증 — 5년 후에도 같은 공식

- 3B 약 2GB VRAM 필요 — Llama 3.2 3B / Phi 3 Mini. 노트북에서도 작동. 간단한 분류·요약·번역. 한국어 자연스러움 약함.
- 7B 약 5GB VRAM — Llama 3.1 8B / Qwen 2.5 7B / Mistral 7B. RTX 3060(12GB)부터 가능. 일반 사내 챗봇. 한국어 ‘쓸 만함’.
- 13B 약 8GB VRAM — Llama 3.1 13B / Qwen 2.5 14B. RTX 4070(12GB)~4080(16GB) 권장. 한국어 ‘ 좋음’. 사내 RAG 추천.
- 70B 약 42GB VRAM — Llama 3.3 70B / Qwen 2.5 72B. RTX 4090 2장(48GB) 또는 H100(80GB). 한국어 ‘ 훌륭’. 본격 사내 AI.

🕒 6분 · VRAM 계산

SAY

“2강 본문의 첫 번째 공식 — 이 공식 하나만 외우면 발주의 50%가 끝납니다. ‘파라미터 × 0.6GB = 필요 VRAM’.”

SAY

“풀이부터. ‘파라미터’ = AI 모델의 크기 단위. ‘B’ = ‘Billion(10억)’. ‘7B 모델’ = 파라미터 70억 개 모델. ‘파라미터’가 많을수록 똑똑하지만 무거움. 사람으로 치면 ‘아는 단어 수’.”

SAY

“그런데 70억 개를 그대로 메모리에 올리면 ‘파라미터 1개 = 2바이트’이라 140GB 필요. 우리 GPU 못 감당. ‘Quantization(양자화)’ = AI 모델을 줄여 메모리 절약하는 기술. Q4 양자화(4비트) 적용 시 ‘파라미터 × 0.6GB’가 실제 VRAM 사용량. $7B \times 0.6 = 4.2GB$. 5GB 정도 잡으면 안전.”

SAY

“구간별 — 3B: VRAM 2GB. 노트북도 가능. 7B: 5GB. RTX 3060(12GB)부터 OK. 13B: 8GB. RTX 4070~4080. 70B: 42GB. 4090 2장 또는 H100. 70B가 ‘한국어 쓸 만한’ 최소 한계선.”

SAY

“핵심 메시지 — ‘큰 모델이 항상 좋은 게 아닙니다.’ 사내 챗봇이면 7~13B로 충분. 70B는 ‘본격 RAG·법무 분석’ 정도 필요. ‘예산 vs 품질’ 트레이드오프.”

STORY

Llama 3.3 70B 출처. Meta AI 공식 발표 2024-12. URL: ai.meta.com/blog/llama-3-3-70b. ‘기존 405B와 비슷한 성능을 70B에 압축’ 주장. 한국어 능력 ‘ 좋음’. Hugging Face에서 무료 다운로드 — 상업 이용 가능 (월 7억 사용자 이하).

STORY

Qwen 2.5 72B 출처. Alibaba Cloud 공식 2024-09. URL: qwenlm.github.io. 한국어·코딩·수학 강함. 한국 회사가 자체 호스팅 시 가장 인기. 무료, 상업 이용 OK. 본 강좌 3편이 자세히.

NOTE

★ 강사 핵심 배경지식 — Quantization(양자화) 정확히: 모델 가중치를 작은 비트수로 표현. (1) FP16 (16비트) — 원본 정확도, 70B = 140GB. (2) INT8 (8비트) — 95% 정확도, 70B = 70GB. (3) Q4 (4비트) — 90% 정확도, 70B = 42GB. (4) Q3 (3비트) — 85% 정확도, 70B = 32GB. ‘Q4’가 ‘품질·메모리 균형 최적’으로 가장 인기. ‘Q4면 충분’ 메시지.

NOTE

강사 배경지식 — VRAM 외에 필요 메모리: VRAM 외에 (1) KV cache — 대화 기록 저장, 보통 VRAM의 20~30%. (2) 컨텍스트 윈도우 — 한 번에 처리 가능한 토큰 수, 32K 토큰 = 추가 5GB+. 즉 ‘파라미터 × 0.6GB’는 ‘최소’ — 실전엔 1.5배 잡아야 안전. 7B 모델은 8GB VRAM 권장, 70B 모델은 64GB+ 권장.

NOTE

강사 배경지식 — 한국어 능력과 모델 크기: (1) 3B — 한국어 부자연스러움. (2) 7B — 일반 업무 OK. (3) 13B — 자연스러움. (4) 30B+ — 사람 수준. 단 ‘한국어 특화 모델’ — Solar(Upstage), EXAONE(LG), KULLM(고려대) — 같은 크기에서 한국어 더 좋음. 한국 회사는 한국어 특화 모델 우선 검토.

NOTE

강사 배경지식 — 모델 크기별 응답 속도 (강사 대응용): RTX 4090 기준 — 7B 약 50토큰/초, 13B 약 30토큰/초, 70B Q4 약 8토큰/초. ‘토큰/초’ = 한국어 약 0.5~0.7글자/초. 즉 70B 모델은 ‘1초에 4글자’ 정도. 사람 읽는 속도와 비슷. 본격 운영은 4090 다중·H100.

Q

예상 청중 질문 1: ‘우리 회사 어떤 크기?’ → 답: ‘챗봇이면 7~13B 충분. 사내 문서 RAG면 13~30B. 본격 법무·연구면 70B+. 첫 도입은 7B로 시작 — 실패 부담 적음.’

Q

예상 청중 질문 2: ‘크면 클수록 좋은 거 아닌가?’ → 답: ‘성능은 그렇지만 속도·비용·전기·소음 모두 큼. 7B로 충분한 일에 70B 쓰면 비용 5배+, 속도 5배 느림. ‘목적에 맞는 크기’가 정답.’

Q

예상 청중 질문 3: ‘Q4 양자화 품질 떨어지지 않나?’ → 답: ‘떨어집니다. 정확히는 ‘약 5~10% 정확도 감소’. 단 ‘사내 챗봇’에는 차이 거의 안 느낌. ‘법무 분석·의료 진단’ 같은 정밀 작업은 Q8 또는 FP16 권장.’

TIP

강사 함정 — 양자화 디테일 깊게 들어가지 말 것: Q4·Q5·Q8·NF4 같은 디테일은 초보자 혼란. ‘Q4가 균형 최적’만 메시지. 더 깊은 건 3편에서.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 공식 외우기. 1~2분 ‘파라미터·양자화’ 풀이. 2~4분 구간별. 4~5분 한국어 능력. 5~6분 청중 질문. 공식 ‘파라미터 × 0.6GB’ 칠판에 크게 — 외우게.

BRIDGE

“VRAM 공식 알았다면 — 실제 어떤 모델 선택할지. 무료 오픈소스 LLM 비교입니다.”

LLM CHOICE

무료 LLM 모델 선택

■ 가변층 — 2026.6 시점, 매년 새 모델 등장

- Llama 3.3 / Qwen 2.5 (글로벌 일반) — Llama 3.3 70B — Meta, 가장 폭넓은 사용. Qwen 2.5 72B — Alibaba, 한국어·코딩 강함. 둘 다 무료·상업 OK. 시작 권장.
- Solar / EXAONE / KULLM (한국어 특화) — Solar (Upstage) — 한국 회사, 한국어 강점. EXAONE (LG) — 산업·기술 강점. KULLM (고려대) — 학술·연구. 같은 크기에서 한국어 더 좋음.

🕒 5분 · 모델 선택

SAY

“모델 선택입니다. 자체 호스팅 시 ‘어떤 오픈소스 모델 쓸지’입니다.”

SAY

“두 갈래로 정리됩니다. 글로벌 일반과 한국어 특화.”

SAY

“글로벌 일반 — Meta Llama 3.3, Alibaba Qwen 2.5 두 개가 압도적. Llama가 가장 인기, 사례·지원·튜토리얼 풍부. Qwen이 한국어·코딩 더 좋음. 둘 다 Hugging Face에서 무료 다운로드, 상업 이용 OK.”

SAY

“한국어 특화 — Upstage Solar, LG EXAONE, 고려대 KULLM. ‘같은 7B여도 Llama보다 한국어 자연스러움’. 단 사례·지원이 글로벌보다 적음. 한국 회사 ‘한국어 만이 중요’면 한국어 특화. ‘다국어 + 코딩’도 필요면 글로벌.”

SAY

“실전 권장 — 시작은 Llama 3.1 8B 또는 Qwen 2.5 7B. 안정 후 13~70B로 업그레이드. 한국어 욕구 강하면 Solar 추가 검토.”

STORY

Hugging Face — 오픈소스 AI 모델의 GitHub. 모든 무료 LLM의 다운로드·문서·예시 코드 1곳. URL: huggingface.co. 무료 가입, 모델 클릭 한 번에 다운로드. 한국 회사들이 ‘여기서 받아서 사내 서버에 설치’ 패턴.

STORY

Solar 10.7B 공식 정보. Upstage 2023-12 발표. 영어·한국어 양쪽 우수. 같은 크기 Llama 대비 한국어 약 30% ↑. URL: upstage.ai/feed/insight/solar. 상업 이용 OK (CC-BY-NC 4.0 라이선스 — 비영리만, 영리는 별도 협의).

STORY

EXAONE 공식 정보. LG AI Research, 2024 EXAONE 3.0 7.8B 공개. 한국어 + 산업·전문가 도메인 강점. URL: lgresearch.ai. 상업 이용 시 LG와 라이선스 협의 필요.

NOTE

★ 강사 핵심 배경지식 — 모델 선택의 4가지 기준: (1) 한국어 자연스러움 — 사내 사용 시 핵심. (2) 코딩 능력 — 개발팀 사용 시. (3) 라이선스 — 상업 이용 가능? 무료? 제한? (4) 컴퓨팅 요구 — VRAM 얼마. 우리 회사 우선순위 정리 후 선택.

NOTE

강사 배경지식 — ‘라이선스’ 풀이: AI 모델 사용 시 ‘이 조건 지키면 무료’ 약속. (1) Apache 2.0 — 상업·재배포·수정 모두 OK. 가장 자유. Llama·Qwen. (2) CC-BY-NC — 비영리 OK, 영리 협의. Solar. (3) 회사 별도 라이선스 — 협의 필요. EXAONE. 모델 다운로드 전 라이선스 확인 필수.

NOTE

강사 배경지식 — ‘파인튜닝’ 미리 풀이: ‘모델 가져와서 우리 회사 데이터로 추가 학습’. 7B 모델 + 우리 회사 5,000 문서 학습 = ‘우리 회사 전용 AI’. 비용 — 클라우드 GPU 시간당 \$5~10 × 약 20~50시간 = \$100~500. 본 강좌 3편이 자세히. 2강에서는 ‘파인튜닝 가능’만 기억.

Q

예상 청중 질문 1: ‘Solar가 한국어 잘하면 그것만 쓰면?’ → 답: ‘한국어 잘하지만 ‘영어·코딩’ 부분 약간 약함. 사내 사용 전부가 한국어면 Solar. ‘영어 보고서·코딩’도 필요면 Llama·Qwen 추가.’

Q

예상 청중 질문 2: ‘ChatGPT만큼 좋은 오픈소스?’ → 답: ‘아쉽지만 GPT-4·Claude 3.5 수준은 아직. Llama 70B가 ‘약 80% 수준’. 그래도 사내 챗봇·문서 RAG는 충분. ‘세계 최강’이 필요한 작업은 클라우드 API 권장.’

Q

예상 청중 질문 3: ‘새 모델 매년 나오는데 따라가야?’ → 답: ‘기본 — 매년 1회 ‘모델 업그레이드 검토’. 매번 따라갈 필요 X. 18개월 주기로 본격 업그레이드 권장. 본 강좌 11편(관리자 운영)에서 다룸.’

TIP

강사 함정 — ‘이 모델이 최고’ 단언 금지: 모델은 매년 바뀜. ‘2026년 6월 시점 권장’만 말. 6개월 후 권장 모델 다를 가능성 크다고 알림.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 두 갈래. 1~2분 Llama·Qwen 설명. 2~3분 Solar·EXAONE. 3~4분 라이선스 풀이. 4~5분 청중 질문. 라이선스 부분 — 청중에게 ‘다운로드 전 확인’ 강조.

BRIDGE

“모델 정해졌다면 — 그 모델 돌릴 GPU 선택입니다. 가격대별 5가지로 정리.”

GPU CHOICE

GPU 선택 가이드

■ 가변층 — 2026.6 가격, 매년 30~50% ↓

- RTX 3060 약 30~40만 원, 12GB VRAM — 최저가 진입. 3~7B 모델 OK. ‘맛보기·개인 데스크탑 자체 호스팅’ 용도. 13B 이상 어려움.
- RTX 4070 약 80~100만 원, 12GB VRAM — 가성비 1위. 7~13B 모델. 사내 챗봇 1대 가능. ‘소규모 자체 호스팅 시작점’ 권장.
- RTX 4090 약 250~300만 원, 24GB VRAM — ‘게이밍 최강’, 자체 호스팅 표준. 13~30B 모델 + Q4 70B 1장. 2장 합치면 70B 본격. 한국 자체 호스팅 가장 많이 선택.
- H100/A100 약 4,000~6,000만 원, 80GB — 엔터프라이즈급. 70B 본격 + 다중 사용자. 대량 토큰. 대기업·서비스 회사. 발열·전기·소음 큼.

SAY

“GPU 4가지로 정리했습니다. 가격대 30만 원~6,000만 원 — 200배 차이. 어디 위치할지 보세요.”

SAY

“RTX 3060 — 최저가. 30~40만 원. VRAM 12GB. 3~7B 모델 OK. ‘맛보기·개인 데스크탑 자체 호스팅’ 용도. 사내 본격 운영 X.”

SAY

“RTX 4070 — 가성비 1위. 80~100만 원. VRAM 12GB. 7~13B 모델. 사내 챗봇 1대 운영 가능. ‘소규모 자체 호스팅 시작점’으로 한국 회사 권장.”

SAY

“RTX 4090 — 한국 자체 호스팅 표준. 250~300만 원. VRAM 24GB. 13~30B + Q4 70B 1장. 2장 합치면 본격 70B. 가장 인기.”

SAY

“H100·A100 — 엔터프라이즈급. 4,000~6,000만 원 1장. VRAM 80GB. 70B + 다중 사용자 + 대량 토큰. 대기업·서비스 회사용. 발열·전기·소음 큼 — 서버실 필수.”

STORY

RTX 4090 한국 가격 (강사 대응용). 2024 출시 직후 약 300만 원. 2026.6 약 250만 원 (정상가) + 일부 매장 200만 원대. 비교 — 미국 약 \$1,599. 한국 가격이 다소 비쌌 (수입 마진). 컴퓨존·다나와·옥션 비교 권장.

STORY

H100 한국 구입 (강사 대응용). 일반 매장 X — 기업 영업으로만. NVIDIA 한국 파트너 — 삼성SDS, LG CNS, 하나로 ICT 등. 가격 4,000~6,000만 원, 리드타임 3~6개월. 단순 GPU가 아니라 ‘서버 + GPU 패키지’로 구매. 데이터센터급 전기·냉각 필요.

NOTE

★ 강사 핵심 배경지식 — VRAM이 ‘속도보다 우선’: GPU 선택 시 핵심은 VRAM 크기. 13B 모델 돌려야 하는데 8GB GPU 사면 ‘속도 빠르지만 모델 못 올림’. 8B 모델 + 빠른 GPU(4090) vs 13B 모델 + 느린 GPU(3060 12GB) — 사내 사용은 후자가 더 유용.

NOTE

강사 배경지식 — RTX 4090의 ‘다중 장착’ 패턴: 한국 자체 호스팅 가장 흔한 구성 — ‘4090 2장’. 2장 합쳐 48GB VRAM → 70B 본격 가능. 단 (1) 메인보드가 더블 PCIe 지원 필요. (2) 파워 1500W+. (3) 케이스 큰 풀 타워. (4) 발열 — 추가 쿨링. 단순 1장 추가가 아니라 ‘시스템 전체 재설계’.

NOTE

강사 배경지식 — GPU 매년 가격: 2024년 4090 약 400만 원 → 2026.6 약 250만 원. 2년 약 40% 하락. 5090 출시 후 4090 추가 하락 예상. ‘급하지 않으면 6개월 미루기’ 옵션도 — 단 ‘시작 안 한 비용’도 손해. ‘지금 사서 운영’ 권장.

NOTE

강사 배경지식 — 4090 vs H100 비용 분석: 한국 회사 가장 흔한 질문 ‘4090 4장 vs H100 1장?’. (1) 가격 — $4090 \times 4 = 1,000$ 만 원 vs $H100 = 6,000$ 만 원. (2) VRAM — 4090 4장 = 96GB vs H100 = 80GB. (3) 속도 — H100 약 1.5배. (4) 소음·발열 — 4090 4장이 훨씬 큼. 보통 ‘4090 4장’이 합리적 단 ‘서비스 회사’는 H100 필수.

Q

예상 청중 질문 1: ‘우리는 첫 시작인데 어디?’ → 답: ‘1대 운영이면 4070 또는 4090. 4070 100만 원으로 시작 — 7~13B 사내 챗봇 OK. 6개월 후 ‘직원 만족도 좋음’ 확인하면 4090 업그레이드.’

Q

예상 청중 질문 2: ‘4090 1장 vs 4080 2장?’ → 답: ‘4090 1장 권장. 4080 2장은 (1) 두 GPU 사이 데이터 이동 비용. (2) 한 모델을 2장에 나누는 복잡도. ‘1대 = 1 GPU’ 가능하면 우선. VRAM 부족할 때만 다중 GPU.’

Q

예상 청중 질문 3: ‘게이밍 GPU(RTX 4090) 사내 사용해도 되나? AMD나 Intel은?’ → 답: ‘4090 사내 사용 OK — Anthropic·Meta도 R&D에 사용. NVIDIA는 ‘RTX는 게이밍, A100·H100은 서버’ 구분 라이선스가 있지만 실제 적용 약함. AMD(Radeon)·Intel(Arc) GPU도 가능하지만 — CUDA가 NVIDIA 전용이라 호환성 떨어짐. 한국 회사 99% NVIDIA 선택.’

TIP

강사 함정 — GPU 모델명 외우게 금지: 모델은 매년 바뀜. ‘VRAM 12GB·24GB·80GB 구간만 외우면 됨’ 메시지. 모델명은 가변증.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 4구간 빠르게. 1~3분 4090 중심 디테일 (가장 흔한 선택). 3~4분 H100. 4~5분 ‘4090 4장 vs H100’ 비교. 5~6분 청중 질문. 4090을 ‘한국 표준’으로 강조.

BRIDGE

“GPU 정해졌다면 — 그 GPU를 어떤 PC에 넣을지. 미니PC·워크스테이션·서버 3가지로.”

PC FORM

미니PC vs 워크스테이션 vs 서버

■ 불변증 — 3가지 형태, 용도별 선택

- GPU 1장 + 노트북 폼팩터 (미니PC) — 100~300만 원. 무소음·저전력. 외장 GPU 박스로 4090 가능. 사무실 책상에 둘 수 있음. 5~10명 사내 챗봇 + 개인 사용.
- GPU 2~4장 + 풀타워 (워크스테이션) — 500~2,000만 원. 일반 사무실 옆방 OK. 4090 2장 = 70B 본격. 발열·소음 큼. 별도 공조 권장. 50~200명 사내.
- GPU 4~8장 + 데이터센터 (서버 랙) — 5,000만~수억 원. 데이터센터 또는 서버실. H100 다중. 200명+ 사내 또는 외부 서비스. 24/7 운영 + 이중화 필수.

🕒 6분 · PC 형태

SAY

“GPU 정했다면 — 그 GPU를 어떤 ‘몸체(폼팩터)’에 넣을지. 3가지 — 미니PC, 워크스테이션, 서버.”

SAY

“미니PC — 100~300만 원. ‘책상에 두는 작은 컴퓨터’. 일반적으로 GPU 내장 약함. 외장 GPU 박스(eGPU) 연결로 4090 가능. 무소음·저전력. 5~10명 사내 챗봇 + 개인 자체 호스팅.”

SAY

“워크스테이션 — 500~2,000만 원. ‘큰 데스크탑’ 풀타워 케이스. GPU 2~4장. 4090 2장 = 70B 본격. 한국 자체 호스팅 가장 흔한 폼팩터. 단 발열·소음 큼 — 사무실 책상 X, 옆방·소회의실 권장.”

SAY

“서버 (랙) — 5,000만~수억 원. ‘세로로 긴 박스가 랙에 꽂혀 있는’ 형태. 데이터센터 또는 회사 서버실. H100 다중. 24/7 운영 + 이중화 + 별도 공조 + 보안 출입. 200명+ 또는 외부 서비스.”

STORY

한국 자체 호스팅 폼팩터 분포 (강사 대응용 추정). 미니PC + eGPU 약 10%. 워크스테이션 약 70%. 서버 약 20%. 한국 중견기업 자체 호스팅 ‘대부분 워크스테이션’.

STORY

워크스테이션 발열 디테일. 4090 1장 — 약 450W 전기, 발열 약 1,500 BTU/h. 4090 2장 — 약 900W, 발열 3,000 BTU/h. 일반 사무실 옆방(15평) 에어컨 1대로 감당. 더 큰 구성은 서버실 권장. 출처: NVIDIA GeForce RTX 4090 Spec.

NOTE

★ 강사 핵심 배경지식 — 폼팩터 선택의 3가지 기준: (1) 동시 사용자 수 — 5~10명? 50~200명? 200+? (2) 사무실 공간 — 책상 위? 옆방? 서버실? (3) 예산 — 100만 원대? 1,000만 원대? 5,000만 원+? 셋의 교차점이 선택. 우리 회사 5명 챗봇은 미니PC, 100명 RAG는 워크스테이션, 5,000 직원 챗봇은 서버.

NOTE

강사 배경지식 — ‘eGPU(외장 GPU)’: 미니PC·노트북에 외장으로 연결하는 GPU 박스. Thunderbolt 케이블로 연결. 4090을 노트북에 연결 가능. 단 (1) 속도 약 70% (Thunderbolt 한계). (2) 케이블 안정성 — 헐거우면 끊김. (3) 가격 추가 50~100만 원. ‘작은 시작’ 패턴으로 적합.

NOTE

강사 배경지식 — 워크스테이션 케이스 선택: 4090 2장 + 발열·소음 처리 — 풀타워 케이스 + 케이스 팬 6개 + CPU 쿨러 큰 것 + 파워 1500W. 케이스 추천 — Fractal Design Define 7 XL, Lian Li O11 Dynamic XL. 가격 약 30~50만 원. ‘조용·발열 처리’가 케이스 선택의 핵심.

NOTE

강사 배경지식 — 서버실 표준 요구사항: 24시간 22°C 유지(전용 에어컨), 정전 대응 UPS(무정전 전원공급), 화재 감지·진압, 출입 통제(카드키·로그), 인터넷 회선 이중. 일반 사무실 서버실로 부적합 — 별도 공조 + 보안 시설 필요. 자체 서버실 신축 시 500만~3,000만 원 추가.

Q

예상 청중 질문 1: ‘우리는 5~10명 챗봇인데 워크스테이션 X 미니PC OK?’ → 답: ‘미니 + eGPU + 4070 정도면 7~13B 모델 + 5~10명 OK. 단 ‘동시 5명 채팅’ 시 속도 떨어질 수 있음. 워크스테이션 + 4090 1장이 안전.’

Q

예상 청중 질문 2: ‘우리는 5,000명 회사. 서버 필요?’ → 답: ‘5,000명 전부 동시 사용 X. 동시 사용자 50~200명 가정. 워크스테이션 2~3대로 충분. 5,000명 전부는 클라우드 API가 더 경제적.’

Q

예상 청중 질문 3: ‘우리 회사 서버실 없는데?’ → 답: ‘옵션 — (1) 워크스테이션 + 옆방 (에어컨 1대). (2) IDC 임대 — 월 30~100만 원에 데이터센터 1U 공간. (3) 클라우드 + ‘민감 부분만 자체 호스팅’ 하이브리드. 자체 서버실 신축은 가장 비용 큼.’

TIP

강사 함정 — ‘우리는 서버 필요해’ 청중 과장 반박: 청중이 ‘대기업처럼 서버실’ 환상. 실제 한국 회사 70%가 워크스테이션이면 충분. ‘서버는 200명 이상 또는 외부 서비스’ 메시지.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 3가지 형태. 1~3분 워크스테이션 디테일 (가장 흔함). 3~4분 미니PC + eGPU. 4~5분 서버 + 서버실. 5~6분 청중 질문. 워크스테이션 중심 강조.

BRIDGE

“폼팩터까지 정했다면 — 그 안에 깔 ‘OS(운영체제)’ 결정. 답은 거의 정해져 있어요.”

OS · DRIVER

OS·드라이버 표준 — Ubuntu + NVIDIA + CUDA

■ 불변층 — 자체 호스팅의 ‘기본 구성’

- ★ OS: Ubuntu 22.04 LTS — 무료, 가장 표준, AI 라이브러리 호환 1위
- ★ NVIDIA 드라이버: 최신 안정판 (예: 550.x) — apt로 설치
- ★ CUDA: 12.x (모델 요구 버전 확인 필수)
- ★ Python 3.10~3.11 — AI 라이브러리 표준
- ★ PyTorch — Hugging Face 모델 실행의 기본
- ★ Windows·macOS 가능하지만 ‘비추천’ — AI 라이브러리 호환성·성능 떨어짐

🕒 5분 · OS·드라이버

SAY

“OS·드라이버 결정은 거의 정해져 있어요. ‘Ubuntu + NVIDIA + CUDA + Python + PyTorch’가 한국 자체 호스팅 99%의 표준.”

SAY

“Ubuntu 22.04 LTS — 무료. 가장 표준. AI 라이브러리 호환 1위. LTS = ‘Long Term Support’ = 5년 무료 보안 업데이트. 안정. NVIDIA 드라이버 + CUDA 자동 설치 지원.”

SAY

“NVIDIA 드라이버 — 최신 안정판. 2026.6 기준 약 550.x 시리즈. ‘apt install nvidia-driver-550’ 한 줄로 설치. 재부팅 후 ‘nvidia-smi’ 명령으로 작동 확인.”

SAY

“CUDA — NVIDIA의 GPU 계산 도구. AI 모델은 ‘CUDA 위에서’ 작동. 12.x 권장. 단 — ‘모델이 요구하는 CUDA 버전’ 확인 필수. Llama 3.3은 CUDA 12+. 오래된 모델은 CUDA 11.x 요구. 모델 README 확인.”

SAY

“Python 3.10~3.11 — AI 라이브러리 표준 버전. PyTorch — Hugging Face의 모든 모델이 PyTorch 기반. 이 둘 없으면 시작 불가.”

SAY

“Windows·macOS — 가능하지만 비추천. Windows는 NVIDIA 드라이버 OK이지만 AI 라이브러리 호환성 약함. WSL2(Windows 안 리눅스) 옵션이 좋음. macOS는 Apple Silicon 자체 GPU(MLX)로 가능하지만 한국 회사엔 비주류.”

STORY

Ubuntu LTS 출처. Canonical Ltd 공식. 22.04 LTS — 2022.04 출시, 2027.04까지 무료 지원. 24.04 LTS — 2024.04 출시, 2029.04까지. 자체 호스팅 시작 시점에 ‘LTS 중 가장 새것’ 선택 권장. URL: ubuntu.com/about/release-cycle.

STORY

CUDA 호환성 디테일 (강사 대응용). CUDA 12.x = RTX 3000·4000·H100·A100 호환. CUDA 11.x = 더 오래된 GPU + 일부 모델. 새 GPU + 새 모델 = CUDA 12+. ‘CUDA 버전 불일치’가 가장 흔한 설치 에러. 모델 README의 ‘requirements.txt’ 정독.

NOTE

★ 강사 핵심 배경지식 — ‘드라이버’ 정확히: 하드웨어를 OS가 인식하도록 ‘중간에 있는 프로그램’. NVIDIA 드라이버 = OS(Ubuntu)와 GPU(4090)가 소통하게 해주는 프로그램. 없으면 OS가 ‘이 카드 모름’ 상태. 드라이버 → CUDA → PyTorch → AI 모델, 이 순서대로 깔림.

NOTE

강사 배경지식 — ‘CUDA’ 풀이 디테일: ‘Compute Unified Device Architecture’. NVIDIA가 만든 ‘GPU에서 일반 계산 시키는 도구’. 원래 GPU는 ‘그래픽 그리기’ 전용 — CUDA가 등장해 ‘일반 수학 계산 시키기’ 가능해짐. AI는 본질이 수학 계산이라 GPU가 빠름 → AI 붐의 기술적 기반.

NOTE

강사 배경지식 — 설치 표준 순서 (Ubuntu 22.04 기준): (1) Ubuntu 22.04 LTS 설치. (2) 시스템 업데이트 ‘apt update && apt upgrade’. (3) NVIDIA 드라이버 ‘apt install nvidia-driver-550’. (4) 재부팅. (5) ‘nvidia-smi’ 확인. (6) Docker 설치 ‘curl get.docker.com | sh’. (7) NVIDIA Container Toolkit. 약 30분 ~1시간.

NOTE

강사 배경지식 — 자체 호스팅 일상 운영 명령: (1) ‘nvidia-smi’ — GPU 상태·메모리·온도 확인. (2) ‘docker ps’ — 실행 중 컨테이너. (3) ‘df -h’ — 디스크 사용량. (4) ‘systemctl status ...’ — 서비스 상태. (5) ‘journalctl -u ...’ — 로그. 일상 점검의 5가지 명령. 본 강좌 11편(관리자)에서 자세히.

Q

예상 청중 질문 1: ‘우리 직원이 Windows에 익숙한데?’ → 답: ‘WSL2 활용 권장. Windows 위에 Ubuntu 띄움. NVIDIA 드라이버는 Windows에 두고 Ubuntu에서 GPU 사용. 단 성능 약 90~95% — 약간 손해. 운영자 학습 곡선 vs 성능 트레이드오프.’

Q

예상 청중 질문 2: ‘Ubuntu 22.04 vs 24.04?’ → 답: ‘안정 우선이면 22.04 (성숙). 최신 우선이면 24.04 (지원 길음). 2026년 6월 시점 24.04 LTS도 안정 — 권장. 단 일부 AI 라이브러리가 24.04 호환성 검증 중일 수 있어 — 모델 README 확인.’

Q

예상 청중 질문 3: ‘CentOS·RHEL은? 일부 기업이 사용한다는데.’ → 답: ‘가능. 단 Ubuntu가 ‘AI 라이브러리 호환성’ 약 30% 우수. 사례·튜토리얼 약 5배 많음. ‘기존 RHEL 라이선스 있음’ 회사는 RHEL, 신규 도입은 Ubuntu 권장.’

TIP

강사 함정 — 설치 명령 자세히 외우게 금지: 명령어는 매년 바뀜. 청중에게 ‘설치는 한 번이고 그건 IT가 함’ 메시지. ‘우리는 결정 + 점검 명령만 알면 됨’ 위치.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘답이 거의 정해짐’. 1~3분 5가지 표준 빠르게. 3~4분 ‘Windows·macOS 비추천’. 4~5분 청중 질문. 표준 메시지 강조.

BRIDGE

“OS·드라이버 표준 알았다면 — 마지막 한 가지. ‘Docker로 컨테이너 격리’ — 자체 호스팅의 핵심 패턴입니다.”

DOCKER

Docker + 컨테이너 격리

■ 불변층 — 자체 호스팅의 표준 패턴

- OS에 직접 설치 (Docker 없이 (Bad)) — 모든 라이브러리·파이썬·모델을 Ubuntu에 직접 설치. 충돌 빈번. 업그레이드 어려움. 보안 격리 X. '일주일 만에 망가지는 환경'.
- 컨테이너로 격리 (Docker 사용 (Good)) — '컨테이너' = '가상 박스'. 각 모델·서비스를 독립 박스에 격리. 충돌 X. 업그레이드 쉬움. 보안 격리. '일반 호스팅의 표준'.

🕒 6분 · Docker

SAY

“2강 마지막 — Docker입니다. ‘이것 없이 자체 호스팅 시작 X’ 정도로 중요해요.”

SAY

“Docker 없는 설치 vs 있는 설치 — 보세요. Docker 없는 경우 — Ubuntu에 Python, PyTorch, 모델, 웹서버 다 직접 설치. 처음엔 작동. 일주일 후 ‘새 모델 추가’ → 라이브러리 충돌 → 망가짐. 한국 자체 호스팅 ‘초보자 함정 1위’.”

SAY

“Docker 사용 — ‘컨테이너’라는 ‘가상 박스’에 각 서비스를 따로 가둬. 박스끼리는 영향 X. 박스 하나 망가져도 다른 박스 안전. 새 모델 추가는 ‘새 박스 만들기’ — 기존 영향 X. 자체 호스팅의 표준 패턴.”

SAY

“실전 구성 예시. 박스 1 — Llama 3.3 70B 모델 서비스. 박스 2 — Qwen 2.5 7B 모델 서비스. 박스 3 — 사내 챗봇 웹 인터페이스 (Open WebUI 같은 무료 도구). 박스 4 — RAG용 문서 검색 (ChromaDB 같은 무료 벡터 DB). 박스 5 — 모니터링 (Prometheus·Grafana). 5개 박스가 ‘서로 안 부수면서’ 같은 서버에서 작동.”

SAY

“NVIDIA Container Toolkit — Docker가 GPU 쓰게 해주는 추가 도구. ‘apt install nvidia-container-toolkit’ 한 줄. 이게 있어야 박스 안에서 GPU 인식.”

STORY

Docker 공식 정보. Docker Inc 2013 출시. 현재 사실상 ‘컨테이너 표준’. 무료(개인·소규모) + 유료 옵션.
URL: docker.com. 한국 거의 모든 자체 호스팅이 Docker 사용.

STORY

NVIDIA Container Toolkit 출처. NVIDIA 공식. URL: docs.nvidia.com/datacenter/cloud-native/container-toolkit. ‘nvidia-docker’ 또는 ‘nvidia-container-toolkit’ 명칭으로 검색. Docker 컨테이너에서 GPU 인식 가능하게 해주는 ‘다리’.

STORY

Open WebUI 출처. Ollama·Llama.cpp 같은 백엔드 위에 ‘ChatGPT같은 웹 UI’ 제공. 무료 오픈소스.
Docker 이미지 제공. URL: openwebui.com 또는 GitHub [openwebui/open-webui](https://github.com/openwebui/open-webui). 한국 회사 자체 호스팅 챗봇의 가장 흔한 사용자 인터페이스.

NOTE

★ 강사 핵심 배경지식 — ‘컨테이너’ 정확히: 가상머신(VM)과 비슷한 ‘격리된 실행 환경’. VM은 ‘완전한 가상 컴퓨터’ — 무거움. 컨테이너는 ‘프로세스만 격리’ — 가벼움. VM 1대 = 부팅 30초 + RAM 2GB. 컨테이너 1개 = 시작 1초 + RAM 100MB. 자체 호스팅에 컨테이너 표준.

NOTE

강사 배경지식 — Docker 일상 명령 (강사 대응용): (1) ‘docker ps’ — 실행 중 컨테이너 목록. (2) ‘docker logs <컨테이너명>’ — 로그 보기. (3) ‘docker restart <컨테이너명>’ — 재시작. (4) ‘docker pull <이미지>’ — 새 모델 다운로드. (5) ‘docker compose up -d’ — 여러 컨테이너 동시 시작. 운영자 5개 명령으로 90% 일상.

NOTE

강사 배경지식 — ‘이미지’와 ‘컨테이너’ 차이: ‘이미지’ = 설계도(Docker Hub에서 다운로드). ‘컨테이너’ = 설계도로 만든 실제 실행 인스턴스. ‘Llama 3.3 이미지 다운로드 → 컨테이너 실행 → 챗봇 가동’. 이미지는 1개여도 컨테이너는 여러 개 가능.

NOTE

강사 배경지식 — Docker Compose: 여러 컨테이너 정의 + 한 번에 실행. ‘docker-compose.yml’ 파일에 5개 컨테이너 정의 → ‘docker compose up’ 한 줄로 모두 가동. 자체 호스팅 운영의 표준. 본 강좌 7편(사내에 이진트 배포)에서 자세히.

NOTE

강사 배경지식 — Docker 보안 격리: 컨테이너는 ‘OS 격리’ — 한 컨테이너가 다른 컨테이너의 파일·메모리 못 봄. 단 ‘완전 격리’ X — root 권한 컨테이너는 OS 자체 위협 가능. 보안 best practice — ‘non-root 사용자 + read-only 파일시스템 + 제한된 권한’. 본 강좌 9편(보안)에서 자세히.

Q

예상 청중 질문 1: ‘Docker 어렵지 않나?’ → 답: ‘기본 5개 명령(docker ps, logs, restart, pull, compose) 약 1주 학습. 운영자 학습 부담 적음. 어려운 부분(Compose 작성·이미지 빌드)은 ‘설정 1번’이라 IT가 미리 해 두면 운영자는 명령만.’

Q

예상 청중 질문 2: ‘Kubernetes 들어봤는데?’ → 답: ‘Kubernetes = Docker 컨테이너를 ‘여러 서버에 분산 + 자동 복구’. 대기업·대규모 서비스용. 자체 호스팅 ‘1~5대 서버’ 규모는 Docker Compose 충분. Kubernetes 는 ‘10대+ 서버 + 24/7 무중단’ 단계에서 검토. 본 강좌 11편에서 다룸.’

Q

예상 청중 질문 3: ‘Docker로 안 깔고 ‘venv’ 같은 거 안 되나?’ → 답: ‘파이썬만의 격리는 가능 — venv·conda. 단 (1) 라이브러리 격리만 — OS 라이브러리 충돌은 못 막음. (2) GPU·CUDA 충돌 못 막음. (3) 여러 서비스 관리 어려움. Docker가 5배 강력. 자체 호스팅은 Docker 표준.’

TIP

강사 함정 — Docker 명령 자세히 외우게 금지: ‘기본 5개만 알면 일상 운영 OK’. 디테일은 ‘우리 IT가 설치 + 운영자는 사용’ 분리.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 Docker 필요성. 1~2분 컨테이너 = ‘박스’ 비유. 2~3분 실전 구성 5개 박스. 3~4분 일상 5명령. 4~5분 Kubernetes·venv 비교. 5~6분 청중 질문. 박스 비유 적극 활용.

BRIDGE

“2강 마지막 — 실습. 우리 회사 장비 구매서 1페이지 채우기.”

WORKSHOP 2

실습 — 우리 회사 장비 구매서 1페이지

■ 적용 (워크시트)

- ① 사용할 모델 — 7B / 13B / 70B 중?
- ② VRAM 계산 — 모델 $\times$ 0.6GB = ____ GB
- ③ GPU 선택 — RTX 4070 / 4090 / H100 중?
- ④ PC 형태 — 미니PC / 워크스테이션 / 서버 중?
- ⑤ OS·드라이버 — Ubuntu 22.04 + NVIDIA 550 + Docker (표준)
- ★ 예상 총 비용 — 장비 ____ 만 원 + 월 운영 ____ 만 원

🕒 9분 · 실습

SAY

“2강 실습 — 장비 구매서 6칸 채우기. 1강 ‘인프라 결정서’가 ‘클라우드 vs 자체 호스팅’의 큰 방향이었다면, 2강 ‘장비 구매서’는 ‘자체 호스팅이면 무엇 살지’ 구체.”

DO

조별 실습 (5분, 3~4인 1조). 6칸 채우기. ①~④는 2강 내용 정리. ⑤는 표준. ⑥은 ‘① + ②’ 합산.

SAY

“시작 표준 추천 — ‘우리는 첫 시작’인 한국 중견기업 — 7B 모델 + RTX 4070 + 워크스테이션 + Ubuntu + Docker = 약 200만 원 장비. 약 5명 챗봇 OK. 6개월 후 4090 + 13B 업그레이드 가능.”

SAY

“본격 운영 추천 — ‘50~200명 RAG’ 규모 — 13B 모델 + RTX 4090 $\times$ 2 + 워크스테이션 + Ubuntu + Docker = 약 600~800만 원. 사내 챗봇 + 문서 RAG OK.”

SAY

“대규모 추천 — ‘500명+ 본격’ — 70B 모델 + H100 1장 + 서버 + 서버실 = 약 6,000만 원+. 본격 사내 AI.”

Q

발표 요청: “1~2조 발표. 우리 회사 총 비용 추정만.” → 보통 200~1,000만 원. → 다양한 답이 정상.

Q

발표 요청 2: “총 비용이 너무 큰 조? 너무 작은 조?” → 양극단 답. → ‘큰 조 — 1강 인프라 결정서 재검토. 작게 시작 가능. 작은 조 — 정상. 작게 시작이 정석.’

NOTE

★ 강사 핵심 배경지식 — 구매서 6칸 작성 가이드: (1) 모델 — 첫 도입은 7B 권장. (2) VRAM — $7B \times 0.6 = 4.2GB$, 안전마진 1.5배 = 6GB. (3) GPU — 6GB 충족하는 ‘RTX 4070 12GB’ 권장. (4) PC — 5~10명 챗봇이면 워크스테이션. (5) OS — 표준. (6) 비용 — 약 200~250만 원 + 월 운영 약 10~30만 원.

NOTE

강사 배경지식 — ‘다음 주 액션’ 권장 3가지: (1) 장비 구매서 1페이지 IT부에 전달. (2) IT부에서 견적 의뢰서 작성 — 1주 안. (3) 견적 받고 사장님께 결재 — 1주 안. 셋 다 2주 안에 가능. 단 1강 ‘인프라 결정서’가 먼저 — 사장님 결정이 우선.

NOTE

강사 배경지식 — 견적 의뢰처: 한국 자체 호스팅 GPU 장비 매장 — (1) 컴퓨존 (대량 견적). (2) 다나와 (가격 비교). (3) NVIDIA 한국 파트너 (삼성SDS·LG CNS·하나로ICT) — 엔터프라이즈 H100. 견적 3~5개 받아 비교 권장.

Q

예상 청중 질문 1: ‘예산 100만 원밖에 없는데?’ → 답: ‘RTX 3060 + 7B 모델 + 미니PC 구성 가능. 단 ‘운영 미니PC 1대 + 사용자 5명’ 한계. 더 큰 규모 원하면 클라우드 (\$30/월) 시작.’

Q

예상 청중 질문 2: ‘우리는 클라우드 결정인데 2강 무의미한가?’ → 답: ‘아니에요. 클라우드여도 ‘우리가 어떤 모델 사용할지’는 같은 결정. Claude 3.5 vs GPT-4o vs Gemini 선택 시 ‘모델 크기·능력·가격’ 비교 — 2강 사고 그대로 적용.’

Q

예상 청중 질문 3: ‘견적 받았는데 권장과 다르면?’ → 답: ‘견적이 더 비싸면 — ‘이 사양이 정말 필요한가’ 토론. 견적이 더 싸면 — ‘싼 이유’ 확인 (중고? 단종?). 권장은 ‘기준’이고 실제로는 견적·예산·우선순위 종합.’

TIP

강사 함정 — ‘완벽한 구매서’ 압박 X: ‘60% 답으로 시작 → 견적 받으면서 보완’ 메시지. 사장님 결재용 ‘이상 사양’ 결정은 IT부 + 견적 + 회의를 거쳐.

TIP

강사 진행 팁 — 9분 시간 배분: 0~5분 개별 작성. 5~7분 1~2조 발표. 7~9분 ‘다음 주 액션 3가지’. 5분 작성 충분히. 강사는 조별로 돌며 ‘어디 막혔는지’ 확인.

BRIDGE

“2강 끝. 잠깐 쉬고 3강 ‘네트워크·보안·격리’로. 장비를 갖췄어도 보안이 빠지면 사고. 3강이 최후의 장벽입니다.”

2강 WRAP

2강 정리 — 5가지 결정과 다음 단계

■ 마무리

- ① 모델 — 사용 인원·작업에 맞춰 7B / 13B / 70B 선택
- ② VRAM — ‘파라미터 × 0.6GB’ 공식 외움
- ③ GPU — RTX 4070(소규모) / 4090(표준) / H100(대규모)
- ④ PC — 미니PC / 워크스테이션 / 서버, 인원·예산 기준
- ⑤ OS — Ubuntu 22.04 + NVIDIA + Docker (표준)
- ★ 장비만으론 부족 — 3강에서 ‘네트워크·보안·격리’

🕒 3분 · 정리

SAY

“2강 정리 — 5가지 결정점만 다시. 모델·VRAM·GPU·PC·OS. 이 5가지가 ‘우리 회사 장비 구매서’의 5칸. 외울 공식 한 개 — ‘파라미터 × 0.6GB’.”

SAY

“핵심 메시지 한 마디 — ‘작게 시작’. 첫 도입은 7B + RTX 4070 + 워크스테이션 + Ubuntu + Docker = 약 200만 원. 6개월 후 ‘직원 만족도’ 확인하면 업그레이드. 처음부터 H100 사면 6개월 후 ‘과잉 투자’ 후회.”

SAY

“그런데 — 장비만 갖춘다고 자체 호스팅 완성 X. ‘네트워크 안전한가’, ‘권한 통제됐나’, ‘외부 공격 막혔나’, ‘로그 남나’ — 5개 빠지면 사고. 3강이 그 부분입니다. 잠깐 쉬고 만나요.”

NOTE

★ 강사 핵심 배경지식 — 2강 끝 메시지 톤: ‘이제 장비 사면 된다’ 무드 만들지 말 것. ‘장비는 절반, 보안이 나머지 절반’ 메시지. 3강이 ‘덤’이 아니라 ‘본질’이라는 동기.

TIP

강사 진행 팁 — 3분 안에 빨리. 정리 슬라이드는 ‘메시지 강조’가 목적. 디테일 X.

BRIDGE

“쉬는 시간 10분. 3강 ‘네트워크·보안·격리’에서.”

INTRO · TITLE

네트워크·보안·격리

3강 — 장비를 갖춰어도 보안이 없으면 사고난다

🕒 3분 · 시작

SAY

“3강 ‘네트워크·보안·격리’입니다. 2편의 마지막. 1강 ‘방향’, 2강 ‘장비’, 3강 ‘안전’. 셋이 합쳐져야 자체 호스팅 완성입니다.”

SAY

“3강 60분 동안 다섯 가지를 봅니다 — (1) 사내망 격리 구조, (2) Reverse Proxy + HTTPS, (3) mTLS 인증, (4) RBAC 권한, (5) 감사 로그. 어렵게 들려도 핵심 개념 5개만 알면 됩니다.”

SAY

“3강 약속 — ‘초보자가 이해 가능한 깊이’로 갑니다. ‘mTLS 인증서 직접 만들기’ 같은 깊은 기술 X. ‘우리 회사 보안 도면 한 장’ 그릴 수 있는 수준이 목표예요.”

Q

도입 질문: “보안 설정 직접 해본 분?” → 보통 1~2명. → ‘좋아요. 직접 설치하는 IT가 하고, 의사결정자는 ‘우리 보안 도면이 어떤지’만 알면 됩니다. 오늘 그 도면을 그립니다.’

Q

도입 질문 2: “회사에서 ‘피싱 메일·랜섬웨어’ 사고 또는 경고 받은 적 있는 분?” → 보통 다수. → ‘맞아요. 한국 회사 80%+가 매년 1회+ 경고 받습니다. 자체 호스팅 AI도 동일 공격 대상. 보안 빠진 자체 호스팅은 ‘공격 표적’ 그 자체.’

NOTE

★ 강사 핵심 배경지식 — 3강이 ‘가장 안 듣고 싶은 강의’ 톤: 청중 자주 ‘보안 어려워서 지루’ 느낌. 대응 — (1) 사고 사례로 동기 부여. (2) ‘5개 개념만’ 메시지. (3) 비유 적극 사용 (예: mTLS = ‘쌍방 신분증 확인’). (4) ‘우리 IT가 하는 일’과 ‘우리가 결정할 일’ 분리.

NOTE

강사 배경지식 — 자체 호스팅 보안 사고 패턴: 가장 흔한 사고 — (1) 외부 노출 — IT가 ‘아직 테스트 중’ 상태로 인터넷에 노출 → 자동 봇이 발견 → 침투. (2) 약한 비밀번호. (3) 권한 통제 X — 직원 1명이 모든 데이터 다룬 로드 가능. (4) 패치 X — 1년 이상 보안 업데이트 안 됨. 셋 다 ‘방법 알면 막을 수 있는’ 사고.

NOTE

강사 배경지식 — 3강 60분 시간 배분: 0~3분 인트로. 3~6분 목표. 6~18분 사내망 격리 (가장 중요). 18~30분 Reverse Proxy + mTLS. 30~42분 RBAC. 42~54분 감사 로그·사고 대응. 54~58분 실습. 58~60분 마무리.

TIP

강사 함정 — 보안 기술 자랑 X: ‘저는 침투 테스트 자격 있어요’ 같은 자랑은 청중에게 ‘남의 일’ 느낌. ‘우리 회사가 어떻게 되는지’ 메시지 중심.

BRIDGE

“학습 목표 빠르게.”

OBJECTIVES

60분 후, 이 3가지를 한다

- ① 사내망·DMZ·외부 — 3구역 구분으로 ‘우리 AI 어디 둘지’ 답한다
- ② Reverse Proxy·mTLS·RBAC·감사 로그 — 4가지 보안 장치 풀이
- ③ ‘우리 회사 보안 도면 1페이지’ 완성

🕒 3분 · 학습목표

SAY

“60분 후 셋. 첫째, ‘사내망·DMZ·외부’ 3구역 구분으로 ‘우리 AI 서버 어디 둘지’ 답할 수 있게 됩니다. ‘DMZ’는 ‘반쯤 외부, 반쯤 내부’ 영역인데 — 잠시 후 자세히.”

SAY

“둘째, 4가지 보안 장치 — Reverse Proxy(역방향 프록시), mTLS(상호 인증), RBAC(권한 관리), 감사 로그 — 풀이하고 우리 회사에 어떻게 적용할지 그립니다.”

SAY

“셋째, ‘우리 회사 보안 도면 1페이지’. 1강 인프라 결정서 + 2강 장비 구매서 + 3강 보안 도면 = ‘자체 호스팅 도입 완전판’ 3장.”

NOTE

★ 강사 핵심 배경지식 — 3강 성공 기준: 청중이 ‘우리 IT부에 보안 도면 요구할 때 어떻게 토론할지’ 알게 됨. ‘직접 설치’가 아니라 ‘질문 가능’. 보안 도면 1장 손에.

NOTE

강사 배경지식 — 4가지 보안 장치의 역할: (1) Reverse Proxy — 외부 접근 통제. (2) mTLS — 통신 암호화 + 신원 인증. (3) RBAC — 누구는 무엇 볼 수 있나. (4) 감사 로그 — 누가 무엇 했는지 기록. 네 가지가 ‘방화벽·문지기·신분증·CCTV’ 비유.

TIP

강사 진행 팁 — 학습 목표 3분 안에. ‘본문이 더 중요’.

NETWORK ZONES

네트워크 3구역 — 사내·DMZ·외부

■ 불변층 — 보안의 ‘기본 도면’

- 사내망 (Internal) 회사 직원만 접근 — 회사 안의 LAN. 외부 인터넷에서 직접 접근 X. 사내 DB·파일 서버·민감 시스템. AI 서버 ‘사내’에 둬 = 직원만 사용. 외부 차단 100%.
- DMZ (반외부) 외부·사내 양쪽 접근 — ‘De-Militarized Zone(비무장 지대)’. 회사 홈페이지·메일 서버처럼 외부에서도 접근하는 시스템 위치. AI 서버를 외부 협력사도 쓰게 하면 DMZ.
- 외부 (Internet) 누구나 접근 — 공개 인터넷. 우리가 통제 못 함. 클라우드 AI(Claude·ChatGPT)는 ‘외부’에 위치. 사용 시 사내→외부 통신 발생.

🕒 6분 · 3구역

SAY

“네트워크 보안의 ‘기본 도면’ — 회사 네트워크는 3구역으로 나뉩니다. 사내망·DMZ·외부.”

SAY

“사내망 — 회사 안의 LAN. 외부에서 직접 접근 X. 사내 DB, 파일 서버, 민감 시스템. AI 서버를 사내에 두면 — 직원만 사용 가능. 외부 차단 100%. 가장 안전.”

SAY

“DMZ — ‘De-Militarized Zone(비무장 지대)’. 군사 용어 — ‘남·북 사이 경계지역’. 네트워크에서는 ‘외부와 사내 사이 영역’. 회사 홈페이지·메일 서버처럼 외부도 접근하는 시스템 위치. AI 서버를 외부 협력사도 쓰게 한다면 DMZ.”

SAY

“외부 — 공개 인터넷. 우리가 통제 못 함. 클라우드 AI는 모두 ‘외부’ 영역. 사용 시 ‘사내 → 외부’ 통신 발생.”

SAY

“원칙 — ‘자체 호스팅 AI는 99% 사내망에 둬’입니다. ‘외부 협력사·고객도 사용’이라면 DMZ. 외부 인터넷에 그대로 노출 — 절대 금지.”

STORY

DMZ 사고 패턴 (강사 대응용). 한국 자체 호스팅 사고 1위 — ‘DMZ 설정 잘못해서 사내 시스템 노출’. 예시 — DMZ에 둔 AI 서버가 ‘사내 DB에 접근 가능’으로 설정 → 외부 공격자가 AI 통해 DB 접근. ‘DMZ 시스템은 사내 접근 최소화’ 원칙 강조.

STORY

방화벽 풀이. 두 구역 사이 ‘문지기’ 역할. (1) 외부→DMZ — 정해진 포트만 열림 (443/HTTPS, 80/HTTP 등). (2) DMZ→사내 — 매우 제한적 (보통 닫힘). (3) 사내→DMZ — 어느 정도. 한국 회사 99%가 방화벽 운영 — Fortinet·Palo Alto·체크포인트 등 솔루션.

NOTE

★ 강사 핵심 배경지식 — ‘사내망’ 정확히 무엇: 회사 안의 ‘LAN(Local Area Network)’. 인터넷 케이블이 회사 라우터를 통해 회사 안 컴퓨터·서버·프린터에 연결. 외부에서 ‘회사 IP 주소’ 접근 시도해도 라우터가 차단 — 사내 컴퓨터는 ‘사내 IP(192.168.x.x)’만 가짐. 외부에서 직접 접근 불가.

NOTE

강사 배경지식 — DMZ 설계 패턴 (강사 대응용): 일반적 — (1) DMZ에 ‘프록시 서버’ 둬. (2) 프록시가 사용자 인증 + 외부 요청만 받음. (3) 인증된 요청만 사내 AI 서버로 전달. (4) AI 응답을 프록시가 받아 사용자에게. ‘프록시’ = 중간 매개자. ‘DMZ에 직접 AI 서버 두기’ X — ‘DMZ에 프록시, 사내에 AI 서버’ 권장.

NOTE

강사 배경지식 — 사내·DMZ·외부 결정 기준: (1) 직원만 사용 → 사내. (2) 외부 협력사·고객도 사용 → DMZ + 프록시. (3) 일반 대중에 공개 → 외부 (드물지만 가능). 99% 자체 호스팅은 (1).

NOTE

강사 배경지식 — VPN 풀이: ‘Virtual Private Network’. 외부 인터넷을 통해 ‘마치 사내망에 있는 듯’ 접근. 재택근무 직원이 회사 사내 AI 사용 시 VPN 필수. 한국 회사 VPN 솔루션 — Cisco AnyConnect, FortiClient, NordLayer 등. AI 서버 = 사내, 사용자 = 재택 VPN 패턴.

Q

예상 청중 질문 1: ‘우리는 직원만 쓸 텐데 사내망에 두면 되나?’ → 답: ‘맞습니다. 99% 자체 호스팅의 정답. 사내망에 두면 외부 직접 접근 X. 재택근무는 VPN.’

Q

예상 청중 질문 2: ‘우리 회사 영업팀이 외부에서도 쓰면 좋겠는데?’ → 답: ‘옵션 — (1) VPN 통한 사내 접근. (2) DMZ + 프록시 + 강력한 인증. (3) 일부 기능만 외부 노출. (1)이 가장 단순·안전.’

Q

예상 청중 질문 3: ‘우리 회사 사내망·DMZ 잘 설계됐는지 어떻게 알지?’ → 답: ‘IT부에 ‘우리 회사 네트워크 도면 보여줘’ 요청. 3구역 명확하면 OK, 모호하면 위험. 외주 보안 진단 — 약 200~500만 원에 점검 가능.’

TIP

강사 함정 — 방화벽·VPN 깊은 디테일 X: ‘우리 회사가 어디에 AI 돌지’ 메시지만.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 3구역 도면. 1~3분 각 구역 1분씩. 3~4분 DMZ 사고 + VPN. 4~5분 결정 기준. 5~6분 청중 질문. 도면 칠판에 크게.

BRIDGE

“구역 정해졌다면 — 그 사이 ‘문지기’가 필요. ‘Reverse Proxy + HTTPS’ 첫 번째 보안 장치입니다.”

REVERSE PROXY

Reverse Proxy + HTTPS — 첫 번째 문지기

■ 불변층 — 모든 자체 호스팅의 표준

- ★ Reverse Proxy(역방향 프록시) — 사용자 요청을 받아 ‘안쪽 서버로 전달’하는 중간 서버
- ★ 역할 — (1) 외부 차단·인증, (2) HTTPS 처리, (3) 부하 분산, (4) 로그 집중
- ★ 한국 표준 — Nginx (무료, 가장 흔함) 또는 Cloudflare (DDoS 방어 + CDN)
- ★ HTTPS 풀이 — 통신 암호화 + 서버 신원 확인. 자물쇠 아이콘 = HTTPS
- ★ 인증서 — Let's Encrypt 무료 인증서 90일 갱신 또는 회사 자체 인증서
- ★ 자체 호스팅 안 돌 시 — 사용자 요청 직접 받음 + 평문 통신 = 공격 표적

SAY

“네트워크 도면 그렸다면 — 첫 번째 보안 장치 ‘Reverse Proxy’입니다. 줄여서 ‘리버스 프록시’. 자체 호스팅 표준.”

SAY

“프록시 = 중간자. ‘Reverse Proxy’ = ‘안쪽 서버 대신 사용자 요청을 받는 중간 서버’입니다. 비유 — 회사 안내 데스크. 직원이 자기 방에 손님 직접 안 받음 — 1층 안내데스크가 손님 받고 직원에게 안내.”

SAY

“역할 4가지. (1) 외부 차단·인증 — 안 인증된 사용자 차단. (2) HTTPS 처리 — 통신 암호화. (3) 부하 분산 — AI 서버 여러 대 있을 때 분배. (4) 로그 집중 — 모든 요청 기록.”

SAY

“한국 표준 — Nginx(엔진엑스) 또는 Cloudflare(클라우드플레어). Nginx는 무료 + 사내 설치. Cloudflare는 클라우드 서비스로 DDoS 방어 + CDN 추가. 둘 다 가능 — 사내 직원만 쓰면 Nginx, 외부 노출이면 Cloudflare 권장.”

SAY

“HTTPS — 통신 암호화. 자물쇠 아이콘 = HTTPS. 풀어 — ‘사용자 PC → AI 서버’ 사이 데이터를 암호화. 중간에 누가 가로채도 못 봄. 인증서 필요 — Let's Encrypt 무료 90일 갱신 또는 회사 자체.”

STORY

Nginx 출처. 러시아 개발자 2004 시작. 현재 ‘웹서버 1위’ (W3Techs 통계). 무료 + 오픈소스. URL: nginx.org. 한국 자체 호스팅 90%+가 Nginx 사용.

STORY

Let's Encrypt 출처. Internet Security Research Group 2014 시작. 무료 HTTPS 인증서 발급. 90일 유효, 자동 갱신. URL: letsencrypt.org. 전 세계 HTTPS 사이트 50%+ 사용.

STORY

Cloudflare 출처. 미국 회사 2009 시작. CDN + DDoS 방어 + Reverse Proxy. 무료 등급도 강력. 한국에서도 인기. URL: cloudflare.com. 사내 직원만 쓰면 Nginx, 외부 노출 + DDoS 우려면 Cloudflare.

NOTE

★ 강사 핵심 배경지식 — ‘프록시’ vs ‘Reverse Proxy’ 차이: 둘 다 중간자. ‘Forward Proxy’ = 사내 사용자 → 외부 인터넷 중간자. 직원이 인터넷 차단 사이트 우회 같은. ‘Reverse Proxy’ = 외부 사용자 → 사내 서버 중간자. 우리 AI 서버 보호 역할. 자체 호스팅에서 ‘Reverse Proxy’가 표준.

NOTE

강사 배경지식 — Nginx 일상 명령 (강사 대응용): (1) ‘systemctl status nginx’ — 작동 상태. (2) ‘nginx -t’ — 설정 문법 검증. (3) ‘systemctl reload nginx’ — 설정 새로 적용. (4) ‘tail -f /var/log/nginx/access.log’ — 실시간 요청 로그. (5) ‘tail -f /var/log/nginx/error.log’ — 에러. 5개 명령으로 일상 운영.

NOTE

강사 배경지식 — HTTPS 인증서 3종류: (1) Let's Encrypt — 무료, 90일, 자동 갱신, 일반 사용. (2) 회사 인증서 — 사내 전용. 자체 발급 ‘CA’ 운영. (3) 상용 인증서 — Sectigo·DigiCert 등에서 구입. 연 10만 원~. EV(녹색 자물쇠) 옵션. 자체 호스팅은 (1) 또는 (2) 표준.

NOTE

강사 배경지식 — 자체 호스팅에 Reverse Proxy 없으면: (1) AI 서버가 직접 외부 요청 받음 — 공격 표적. (2) HTTPS 없음 — 통신 평문 가로채기. (3) 로그 분산 — 사고 추적 어려움. (4) 부하 분산 X — AI 서버 다중화 시 처리 어려움. 사실상 ‘초보자 함정 2위’ — 1위는 ‘Docker 없이 설치’.

Q

예상 청중 질문 1: ‘Nginx 설치 어렵나?’ → 답: ‘기본 설치 — apt install nginx 한 줄. 설정 파일 작성이 약간 학습 필요 — 1주 학습. 한국어 튜토리얼 많아 따라하기 가능. IT부 1주 학습으로 충분.’

Q

예상 청중 질문 2: ‘Cloudflare 무료 쓸 만한가?’ → 답: ‘무료도 충분 — DDoS 방어 + 기본 CDN + HTTPS 무료. 단 (1) 모든 트래픽이 Cloudflare 거침 (데이터 미국 회사 거침). (2) 고급 기능은 유료. 사내 직원만 사용은 Nginx, 외부 노출은 Cloudflare 검토.’

Q

예상 청중 질문 3: ‘Let's Encrypt 90일 갱신 번거롭지 않나?’ → 답: “certbot’ 도구로 자동 갱신 — 90일마다 자동. 1회 설정 후 영원히 자동. 번거롭지 않습니다.’

TIP

강사 함정 — Nginx 설정 디테일 X: ‘우리 IT가 설정 + 우리는 결정만’ 분리.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘프록시 = 중간자’ 비유. 1~2분 4가지 역할. 2~3분 Nginx·Cloudflare. 3~4분 HTTPS·인증서. 4~5분 ‘없으면 어떻게 됨’. 5~6분 청중 질문. 안내데스크 비유 적극.

BRIDGE

“프록시·HTTPS 알았다면 — 더 강력한 인증. ‘mTLS(상호 인증)’입니다.”

mTLS

mTLS — 양쪽 신분증 확인

■ 불변증 — 사내 서비스 사이 강력한 인증

- 서버만 신분증 (일반 HTTPS) — 사용자(브라우저)가 서버 신분증(인증서) 확인. 서버 입장에서는 ‘사용자 정확히 누군지’ 모름. 비밀번호로 사용자 확인 — 별도.
- 양쪽 신분증 (mTLS (상호 인증)) — ‘mutual TLS’. 서버 + 사용자(또는 사내 서비스) 둘 다 신분증(인증서). 비밀번호 없이도 신원 확인. 사내 서비스 사이 통신·채택 직원 인증에 강력.

🕒 6분 · mTLS

SAY

“두 번째 보안 장치 — mTLS. 줄여 ‘엠티엘에스’. 약간 어려운 개념인데 — 비유로 쉽게.”

SAY

“일반 HTTPS — 사용자가 ‘서버 신분증’만 확인. 자물쇠 아이콘 — ‘이 서버가 진짜 카카오’ 같은 검증. 그런데 서버 입장에서는 ‘이 사용자가 누군지’ 모름. 비밀번호로 사용자 확인 — 별도 단계.”

SAY

“mTLS — ‘mutual TLS(상호 TLS)’. ‘양쪽이 신분증’. 서버 + 사용자(또는 사내 서비스) 둘 다 인증서. 비밀번호 없이도 ‘이 사용자는 김 사장’임이 자동 인증.”

SAY

“쓰임 — (1) 사내 서비스 사이 통신. AI 서버와 DB 서버 사이 자동 인증. ‘외부 침입자’가 사내 들어와도 인증서 없으면 차단. (2) 재택 직원 인증. VPN + mTLS = ‘이 PC는 김 직원의 회사 노트북’ 자동 확인.”

SAY

“실전 — 사내 서비스 사이는 ‘반드시 mTLS’ 표준. 사용자(직원) 접근은 ‘일반 HTTPS + 비밀번호 + 2FA’가 더 일반적. mTLS는 ‘서비스 to 서비스’ 우선.”

STORY

TLS·SSL 풀이. TLS = Transport Layer Security. SSL = Secure Sockets Layer (구버전). 둘 다 ‘통신 암호화 + 인증’ 표준. ‘TLS 1.3’이 현재 권장 버전. HTTPS의 ‘S’가 ‘SSL/TLS’를 의미.

STORY

Zero Trust 풀이. ‘아무도 안 믿는다’ 보안 원칙. 기존 — ‘사내망 안은 안전’. Zero Trust — ‘사내망도 안전 X’. 모든 통신 인증 + 암호화. mTLS = Zero Trust의 핵심 기술. 구글·Cloudflare·Microsoft 등 채택. 한국도 ‘사내망 신뢰’ 흔들리는 사고 후 도입 증가.

STORY

한국 mTLS 도입 사례 (강사 대응용). 카카오·네이버 같은 대형 IT 회사는 사내 서비스 전반 mTLS 표준. 일반 회사는 ‘AI 서버·DB·로깅 서버’ 같은 핵심 인프라부터 도입. 본 강좌 9편(보안)에서 자세히.

NOTE

★ 강사 핵심 배경지식 — mTLS 동작 흐름: (1) 사내 서비스 A가 사내 서비스 B에 요청. (2) B가 ‘너 신분증 줘’ 응답. (3) A가 자기 인증서 전달. (4) B가 ‘우리 사내 CA(인증서 발급기관)’에 ‘이 인증서 유효’ 확인. (5) 동시에 A도 B 인증서 확인. (6) 양쪽 OK면 통신. 추가 검증 — 보안 강해짐.

NOTE

강사 배경지식 — ‘인증서’의 의미: 디지털 신분증. ‘이 사람·서비스는 ___이다’를 신뢰할 수 있는 발급기관(CA)이 보증. 비유 — 주민등록증. 정부가 발급. 만료기간 있음. 위조 어려움. 디지털 인증서도 동일 — 사내 CA가 발급, 만료기간(보통 1년), 위조 거의 불가능.

NOTE

강사 배경지식 — 사내 CA 구축: 자체 호스팅에 mTLS 적용 시 ‘사내 인증서 발급기관(CA)’ 필요. 무료 도구 — HashiCorp Vault, Smallstep CA, OpenSSL 직접. ‘사내 IT가 1주일 학습 후 설치 가능’ 수준. 본 강좌 9편에서 자세히.

NOTE

강사 배경지식 — 2FA(2단계 인증) 풀이: 비밀번호 + 추가 인증(SMS·앱). ‘비밀번호 알아도 핸드폰 없으면 못 들어옴’. 일반 직원 인증의 표준. mTLS와 다름 — mTLS는 ‘기기’ 인증, 2FA는 ‘사람’ 인증. 둘 다 같이 가능.

Q

예상 청중 질문 1: ‘mTLS 설치 어렵지 않나?’ → 답: ‘1단계는 어려움 — 사내 CA 설치 + 인증서 발급. 1회 설치 약 1주 학습. 이후는 ‘새 서비스 인증서 발급’ 정도. 자동화 도구(Cert-Manager 등)로 줄일 수 있음.’

Q

예상 청중 질문 2: ‘우리는 작은 회사, mTLS 필요?’ → 답: ‘직원 10명 이하 + 자체 호스팅 1대면 단순 HTTPS + 비밀번호 + 2FA로 충분. ‘서비스 to 서비스 통신’ 여러 대 운영하기 시작하면 mTLS 검토.’

Q

예상 청중 질문 3: ‘VPN으로 충분한데 mTLS도?’ → 답: ‘VPN = 외부→사내 통신 보호. mTLS = 사내 서비스 사이 통신 보호. 둘 다 보호. ‘VPN만’이면 — VPN 들어온 침입자가 사내 자유롭게. mTLS도 있으면 — 사내에서도 인증서 필요. 보안 강해짐.’

TIP

강사 함정 — mTLS 기술 디테일 깊게 X: 1단계 ‘mTLS = 양쪽 인증’ 메시지만. 인증서·CA 설치 9편에서.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 비유 — 신분증. 1~3분 일반 HTTPS vs mTLS. 3~4분 사용 시나리오. 4~5분 Zero Trust 트렌드. 5~6분 청중 질문. 신분증 비유 적극.

“인증이 강해졌다면 — 인증된 사용자가 ‘무엇 할 수 있나’ 통제. ‘RBAC(권한 관리)’입니다.”

RBAC

RBAC — 역할 기반 권한

■ 불변증 — ‘누가 무엇 할 수 있나’ 통제

- ★ RBAC = ‘Role-Based Access Control’. ‘역할’별 권한 부여
- ★ 역할 예시 — Admin(관리자), HR(인사팀), Sales(영업팀), General(일반 직원)
- ★ 권한 예시 — 모델 변경, 사용자 추가, 로그 조회, 사내 문서 검색, 챗 가능 여부
- ★ 원칙 — ‘최소 권한’ — 필요한 만큼만. 기본은 ‘아무 권한 없음’
- ★ 한국 표준 — Keycloak (무료 SSO), Okta (유료), Azure AD (Microsoft 사용 회사)
- ★ RBAC 없으면 — 모든 직원이 ‘모든 사내 문서 검색 가능’ 사고 위험

🕒 6분 · RBAC

SAY

“세 번째 보안 장치 — RBAC. ‘Role-Based Access Control’ = ‘역할 기반 권한 통제’입니다. ‘누가 무엇 할 수 있나’ 결정.”

SAY

“역할 예시 — Admin(관리자), HR(인사팀), Sales(영업팀), General(일반 직원). 각 역할마다 권한이 달라요.”

SAY

“권한 예시 — 모델 변경(Admin만), 사용자 추가(Admin), 로그 조회(Admin + 보안팀), 사내 문서 검색(HR은 인사 문서만, Sales는 영업 문서만), 챗 가능 여부(모든 직원). 즉 — 역할 × 권한 매트릭스.”

SAY

“원칙 — ‘최소 권한 원칙(Principle of Least Privilege)’. 직원에게 ‘필요한 만큼만’ 권한. 기본은 ‘아무 권한 없음’. 영업팀에 ‘인사 문서 접근’ 주지 않음. ‘작은 권한 + 필요시 추가’가 정석.”

SAY

“한국 표준 도구 — Keycloak(무료 오픈소스 SSO), Okta(유료), Azure AD(Microsoft 사용 회사). ‘SSO’ = ‘Single Sign-On’ = ‘한 번 로그인 → 모든 사내 시스템 접근’. RBAC + SSO가 한 묶음.”

SAY

“RBAC 없으면 — 모든 직원이 모든 사내 문서 검색 가능. 사고 — ‘영업팀 직원이 임원 연봉 정보 검색’. ‘퇴사자가 영업 노하우 다운로드’. 본 강좌 9편(보안)이 자세하.”

STORY

Keycloak 출처. Red Hat 2014 시작. 현재 오픈소스 SSO 1위. URL: keycloak.org. 무료 + 한국어 지원. RBAC + SSO + 2FA + LDAP 통합. 사내 자체 호스팅 SSO 표준.

STORY

‘최소 권한 원칙’ 출처. Saltzer & Schroeder 1975 논문 ‘The Protection of Information in Computer Systems’. 50년 된 원칙. 핵심 — ‘직무 수행에 필수적인 최소 권한만 부여’. 모든 보안 표준의 기본.

STORY

한국 RBAC 사고 사례 (강사 대응용). 2022 한 대기업 사고 — 사내 챗봇에 RBAC X 설정 → 신입사원이 임원 연봉 정보 검색 → 유출. 6개월간 사내 챗봇 사용 중단. ‘RBAC 처음부터 설계’의 중요성. 본 강좌 9편.

NOTE

★ 강사 핵심 배경지식 — RBAC vs ABAC: RBAC = 역할 기반. ABAC(Attribute-Based) = 속성 기반 (시간·위치·기기 등). RBAC가 더 단순·일반적. ABAC는 더 세밀하지만 복잡. 대부분 회사 ‘RBAC 시작 → 필요시 ABAC 보강’ 패턴. 본 강좌 9편 보안 자세하.

NOTE

강사 배경지식 — SSO 풀이: ‘Single Sign-On’ = ‘1회 로그인 → 모든 사내 시스템’. 직원이 메일·사내 챗봇·DB·CRM 각각 따로 로그인 X. 1회 로그인이면 모두 자동 접근. ‘SSO + RBAC’ 조합이 표준. SSO 없이 사내 시스템 운영 = 직원 비밀번호 10개+ → 약한 비밀번호 + 분실 사고.

NOTE

강사 배경지식 — Active Directory(AD) 풀이: Microsoft의 사내 사용자 관리 시스템. 한국 대기업·중견기업 다수 사용. Azure AD는 클라우드 버전. ‘기존 AD 있음’ 회사는 RBAC을 ‘Azure AD 연동’으로 시작 권장. 새 도구 도입 비용 적음.

NOTE

강사 배경지식 — RBAC 설계 6단계: (1) 역할 목록 작성 — Admin/HR/Sales/Marketing/Dev/General. (2) 권한 목록 작성 — 사내 챗봇, 사내 문서 RAG, 모델 변경 등. (3) 매트릭스 채우기. (4) ‘최소 권한’ 원칙 확인. (5) SSO 도구 설치. (6) 정기 검토 — 6개월마다.

Q

예상 청중 질문 1: ‘우리는 직원 50명. RBAC 필요?’ → 답: ‘50명이면 필요. 30명도 권장. 10명 미만 + 모두 신라면 단순 비밀번호도 OK이지만 — 결국 50명·100명 되면 RBAC 필요. 처음부터 설계가 정석.’

Q

예상 청중 질문 2: ‘우리는 SSO 없는데 시작 어떻게?’ → 답: ‘Keycloak 1주 학습 + 설치. 또는 기존 Active Directory 있으면 연동. Microsoft 365 사용 회사는 Azure AD 자동. 본 강좌 9편 자세히.’

Q

예상 청중 질문 3: ‘인사팀이 영업 데이터 봐야 할 때 임시 권한?’ → 답: “‘임시 권한 부여’ 기능 — Keycloak·Okta·Azure AD 모두 지원. 시간 제한(예: 1일) + 자동 해제 + 감사 로그. ‘영구 권한 부여’ X — 임시.’

TIP

강사 함정 — Keycloak·Okta·Azure AD 비교 디테일 X: ‘RBAC 적용 결정’만. 도구 선택은 IT부.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 RBAC 개념. 1~2분 역할 + 권한 매트릭스. 2~3분 ‘최소 권한 원칙’. 3~4분 Keycloak·SSO. 4~5분 사고 사례. 5~6분 청중 질문. 매트릭스 실전 예시 칠판.

BRIDGE

“RBAC까지 했다면 — 마지막. ‘누가 무엇 했는지 기록’ 감사 로그입니다.”

AUDIT LOG

감사 로그 — 누가 무엇 했는지 기록

■ 불변층 — 사고 추적의 ‘CCTV’

- ★ 감사 로그(Audit Log) — 모든 중요 행위 기록 — 누가·언제·무엇·결과
- ★ 기록 대상 — 로그인, 모델 변경, 사용자 추가, 민감 문서 검색, 외부 송신
- ★ 보관 — 최소 1년 (한국 개인정보보호법 권고), 권장 3년+
- ★ 한국 표준 — ELK Stack (Elasticsearch + Logstash + Kibana) 무료 또는 Datadog 유료
- ★ 자동 알람 — 의심 패턴(새벽 대량 다운로드 등) 발생 시 즉시 알림
- ★ 감사 로그 없으면 — 사고 발생해도 ‘누가 했는지’ 모름 = 같은 사고 반복

🕒 6분 · 감사 로그

SAY

“네 번째 마지막 보안 장치 — 감사 로그(Audit Log). 사고 추적의 ‘CCTV’ 역할입니다.”

SAY

“감사 로그 = 모든 중요 행위 기록. 누가·언제·무엇·결과. 비유 — 회사 CCTV. 무슨 일 일어났을 때 ‘영상 돌려 보기’ 가능. 디지털 세계의 CCTV가 감사 로그.”

SAY

“기록 대상 — (1) 로그인 — 누가·언제·어디서. (2) 모델 변경 — Admin이 새 모델 추가. (3) 사용자 추가/삭제. (4) 민감 문서 검색 — 누가·어떤 검색어. (5) 외부 송신 — 사내 데이터가 외부로 나간 사례.”

SAY

“보관 — 최소 1년 (한국 개인정보보호법 권고). 권장 3년+. ‘사고는 발견까지 평균 6개월+’ — 3년 로그가 안전.”

SAY

“한국 표준 도구 — ELK Stack 무료(Elasticsearch + Logstash + Kibana) 또는 Datadog 유료. ELK는 ‘자체 호스팅’, Datadog는 ‘클라우드 SaaS’. 무료 시작은 ELK, 운영 부담 줄이려면 Datadog.”

SAY

“자동 알람 — 단순 기록만 X. 의심 패턴 자동 감지. 예 — ‘새벽 3시 100MB+ 다운로드’ 시 즉시 슬랙 알림. ‘1명이 1시간 안에 1000건 검색’ 시 알림. 사고 발생 즉시 대응.”

STORY

ELK Stack 출처. Elasticsearch (검색), Logstash (수집), Kibana (시각화) 3개 도구 묶음. 무료 오픈소스. URL: elastic.co. 전 세계 로그 시스템 1위.

STORY

한국 개인정보보호법 ‘접속기록 보관’. 개인정보보호법 제29조·시행령. ‘개인정보처리시스템 접속기록 1년 이상 보관’ 의무. 위반 시 과태료. 자체 호스팅 AI도 개인정보 처리 시 적용. 출처: 개인정보보호위원회 가이드라인.

STORY

사고 발견 평균 시간 (강사 대응용). IBM ‘2023 Cost of Data Breach Report’ — 사고 발견 평균 204일, 봉쇄 평균 73일. 합 9개월. ‘1년 로그’ 최소, ‘3년 권장’ 이유. 감사 로그 없으면 사고 발견 시점에 추적 불가.

NOTE

★ 강사 핵심 배경지식 — 감사 로그가 ‘비즈니스 가치’도 있음: 사고 대응 외에도 (1) 사용자 행동 분석 — 어떤 직원이 어떤 문서 자주 검색. (2) 성능 분석 — 어떤 요청이 느림. (3) 모델 개선 — 어떤 질문에 답 못 함. 로그 = 운영 데이터 + 보안 데이터. 양쪽 활용 가능.

NOTE

강사 배경지식 — 로그 ‘부풀림’ 함정: 모든 행위 다 기록 — 디스크 가득 + 분석 어려움. ‘중요 행위만 기록 + 일반 로그는 1주 보관 후 삭제’ 권장. 디스크 비용·검색 속도 균형. 본 강좌 11편(관리자)에서 자세히.

NOTE

강사 배경지식 — 로그 ‘위·변조 방지’: 침입자가 로그 지우면 추적 X. 방지 — (1) 별도 로그 서버 — 분리 보관. (2) 로그 서명 — 위변조 시 감지. (3) 로그 백업 — 다른 위치 복제. 본 강좌 9편(보안), 10편(백업·재해복구) 자세히.

NOTE

강사 배경지식 — ‘SIEM’ 개념: ‘Security Information and Event Management’. 감사 로그를 자동 분석 + 의심 패턴 감지 + 알람. ELK Stack + 규칙 추가 = 간이 SIEM. 본격 SIEM — Splunk, IBM QRadar 등. 한국 대기업 사용. 중소기업은 ELK + 슬랙 알람으로 시작.

Q

예상 청중 질문 1: ‘우리는 작은 회사인데 감사 로그 필요?’ → 답: ‘10명 이상 + 자체 호스팅이면 필요. 사고 발생 시 ‘누가 한 일’ 추적 못 함 = 같은 사고 반복. ELK Stack 무료 시작.’

Q

예상 청중 질문 2: ‘ELK Stack 설치 어렵나?’ → 답: ‘Docker로 1일 설치 가능. 단 설정 — 1주 학습 필요. 한국어 튜토리얼 많음. 또는 Datadog 클라우드로 ‘운영 부담 X’ 옵션.’

Q

예상 청중 질문 3: ‘직원 사생활 침해?’ → 답: ‘감사 로그는 ‘회사 시스템 사용 행위’ 기록. 회사 시스템은 회사 자산. 단 ‘무엇이 기록되는지’ 직원에게 사전 공지 + 사내 정책 명시 권장. 한국 법규 준수.’

TIP

강사 함정 — ELK·SIEM 디테일 깊이 X: ‘감사 로그 두기 결정’만. 도구·설계 디테일은 9·11편.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘CCTV 비유’. 1~2분 기록 대상 5개. 2~3분 보관 기간 + 법규. 3~4분 ELK·Datadog. 4~5분 자동 알람. 5~6분 청중 질문. 비유와 법규 모두 강조.

BRIDGE

“4가지 보안 장치 다 봤다면 — 사고가 났을 때 대응 4단계 알아두기. 본 강좌 10편의 미리보기.”

INCIDENT RESPONSE

사고 대응 4단계 — 미리 알아두기

■ 불변증 — 10편(백업·DR)의 미리보기

- 1. 탐지 Detect (감사 로그 알람) — 감사 로그·자동 알람·직원 신고로 사고 인지. ‘새벽 3시 대량 다운로드 슬랙 알람’ 같은. 발견까지 평균 6개월+ → 빠른 발견이 핵심.
- 2. 봉쇄 Contain (계정·서버 차단) — 사고 발생 즉시 의심 계정 정지·해당 서버 격리. 확산 차단. ‘침입자가 더 못 움직이게’. 평균 73일 — 단축이 핵심.
- 3. 복구 Recover (백업 복원) — 백업에서 복원. 손상된 데이터·시스템 회복. 본 강좌 10편(백업·재해복구) 자세히. 백업 없으면 복구 불가.
- 4. 학습 Learn (재발 방지) — 사고 원인 분석 → 보안 강화. ‘이번 사고 같은 거 다시 안 일어나게’. 본 강좌 11편 (관리자 운영) 자세히.

🕒 5분 · 사고 대응

SAY

“3강 본문 마지막 — 사고가 났을 때 4단계입니다. 본 강좌 10편(백업·DR)의 미리보기예요.”

SAY

“1단계 탐지. 감사 로그 + 자동 알람 + 직원 신고로 사고 인지. ‘새벽 3시 대량 다운로드 슬랙 알람’ 같은. 평균 발견 시간 6개월+ — 빠른 발견이 핵심.”

SAY

“2단계 봉쇄. 사고 발생 즉시 의심 계정 정지·해당 서버 격리. 확산 차단. ‘침입자가 더 못 움직이게’. 평균 73일 — 단축이 핵심.”

SAY

“3단계 복구. 백업에서 복원. 손상된 데이터·시스템 회복. 본 강좌 10편 자세히. 백업 없으면 복구 불가 — 백업 필수.”

SAY

“4단계 학습. 사고 원인 분석 → 보안 강화. ‘이번 사고 같은 거 다시 안 일어나게’. 본 강좌 11편 자세히.”

SAY

“핵심 메시지 — 사고는 ‘일어날까’가 아니라 ‘언제 일어날까’입니다. 처음부터 4단계 준비. ‘난 사고 안 일어나’ X.”

STORY

사고 대응 4단계 출처. NIST(미국 표준기술연구소) ‘Computer Security Incident Handling Guide’ SP 800-61. URL: nist.gov. 전 세계 사고 대응 표준 프레임워크. 한국 KISA(한국인터넷진흥원)도 동일 기반 가이드.

STORY

한국 KISA 침해사고 대응 가이드. URL: kisa.or.kr. 한국 회사 사고 발생 시 KISA 신고 (개인정보 유출은 의무). 24시간 핫라인 — 118. 자체 호스팅 사고 시 KISA 지원 + 신고.

STORY

‘백업 3-2-1’ 원칙. 본 강좌 10편 미리보기. (1) 3 — 데이터 사본 3개 (원본 + 백업 2개). (2) 2 — 2개 다른 매체 (하드디스크 + 클라우드). (3) 1 — 1개는 오프사이트 (다른 위치). 출처: ISO 표준 + 미국 CISA 가이드.

NOTE

★ 강사 핵심 배경지식 — 사고 대응 ‘플레이북’ 작성: 사고 시점 0초~30분 흐름 미리 문서화. 누가·무엇·어떻게. ‘사고 일어났는데 누가 결정?’ 우왕좌왕 X. 30분 안에 봉쇄. ‘플레이북 없는 사고 = 평균 봉쇄 73일, 플레이북 있는 사고 = 평균 봉쇄 24시간’ (IBM 2023 보고서). 본 강좌 9편(보안), 10편(DR)에서 작성.

NOTE

강사 배경지식 — ‘침해사고 신고 의무’ 한국 법규: 개인정보 유출 시 — 정보주체에 72시간 안 통지, 1,000명 이상 KISA 신고. 위반 시 과태료. 자체 호스팅 AI도 개인정보 처리 시 적용. 본 강좌 9편.

NOTE

강사 배경지식 — ‘외주 사고 대응’ 옵션: 사내 대응 인력 없을 시 외주 ‘DFIR(Digital Forensics and Incident Response)’ 서비스. 한국 — 안랩, 시큐아이, 윈스 등. 사고 발생 시 호출 — 시간당 30~100만 원. 사전 계약 권장 (사고 시 빠른 대응).

NOTE

강사 배경지식 — 사고 대응 시뮬레이션: 분기별 1회 ‘가짜 사고 시뮬레이션’ 권장. 한 직원이 ‘침입자’ 역할, 실제 4단계 작동 확인. 사내 IT 훈련 + 보안 의식 향상. 본 강좌 11편 자세히.

Q

예상 청중 질문 1: ‘사고 대응 인력 사내 없는데?’ → 답: ‘외주 DFIR 사전 계약 권장. 안랩·시큐아이·원스 등 한국 회사. 사고 시 24시간 호출. 단 평시 모니터링은 사내 — 외주 호출은 사고 인지 후.’

Q

예상 청중 질문 2: ‘우리 백업 안 되어 있는데 어쩌나?’ → 답: ‘오늘 즉시 시작. 자체 호스팅 시작 전에 백업 설계 필수. 본 강좌 10편(백업·DR)이 가이드. 3-2-1 원칙 — 사본 3개, 매체 2종, 1개는 다른 위치.’

Q

예상 청중 질문 3: ‘4단계 모두 IT부가 하나? 우리는?’ → 답: ‘IT부가 실행, 의사결정자는 결정. 사고 발생 시 ‘대외 발표 결정’, ‘서비스 중단 결정’, ‘외주 호출 결정’은 사장님·임원. 사전에 결정 권한 미리 정해두기.’

TIP

강사 함정 — 사고 대응 디테일 깊게 X: ‘4단계 인지’만. 10·11편 디테일.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘사고는 언제 일어날까’. 1~3분 4단계 각 30초씩. 3~4분 백업 3-2-1. 4~5분 청중 질문. ‘사고 안 일어나’ 환상 깨주기.

BRIDGE

“3강 마지막 — 실습. 우리 회사 보안 도면 1페이지.”

WORKSHOP 3

실습 — 우리 회사 보안 도면 1페이지

■ 적용 (워크시트)

- ① 네트워크 위치 — 사내망 / DMZ / 외부 중?
- ② Reverse Proxy — Nginx / Cloudflare / 없음?
- ③ 인증 — 단순 비밀번호 / SSO + 2FA / + mTLS?
- ④ RBAC 역할 — 우리 회사 역할 목록 (예: Admin/HR/Sales/General)
- ⑤ 감사 로그 — ELK / Datadog / 없음?
- ★ 다음 액션 — 빠진 항목 IT부에 우선 도입 요청

🕒 9분 · 실습

SAY

“3강 실습 — 보안 도면 5칸 채우기. 1강 인프라 결정서 + 2강 장비 구매서 + 3강 보안 도면 = 자체 호스팅 도입 완전판 3장.”

DO

조별 실습 (5분, 3~4인 1조). 5칸 + 다음 액션. 5칸은 ‘현재 우리 회사 보안’ + ‘앞으로 도입할 것’ 두 단계로 작성.

SAY

“시작 권장 — ‘우리는 첫 자체 호스팅’ 한국 중견기업 — 사내망 + Nginx + SSO + RBAC + ELK = 약 1주~1개월 IT부 작업. 클라우드 옵션 — Cloudflare + Okta + Datadog = 운영 부담 ↓, 비용 ↑.”

Q

발표 요청: “1~2조 발표. 빠진 항목만 한 줄.” → 보통 ‘RBAC 없음’, ‘감사 로그 없음’ 다수. → ‘좋아요. 빠진 항목이 정상. 오늘부터 도입 시작.’

Q

발표 요청 2: “‘5개 모두 갖추’ 조 있나?” → 거의 없음. → ‘대부분 빠진 항목 있어요. 자체 호스팅 시작 전 5개 다 갖추기 권장.’

NOTE

★ 강사 핵심 배경지식 — 보안 도면 5칸 작성 가이드: (1) 위치 — 직원만 → 사내. 외부 협력사 → DMZ. (2) Proxy — 외부 노출 없으면 Nginx. (3) 인증 — 10명 이상 SSO 권장, 사내 서비스 다수 mTLS. (4) RBAC — 5개 역할 정도 우선. (5) 로그 — ELK 시작.

NOTE

강사 배경지식 — 다음 액션 권장 3가지: (1) 보안 도면 1페이지 IT부 전달. (2) ‘빠진 항목’ 우선 도입 — IT부 일정 협의. (3) 외주 보안 진단 검토 — 약 200~500만 원에 점검. 셋 다 1주 안에 가능.

NOTE

강사 배경지식 — 우선순위: 5개 동시 X. 우선순위 — (1) Reverse Proxy + HTTPS — 1주. (2) 감사 로그 — 1주. (3) SSO + RBAC — 2~4주. (4) mTLS — 1~2개월. (5) 사고 대응 플레이북 — 1개월. 약 3개월 본격 운영 준비.

Q

예상 청중 질문 1: ‘우리는 5개 동시 도입 어렵다.’ → 답: ‘동시 X. 우선순위 — Reverse Proxy + 감사 로그 먼저 (1주). SSO + RBAC 그 다음 (2~4주). mTLS는 운영 안정 후 (1~2개월). 단계적.’

Q

예상 청중 질문 2: ‘외주 보안 도입은?’ → 답: ‘권장 — 외주 보안 진단(200~500만 원) + 사내 도입(IT부 작업). 외주만으로는 한계 — 도입은 사내가 해야 운영 가능.’

Q

예상 청중 질문 3: ‘우리는 5개 다 안 됨. 자체 호스팅 포기?’ → 답: ‘옵션 — (1) 5개 다 갖춰서 자체. (2) Managed Agents (자체 호스팅 sandbox) — 일부 운영 Anthropic이 대신. (3) 클라우드 유지. (1) 어려우면 (2) 또는 (3).’

TIP

강사 함정 — ‘완벽 도면 압박’ 금지: 5분에 5칸. 완벽 X. ‘현재 상태 + 도입할 것’ 두 단계.

TIP

강사 진행 팁 — 9분 시간 배분: 0~5분 개별 작성. 5~7분 1~2조 발표. 7~9분 우선순위 + 다음 액션. 우선순위가 핵심 — 5개 동시 X.

WRAP · PART 2

2편 정리 — 인프라 결정 3장

■ 마무리 + 3편 예고

- 1강 — 인프라 결정서 (클라우드 vs 자체 vs 하이브리드, 4질문)
- 2강 — 장비 구매서 (모델·VRAM·GPU·PC·OS·Docker)
- 3강 — 보안 도면 (사내망·Reverse Proxy·인증·RBAC·로그)
- ★ 세 장 합치면 ‘자체 호스팅 도입 완전판’
- ★ 다음 주 액션 — 3장 사장님·임원 검토 → 견적 의뢰 → 도입 일정
- ★ 3편(모델·추론) — 자체 호스팅했다면 어떤 모델·어떻게 최적화

🕒 5분 · 마무리

SAY

“2편 마무리. 3강 동안 ‘인프라 결정서 + 장비 구매서 + 보안 도면’ 세 장이 손에 남았어요. 이 세 장이 ‘자체 호스팅 도입 완전판’이고, 1편의 ‘90일 계획서’와 합치면 ‘AI 도입 마스터 계획’ 4장입니다.”

SAY

“다음 주 액션 3가지. (1) 4장을 사장님·임원께 보고 — 1주 안. (2) 사장님 결정 후 IT부에 견적 의뢰 — 2주 안. (3) 견적 받고 도입 일정 확정 — 1개월 안. ‘완벽 결정 후 시작’ X — ‘60% 결정으로 시작 → 보완’ 정석.”

SAY

“3편 예고 — ‘모델·추론’입니다. 2편이 ‘무엇으로 갈지’였다면 3편은 ‘갔으면 어떤 모델·어떻게 최적화’. Llama·Qwen 비교, Hugging Face·Ollama 사용법, 추론 최적화(vLLM·TensorRT). 본격 자체 호스팅 운영 디테일이에요.”

SAY

“2편 핵심 메시지 한 마디 — ‘자체 호스팅은 99% 회사에 너무 일찍 옵니다. 4질문 답이 ‘예’ 3개+ 일 때 갑니다. 그 외엔 클라우드.’ 솔직히 말씀드려요. 자체 호스팅은 비용 + 시간 + 인력 큰 일.”

Q

발표 요청: “2편 끝나니 ‘우리 회사 인프라 방향’ 한 줄로 말씀하시면?” → 보통 ‘클라우드 시작 → L3에서 하이브리드 검토’. → ‘좋습니다. 정답.’

Q

발표 요청 2: “2편에서 가장 도움 된 부분은?” → 다양. ‘4질문’, ‘VRAM 공식’, ‘RBAC’ 등. → ‘여러분의 가장 도움된 부분이 ‘다음 회의의 출발점.’

NOTE

★ 강사 핵심 배경지식 — 2편 마무리 톤: ‘완벽 결정’ 압박 X. ‘오늘 60% 결정으로 시작 → 진행하면서 보완’ 메시지. 결정 자체보다 ‘결정 회의 시작’이 중요. 청중에게 ‘다음 주 회의 안건에 추가’ 액션.

NOTE

강사 배경지식 — 11편 강좌 전체에서 2편 위치: 11편 중 2편이 ‘인프라’ — 가장 ‘큰 결정’ 편. 1편(왜·어떻게 시작), 2편(인프라). 3편부터는 ‘구체 기술’ — 3편 모델·추론, 4편 챗봇·RAG, 5편 에이전트 기초, 6편 하네스 등. ‘큰 결정 → 구체 기술’ 흐름. 2편 결정이 3편+ 모든 결정의 기반.

NOTE

강사 배경지식 — 2편 청중 다음 행동 예측: (1) ‘클라우드 시작’ 결정 청중 — 사내 결재 + 5명 챗봇 시작. (2) ‘하이브리드 검토’ 청중 — 6개월 클라우드 운영 후 재검토. (3) ‘자체 호스팅 결정’ 청중 — IT부 + 견적 + 1~3개월 도입. 청중별 ‘다음 행동’ 명확히 인지하게.

NOTE

강사 배경지식 — 3편 예고 톤: 3편이 ‘기술 디테일’ 강. 청중 일부에게 부담. ‘3편은 자체 호스팅 결정한 분께 본격 도움 — 클라우드 분은 우리 클라우드 API 어떻게 더 잘 쓸까 부분만 보면 됨’ 안심 메시지.

TIP

강사 함정 — 청중 ‘피로’ 인정: 2편 3강 = 180분. 청중 피곤. ‘다 외우려 X. 워크시트 3장만 갖고 가시면 됨’ 안심.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘3장 정리’. 1~2분 ‘다음 주 액션 3가지’. 2~3분 ‘3편 예고’. 3~4분 ‘핵심 메시지’. 4~5분 청중 발표. ‘완벽 결정 압박 X’ 마무리 톤.

BRIDGE

“2편 끝. 3편 ‘모델·추론’에서 만나요. 청중 여러분 고생하셨습니다.”