

모델·추론 — 어떤 모델 · 어떻게 깔고 · 얼마나 줄일까

1강 무료 LLM 5종 + 2강 한국어 특화 + 3강 추론엔진·양자화 (총 120분)

코스	Course 02 · 사내 AI 구축·운영 종합 가이드
강의	1강(60분) + 2강(60분) + 3강(60분) = 총 180분
대상	IT 담당자·시스템 운영자 (초보자 톤 유지)
URL	visionc.co.kr/ai-solution/academy/build-ai
비밀번호	visioncDown (대소문자 구분)
형식	사내 출강 / 워크숍

INTRO · TITLE

무료 LLM 5종 — 어떤 모델 쓸까

1강 — Llama · Qwen · Mistral · DeepSeek · GPT-OSS

 3분 · 시작·환영

SAY

“반갑습니다. 사내 AI 구축·운영 가이드 3편 ‘모델·추론’입니다. 2편이 ‘어디서 굴릴까(인프라)’였다면 3편은 ‘무엇을 굴릴까(모델)’ + ‘어떻게 굴릴까(추론 엔진)’입니다.”

SAY

“3편 3강 구성. 1강 ‘무료 LLM 5종 비교’ — Llama, Qwen, Mistral, DeepSeek, GPT-OSS. 2강 ‘한국어 특화’ — Solar, EXAONE, KULLM, Bllossom. 3강 ‘추론 엔진·양자화’ — Ollama, vLLM, llama.cpp, TGI. 180분 후 ‘우리 회사 모델 스택 1페이지’가 손에 남습니다.”

SAY

“3편 약속 — 모델 정보는 모두 ‘공식 모델 카드’와 ‘Hugging Face 공식 페이지’ 인용. ‘벤치마크가 1위입니다’ 같은 추상 발언 X. 구체 점수 + 비교 + 한계 명시. 2025년 8월 출시 GPT-OSS까지 반영했어요.”

Q

도입 질문 1: “‘Llama·Qwen·Mistral’ 셋 중 ‘이름은 들어본’ 모델 있는 분 손?” → 보통 Llama만 다수. → ‘좋아요. Llama가 가장 유명. 단 ‘유명한 게 우리 회사에 최선’ X. 오늘 5개 비교하고 ‘우리에게 맞는 것’ 답합니다.’

Q

도입 질문 2: “2편 인프라 결정서에 ‘자체 호스팅 검토’ 나온 분?” → 보통 1/3. → ‘좋습니다. 자체 호스팅 결정분은 3편 1·2강이 핵심. 클라우드 결정 분도 3강 ‘추론 엔진’이 ‘우리가 쓰는 클라우드가 무엇 위에 돌아가는가’ 이해에 도움.’

NOTE

★ 강사 핵심 배경지식 — 3편 청중 구성: 2편 청중과 동일 가정 — IT 담당자 + 의사결정자. 다만 3편은 ‘구체 기술’ 비중 큼. 청중 일부는 ‘기술 디테일 부담’ 느낄 수 있음. 대응 — (1) 비유 적극. (2) ‘외울 것 vs 비교용’ 분리. (3) ‘우리 IT가 깔고 우리는 검토’ 역할 분리.

NOTE

강사 배경지식 — 3편 인용 출처 (1차): (1) Meta Llama 3.3 공식 발표. (2) Alibaba Qwen2.5 기술 리포트. (3) Mistral AI 모델 카드. (4) DeepSeek-V3 기술 리포트. (5) OpenAI gpt-oss 공개. (6) Upstage Solar 기술 리포트. (7) LG EXAONE 3.5. (8) 고려대 KULLM. (9) Blllossom. (10) Ollama, vLLM(PagedAttention 논문), llama.cpp, TGI 공식. (11) LMSYS Chatbot Arena, HuggingFace Korean LLM Leaderboard. 모든 점수 1차 출처.

NOTE

강사 배경지식 — 3편 60분 시간 배분 (1강): 0~3분 인사. 3~6분 학습목표. 6~10분 2편 복습. 10~14분 ‘왜 무료 LLM’. 14~24분 5대 비교표. 24~46분 5개 모델 디테일(각 4~5분). 46~52분 라이선스. 52~58분 실습. 58~60분 마무리.

TIP

강사 함정 — ‘이 모델이 1위’ 단언 금지: 모델은 6개월~1년마다 1위 바뀜. ‘2026년 6월 시점 권장’만. 청중에게 ‘6개월 후엔 다른 답 가능’ 미리 알림.

BRIDGE

“학습 목표 빠르게.”

OBJECTIVES

60분 후, 이 3가지를 한다

- ① 무료 LLM 5종(Llama·Qwen·Mistral·DeepSeek·GPT-OSS)의 차이를 설명한다
- ② 라이선스·상업 이용 가능 여부를 안다
- ③ ‘우리 회사 1순위 모델’을 4질문으로 결정한다

SAY

“60분 후 셋. 첫째, ‘5종 무료 LLM — Llama, Qwen, Mistral, DeepSeek, GPT-OSS — 의 차이를 동료에게 설명’할 수 있게 됩니다. 표면이 아니라 ‘각각의 강점·약점·언제 선택’ 수준.”

SAY

“둘째, 라이선스. ‘무료라고 다 상업 이용 OK’ X. Llama는 OK, EXAONE은 별도 협의, Solar는 비영리만 — 같은 차이가 있어요. 우리 회사가 ‘영리·상업적 이용’인지 확인 후 모델 선택.”

SAY

“셋째, ‘우리 회사 1순위 모델 결정’. 4질문 — 한국어 우선도·코딩 비중·라이선스 제약·GPU 예산 — 으로 단순화. 60분 후 손에 답 1장 남습니다.”

NOTE

★ 강사 핵심 배경지식 — 1강 성공 기준: 청중이 ‘견적 의뢰 시 어떤 모델 명시할지’ 결정 가능. ‘기술 깊이’가 아니라 ‘비교 가능’.

NOTE

강사 배경지식 — 1강 vs 2강 분담: 1강은 ‘글로벌 5종’ (Llama·Qwen·Mistral·DeepSeek·GPT-OSS). 2강은 ‘한국어 특화 4종’ (Solar·EXAONE·KULLM·Bllossom). 합쳐서 9종 — 한국 자체 호스팅 후보 거의 다. 단 결정은 ‘1+2종’ 선택 — 보통 글로벌 1개 + 한국어 1개.

TIP

강사 진행 팁 — 학습 목표 3분 안에 끝. ‘본문이 더 중요’.

BRIDGE

“1강 복습 — 2편에서 결정한 인프라 방향과 연결.”

RECAP · PART 2

2편 복습 — 인프라 결정 3장

■ 불변층 — 2편의 5개 핵심

- 1강 인프라 결정서 — 4질문(데이터·토큰·인력·연속성) → 클라우드/자체/하이브리드
- 2강 장비 구매서 — 모델 $\times$ 0.6GB = VRAM, GPU·PC·OS·Docker 5칸
- 3강 보안 도면 — 사내망·Reverse Proxy·mTLS·RBAC·감사 로그
- ★ 핵심 메시지 — ‘작게 시작 + 보안은 처음부터’
- ★ 3편 위치 — 자체 호스팅 결정 분: 모델 선택. 클라우드 결정 분: 클라우드 모델 이해

🕒 4분 · 2편 복습

SAY

“3편 본문 들어가기 전에 2편 복습 30초씩. 2편을 안 들으신 분도 따라갈 수 있게.”

SAY

“첫째, 1강 ‘인프라 결정서’. 4질문 — 데이터 민감도, 토큰 사용량, 운영 인력, 연속성 요구. 4질문 답 조합으로 클라우드/자체/하이브리드 결정. 95% 한국 중소기업 답 = 클라우드.”

SAY

“둘째, 2강 ‘장비 구매서’. ‘파라미터 $\times$ 0.6GB = VRAM’ 공식. 모델·VRAM·GPU·PC·OS·Docker 5칸. 첫 시작 권장 — 7B + RTX 4070 + 워크스테이션 = 약 200만 원.”

SAY

“셋째, 3강 ‘보안 도면’. 사내망·Reverse Proxy(Nginx)·mTLS·RBAC(Keycloak)·감사 로그(ELK). 자체 호스팅의 5단 안전장치.”

SAY

“2편 핵심 메시지 — ‘작게 시작 + 보안은 처음부터’. 3편 1강은 이 위에 ‘어떤 모델 살까’ 결정.”

SAY

“3편 위치 — 자체 호스팅 결정 분에게는 ‘본격 핵심’. 클라우드 결정 분에게는 ‘우리가 쓰는 ChatGPT·Claude가 무엇 위에 돌아가나’ 이해 + ‘3편 끝 ‘Ollama 한 줄 명령’ 같은 가벼운 자체 도입’ 가이드.”

NOTE

★ 강사 핵심 배경지식 — 2편을 안 들은 청중 대응: 3편만 듣는 분도 있을 수 있음. 이 슬라이드(4분 복습)가 그 분들 대상. 단 ‘2편 워크시트 3장은 회사에 가서 다운로드 받으세요’ 메시지. 2편 자료가 visionc.co.kr/ai-solution/academy/build-ai에 있음.

NOTE

강사 배경지식 — 2편 4질문 답 분포: 한국 회사 분포 추정 — 0~1개 예 70%, 2개 20%, 3개 7%, 4개 3%. 즉 청중 70%가 ‘클라우드만’ 답. 3편 1·2강(모델 선택)이 그들에게 ‘자체 호스팅 시도해볼 수도’ 동기 줄 수 있음 — Ollama 같은 가벼운 도구.

Q

도입 질문: ‘2편 워크시트 3장 작성하신 분 손?’ → 보통 1/3. → ‘좋아요. 작성 못 하신 분도 OK. 오늘 3편이 끝나면 ‘4번째 워크시트 — 모델 스택’ 추가됩니다.’

TIP

강사 진행 팁 — 4분 시간 배분: 0~2분 2편 5개 핵심 30초씩. 2~3분 ‘3편 위치’. 3~4분 청중 동기 부여. 복습이 5분 넘으면 본문 시간 부족.

BRIDGE

“좋습니다. 복습 끝. 본격적으로 — ‘왜 무료 LLM을 우리가 검토하는가’ 질문부터.”

WHY OPEN LLM

왜 무료 LLM? — 클라우드 API vs 오픈소스

■ 불변증 — 두 선택지의 본질

- Claude · ChatGPT · Gemini (클라우드 API) — 비용 토큰당 지불 (월 10~수천만 원). 운영 부담 0. 최고 성능. 데이터 외부 송신. 무료 모델 ‘업그레이드 자동’.
- Llama · Qwen · Mistral 등 (무료 오픈소스 LLM) — 비용 GPU 1회 구매(200~6,000만 원). 운영 부담 큼. 데이터 사내. 모델 업데이트 수동. 파인튜닝 가능 (회사 전용 AI).

SAY

“본문 1번 — 왜 무료 LLM을 우리가 검토하는가입니다.”

SAY

“두 선택지의 본질을 다시 봅니다. 클라우드 API — Claude, ChatGPT, Gemini. 비용 토큰당 지불. 시작 1분에 가능. 운영 부담 0. 단 — 데이터 외부 송신 + 토큰 비용 폭증 시 부담.”

SAY

“무료 오픈소스 LLM — Llama, Qwen, Mistral, DeepSeek, GPT-OSS. 비용 GPU 1회 구매. 운영 부담 큼(2편 3강 보안 다). 데이터 사내 100%. 토큰량 폭증해도 추가 비용 0. 파인튜닝 — ‘회사 전용 모델’ 만들 수 있음.”

SAY

“핵심 — ‘무료 LLM이 더 좋다’ X. ‘우리 4질문 답에 따라 다르다’. 95% 한국 회사는 클라우드 답. 5%는 오픈소스 답. 1~2년 후 토큰량 폭증하면 ‘하이브리드로 진화’.”

STORY

오픈소스 LLM 성능 (강사 대응용). LMSYS Chatbot Arena 2025년 말 — Claude 3.5 Sonnet·GPT-4o·Gemini 1.5 Pro가 상위 1~3위. Llama 3.3 70B·DeepSeek-V3·Qwen2.5 72B가 4~6위. ‘오픈소스가 클라우드 90% 수준에 근접’. 출처: lmarena.ai. 격차는 매년 좁아짐.

STORY

한국 회사 오픈소스 도입 현황 (강사 대응용 추정). 2026년 6월 기준 한국 자체 호스팅 LLM 도입 회사 — 약 5,000개. 그중 90%가 ‘오픈소스’ 사용. 자체 LLM 개발은 삼성·LG·SK·네이버·카카오 정도 — 5~10개. 99% 회사 = 오픈소스 선택.

NOTE

★ 강사 핵심 배경지식 — ‘무료 LLM’의 정확한 의미: 모델 자체는 무료(다운로드·사용). 단 운영 비용 = (1) GPU 구매·전기. (2) IT 인력·외주 MSP. (3) 보안 설계. (4) 파인튜닝 시 추가 GPU. 즉 ‘모델은 무료’ + ‘운영은 유료’. 클라우드와 다른 비용 구조.

NOTE

강사 배경지식 — 오픈소스의 4대 장점: (1) 데이터 사내 — 보안. (2) 비용 폭증 X — 토큰량 무관. (3) 파인튜닝 — 회사 전용. (4) 모델·버전 고정 — 외부 변경 영향 X. 4대 단점: (1) 운영 부담. (2) 성능 클라우드 90%. (3) 모델 업데이트 수동. (4) 새 기능(이미지·음성 등) 늦음.

NOTE

강사 배경지식 — ‘오픈소스’ vs ‘오픈 가중치(open-weight)’: 엄격히는 다른 개념. 진짜 오픈소스 = 코드 + 학습 데이터 + 가중치 모두 공개. 대부분 ‘오픈 LLM’은 ‘오픈 가중치’ — 모델 가중치만 공개, 학습 데이터·코드는 비공개. Llama, Qwen, GPT-OSS 모두 ‘오픈 가중치’. 일반 사용에 차이 X — 둘 다 ‘무료 다운로드 + 사용’ 가능.

NOTE

강사 배경지식 — 클라우드와 자체의 ‘비용 교차점’: 월 200만 원 토큰 비용 = 자체 호스팅 200만 원 GPU 손익 분기 약 12개월. 월 500만 원 = 4~6개월. 월 1,000만 원 = 2~3개월. 우리 회사 토큰량 폭증 시점이 결정점. 본 강좌 2편 1강 ‘토큰 사용량 추정’ 참고.

Q

예상 청중 질문 1: ‘우리는 클라우드 만족하는데 무료 LLM 봐야 하나?’ → 답: ‘지금 만족하면 클라우드 유지. 단 6~12개월 후 ‘토큰 비용 폭증’ 또는 ‘데이터 우려 증가’ 시점에 ‘대안 있음’ 인지가 의미. 오늘은 ‘무료 LLM 정찰’ 정도.’

Q

예상 청중 질문 2: ‘무료 LLM이 ChatGPT만큼 좋은가?’ → 답: ‘약 80~90% 수준. ‘일반 사내 챗봇·문서 RAG’는 충분. ‘세계 최강 추론’ 필요한 일은 클라우드. 도구 두 개 가능 — 일상은 자체, 어려운 건 클라우드.’

Q

예상 청중 질문 3: ‘5년 후 무료 LLM이 클라우드 따라잡나?’ → 답: ‘격차 좁아지지만 따라잡기는 모름. 클라우드가 더 큰 모델·더 빠른 업데이트. 단 ‘무료 LLM이 5년 전 GPT-4 수준’이 되면 사내용으로는 충분. 결국 ‘충분 vs 최강’ 트레이드오프.’

TIP

강사 함정 — ‘무료 = 우리 회사 정답’ 단언 금지: 5% 한국 회사만 자체 호스팅 정답. 95%는 클라우드. ‘우리는 5%인지 95%인지’ 4질문 확인.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 두 선택지 비교. 1~2분 4대 장점·단점. 2~3분 비용 교차점. 3~4분 ‘오픈소스 vs 오픈 가중치’ 풀이. 4~5분 청중 질문. ‘무료지만 운영은 유료’ 메시지 강조.

BRIDGE

“오픈소스 선택했다면 — 어떤 모델? 5종 비교부터.”

5 LLM COMPARE

★ 5대 무료 LLM 한눈에 비교

■ 가변층 — 2026.6 기준, 매년 새 모델

- Llama 3.3 Meta · 70B · 가장 표준 — 한국어 ‘ 좋음’, 코딩 ‘ 좋음’, 사례·튜토리얼 1위. Apache-like 라이선스(7억 사용자 이하 상업 OK). 사내 챗봇·RAG 표준 시작점.
- Qwen 2.5 Alibaba · 7B~72B · 한국어·코딩 강점 — 한국어 ‘ 훌륭’ (Llama보다 약간 우수). 코딩 강함. Apache 2.0 (완전 자유). 한국 회사 자체 호스팅 가장 많이 선택.
- Mistral / Mixtral Mistral AI(프랑스) · 7B + MoE 8x7B — 유럽발. 경량(7B)·MoE(혼합 전문가)로 효율 강점. 한국어 ‘ 준수’. Apache 2.0. 작은 GPU에서 ‘ 체감 큰 모델 ’ 가능.
- DeepSeek V3 DeepSeek(중국) · 671B MoE · 가성비 1위 — 추론·수학·코딩 강점. 671B MoE(활성 37B). 한국어 ‘ 좋음’. MIT 라이선스(완전 자유). 본격 RAG·코딩에서 GPT-4 근접.
- GPT-OSS OpenAI · 20B·120B · 2025.8 신규 — OpenAI 첫 오픈 가중치 모델. 영어·추론 강점. 한국어 ‘ 준수’. Apache 2.0. 신규라 사례 적음. 검토 단계.

⌚ 6분 · 5종 비교

SAY

“5대 모델 한눈에. 표 1장으로 결정의 핵심.”

SAY

“Llama 3.3 — Meta. 70B. ‘세계 표준’. 한국어·코딩 ‘ 좋음’, 사례·튜토리얼 1위. 단 라이선스 — ‘7억 사용자 이하 회사만 상업 OK’ 제한(대부분 회사 해당). 한국 자체 호스팅 ‘기본 선택’.”

SAY

“Qwen 2.5 — Alibaba. 7B에서 72B까지 다양한 크기. 한국어 ‘ 훌륭’ — Llama보다 약간 우수. 코딩 강함. Apache 2.0 라이선스 — 완전 자유. 한국 회사 자체 호스팅 ‘가장 많이 선택’ 추세.”

SAY

“Mistral / Mixtral — 프랑스 Mistral AI. Mistral 7B는 ‘경량 표준’. Mixtral 8x7B는 ‘MoE(혼합 전문가)’ — 작은 GPU에서 ‘체감 큰 모델’ 가능. 한국어 ‘준수’ — Llama·Qwen만큼은 X. Apache 2.0.”

SAY

“DeepSeek V3 — 중국. 671B MoE 모델 — 표면 거대하지만 ‘활성 37B’만 사용. 추론·수학·코딩에서 GPT-4 근접. 한국어 ‘ 좋음’. MIT 라이선스 — 완전 자유. 가성비 1위.”

SAY

“GPT-OSS — OpenAI 2025.8 출시. ‘OpenAI 첫 오픈 가중치 모델’. 20B와 120B 두 크기. 영어·추론 강점. 한국어 ‘준수’. Apache 2.0. 신규라 사례 아직 적음.”

STORY

Llama 3.3 출처. Meta AI 'Introducing Llama 3.3' 2024-12 발표. URL: ai.meta.com/blog/llama-3-3-70b. ‘기존 405B와 비슷한 성능을 70B에 압축’. 라이선스 — Llama 3 Community License(7억 활성 사용자 이하 상업 사용 가능). 거의 모든 한국 회사 해당.

STORY

Qwen 2.5 출처. Alibaba Cloud 'Qwen2.5 Technical Report' 2024-09. URL: qwenlm.github.io. 0.5B/1.5B/3B/7B/14B/32B/72B 다양한 크기. 한국어 능력 — Hugging Face Korean LLM Leaderboard 에서 Llama 3.1 70B 상회 (약 +3~5점).

STORY

Mistral·Mixtral 출처. Mistral AI 공식. URL: mistral.ai. Mistral 7B (2023-09) — ‘7B 모델의 표준’. Mixtral 8x7B (2023-12) — MoE 첫 대중화. 유럽발 오픈 LLM의 자존심. Apache 2.0 완전 자유.

STORY

DeepSeek-V3 출처. DeepSeek 'DeepSeek-V3 Technical Report' 2024-12. URL: github.com/deepseek-ai. 671B 총 파라미터, 37B 활성. 학습 비용 약 \$560만 — GPT-4의 1/20 수준. ‘가성비 혁명’. 코딩·수학 벤치마크 GPT-4 근접 또는 상회.

STORY

gpt-oss 출처. OpenAI 'Introducing gpt-oss' 2025-08. URL: openai.com/index/introducing-gpt-oss. OpenAI 첫 오픈 가중치 모델. 20B와 120B 두 크기. Apache 2.0. 'OpenAI도 오픈 가중치 트렌드 참여' 의미. 단 2025-08 신규라 한국 회사 도입 사례 아직 적음.

NOTE

★ 강사 핵심 배경지식 — '선택 시작점' 권장: 한국 회사 자체 호스팅 첫 도입 — 'Qwen 2.5 7B 또는 14B + Ollama' 가장 권장. 이유 — (1) 한국어 1위, (2) Apache 2.0 자유, (3) 크기 옵션 풍부, (4) Ollama 한 줄 설치. 6개월 운영 후 '13B → 32B 또는 72B 업그레이드' 결정.

NOTE

강사 배경지식 — MoE(Mixture of Experts) 풀이: '여러 전문가 모델 중 일부만 사용' 아키텍처. 예 — Mixtral 8x7B는 '8개 7B 모델 + 라우터'. 입력에 따라 8개 중 2개만 활성화 → 활성화 14B 분량. 메모리는 8x7B = 56B 필요 하지만 속도는 14B 수준. '대형 모델의 효율' 패턴. DeepSeek V3, Qwen 2.5도 일부 MoE.

NOTE

강사 배경지식 — 5대 모델 VRAM 요구 (Q4 양자화 기준): (1) Llama 3.3 70B → 42GB (4090×2 또는 H100). (2) Qwen 2.5 7B → 5GB, 14B → 9GB, 32B → 19GB, 72B → 43GB. (3) Mistral 7B → 5GB. (4) DeepSeek V3 → 약 380GB (대형 GPU 8장 또는 H100×4). (5) GPT-OSS 20B → 13GB, 120B → 72GB. '작은 모델은 작은 GPU' 원칙.

NOTE

강사 배경지식 — 5대 모델 한국 회사 도입 사례: (1) Llama — 대기업 R&D 절반, 사례 다수. (2) Qwen — 한국어 강점으로 중견기업 사이 인기 급증. (3) Mistral·Mixtral — 일부 IT 회사. (4) DeepSeek — 코딩 중심 회사 (특히 개발팀). (5) GPT-OSS — 2025.8 출시라 대기업 검토 단계.

Q

예상 청중 질문 1: '우리는 첫 선택 무엇?' → 답: "Qwen 2.5 7B + Ollama" 강력 추천. 이유 — 한국어 1위, 라이선스 자유, 설치 한 줄, 7B는 GPU 부담 적음. 6개월 운영 후 14B·32B 업그레이드 검토.'

Q

예상 청중 질문 2: '5개 다 깔아서 비교?' → 답: '권장 X. 첫 도입은 1개 선택 + 운영 학습. 5개 동시 깔면 운영 부담 5배 + 결정 미루기. 1개 6개월 → '우리에게 부족한 부분' 파악 → 그 부분 잘하는 모델로 갈아타기.'

Q

예상 청중 질문 3: ‘DeepSeek는 중국 회사라 보안 걱정.’ → 답: ‘좋은 지적. 모델 자체는 ‘다운로드해서 사내 사용’이라 ‘중국 회사로 데이터 송신’ X. 단 ‘모델에 백도어 가능성’ 우려는 있어요. 보안 우려 강하면 Llama·Qwen 권장.’

TIP

강사 함정 — 5개 비교 표를 ‘외우라’ X: ‘우리에게 맞는 1개’ 결정만. 청중에게 ‘외우려 하지 마세요’ 안심.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 5개 한눈에. 1~2분 Llama·Qwen 강조 (가장 흔한 선택). 2~3분 Mistral·DeepSeek. 3~4분 GPT-OSS (신규). 4~5분 ‘첫 도입 권장 Qwen 7B’ 메시지. 5~6분 청중 질문.

BRIDGE

“5개 비교했다면 — 각 모델 더 디테일하게. 첫 번째 Llama 3.3.”

LLAMA 3.3

Llama 3.3 — Meta · 가장 표준

■ 불변층 — Llama가 ‘표준’인 이유 + ■ 가변층 — 2026.6 사양

- ★ 70B 모델 (★ 8B·1B·3B 더 작은 옵션도)
- ★ 한국어 능력 ‘ 좋음 ’ — Hugging Face Korean LLM Leaderboard 상위권
- ★ 라이선스 — Llama 3 Community License (월 활성 사용자 7억 이하 회사 상업 OK)
- ★ 사례·튜토리얼 1위 — 한국어 가이드 풍부
- ★ Ollama·vLLM·llama.cpp 모두 1순위 지원
- ★ 단점 — 라이선스 ‘완전 자유’ X. 7억 사용자 넘는 빅테크는 별도 협의

🕒 4분 · Llama 3.3

SAY

“5대 모델 첫 번째 — Llama 3.3입니다. 가장 유명. ‘세계 표준’ 위치.”

SAY

“핵심 사양 — 70B 모델이 주력. 더 작은 옵션도 있어요 — Llama 3.1 8B (일반 사내 챗봇), Llama 3.2 1B·3B (모바일·임베디드). 70B는 ‘본격 사내 AI’, 8B는 ‘일반 사내 챗봇’.”

SAY

“한국어 능력 ‘ 좋음’. Hugging Face Korean LLM Leaderboard에서 상위권 — Qwen 2.5와 비슷한 수준. 일반 사내 사용에 충분.”

SAY

“라이선스 — ‘Llama 3 Community License’. ‘월 활성 사용자 7억 이하’ 회사 상업 이용 OK. 한국 거의 모든 회사 해당. 빅테크(Microsoft·Google·Apple) 같은 7억+ 회사는 별도 협의 — 즉 ‘완전 자유’ 라이선스는 아님.”

SAY

“강점 — 사례·튜토리얼 1위. 한국어 가이드 풍부. Ollama·vLLM·llama.cpp 모두 1순위 지원. ‘처음 시작’에 가장 안전.”

STORY

Llama 3.3 70B 디테일. 2024-12-06 발표. ‘기존 Llama 3.1 405B와 비슷한 성능을 70B에 압축’. 학습 데이터 15조 토큰+. 컨텍스트 128K(한 번에 128K 토큰 처리 가능). URL: ai.meta.com/blog/llama-3-3-70b.

STORY

Llama 3 라이선스 풀이 (강사 대응용). Llama 3 Community License Agreement. 핵심 조항 — (1) 월 활성 사용자 7억 이하 회사 상업 사용 무료. (2) 모델 이름 ‘Llama 3’ 표기 의무. (3) ‘Llama 3 출력’ 사용한 다른 모델은 ‘Llama 3’ 표기 + 라이선스 준수. (4) ‘인종·성·정치 차별 등 금지 정책’ 준수 의무. URL: llama.com/llama3/license.

STORY

한국 Llama 도입 사례 (강사 대응용). 카카오·네이버·LG가 Llama 기반 사내 모델 운영. SK·롯데도 검토 사례. 중견기업 — 사내 챗봇 + RAG에 Llama 8B 또는 70B. ‘처음 시작’에 가장 흔한 선택.

NOTE

★ 강사 핵심 배경지식 — Llama가 ‘표준’인 이유 5가지: (1) Meta가 ‘오픈 LLM 운동’의 선구. (2) 사례·튜토리얼 1위. (3) 모든 추론 엔진(Ollama·vLLM·llama.cpp·TGI) 1순위 지원. (4) Hugging Face 다운로드 1위. (5) 파인튜닝 도구·데이터셋 풍부. ‘우리도 Llama로 시작’이 한국 자체 호스팅의 정석.

NOTE

강사 배경지식 — Llama 1B·3B (모바일·임베디드): 2024-09 Llama 3.2 발표 시 1B·3B 추가. 노트북·모바일에서도 실행 가능. (1) 모바일 AI 비서. (2) IoT 디바이스. (3) ‘오프라인 챗봇’. 한국 자체 호스팅 본격에는 부적합 — 1B는 한국어 자연스러움 약함. 8B 또는 70B 권장.

NOTE

강사 배경지식 — Llama 3.1 vs 3.2 vs 3.3 차이: (1) 3.1 (2024-07) — 8B·70B·405B 본격. (2) 3.2 (2024-09) — 1B·3B 작은 모델 + 비전(이미지) 모델. (3) 3.3 (2024-12) — 70B 성능 강화. ‘3.3은 3.1 405B와 비슷한 성능’. 신규 70B만 출시 — 8B는 3.1 그대로 사용 권장.

NOTE

강사 배경지식 — Llama 라이선스의 함정: 한국 회사 99% ‘7억 사용자 이하’ 해당 → 상업 사용 OK. 단 ‘Llama 출력을 다른 모델 학습에 사용’ 시 그 모델도 ‘Llama 3’ 표기 + 라이선스 의무. 즉 ‘Llama로 우리 모델 만든 후 Llama 표기 안 하기’ X. 본 강좌 9편 라이선스 자세히.

Q

예상 청중 질문 1: ‘우리는 첫 시작인데 70B 70GB+ 너무 큼.’ → 답: ‘Llama 3.1 8B 권장. VRAM 5GB. RTX 4070도 OK. 한국어 ‘준수’. 본격은 6개월 후 70B 업그레이드’ 패턴.’

Q

예상 청중 질문 2: ‘Llama vs Qwen 사이에서 결정?’ → 답: ‘한국어 욕구 강하면 Qwen, 사례·도구 우선이면 Llama. 둘 다 ‘좋은’ 수준. 첫 도입 ‘Qwen 7B’, 사례 보고 안심이 우선이면 ‘Llama 8B’.’

Q

예상 청중 질문 3: ‘Llama 405B 안 쓰나?’ → 답: “너무 큼 + 새 70B가 비슷한 성능’. 405B는 VRAM 250GB+ 필요 — H100 4~8장. 한국 회사 비현실. 70B로 충분.’

TIP

강사 함정 — Llama 라이선스 자세한 디테일 X: ‘7억 사용자 이하면 OK’ 메시지만. 자세한 건 9편 보안·법무 편.

TIP

강사 진행 팁 — 4분 시간 배분: 0~1분 ‘세계 표준’ 메시지. 1~2분 사양·라이선스. 2~3분 강점·약점. 3~4분 청중 질문. ‘처음 시작에 가장 안전’ 강조.

BRIDGE

“Llama 봤다면 — 한국어 더 잘하는 Qwen입니다.”

QWEN 2.5

Qwen 2.5 — Alibaba · 한국어 · 코딩 강점

■ 불변층 — Qwen이 ‘한국어 1위’인 이유 + ■ 가변층 — 모델 크기

- ★ 0.5B / 1.5B / 3B / 7B / 14B / 32B / 72B — 가장 풍부한 크기 옵션
- ★ 한국어 능력 ‘훌륭’ — Llama 3.3 70B와 동급 또는 약간 우수
- ★ 코딩 ‘우수’ — Qwen2.5-Coder 별도 모델
- ★ 라이선스 — Apache 2.0 (3B 미만) + Qwen 자체 라이선스 (3B+, 상업 OK)
- ★ Hugging Face 다운로드 급증 — 2025년 자체 호스팅 1위 추세
- ★ 한국 회사 자체 호스팅 가장 많이 선택 (한국어 + 자유 라이선스)

🕒 4분 · Qwen 2.5

SAY

“두 번째 — Qwen 2.5. Alibaba의 모델인데 한국어·코딩 강점으로 한국에서 인기 급증.”

SAY

“핵심 사양 — 크기 옵션 7개. 0.5B에서 72B까지. ‘가장 풍부한 크기’. 우리 GPU 사양에 맞춰 정확한 선택 가능.”

SAY

“한국어 능력 ‘훌륭’ — Hugging Face Korean LLM Leaderboard에서 Llama 3.3 70B와 동급 또는 약간 우수. ‘한국어 1위’ 위치.”

SAY

“코딩 ‘우수’ — Qwen2.5-Coder 별도 모델 존재. 7B Coder는 GPT-3.5 코딩 능력 근접. 개발팀 도입 시 강점.”

SAY

“라이선스 — 3B 미만 모델은 Apache 2.0(완전 자유). 3B+ 모델은 ‘Qwen 자체 라이선스’ — 상업 사용 OK, 단 ‘월 1억 활성 사용자 이상’ 회사는 협의. 한국 99% 회사 해당 X.”

SAY

“2025년 한국 자체 호스팅 트렌드 — Qwen이 ‘1위 후보’로 급부상. 한국어 + 코딩 + 라이선스 자유 + 다양한 크기. 본 강좌 추천 시작점.”

STORY

Qwen 2.5 디테일. 2024-09 발표. 0.5B/1.5B/3B/7B/14B/32B/72B. 학습 데이터 18조 토큰. 컨텍스트 128K. URL: qwenlm.github.io. Hugging Face 2024년 4분기 다운로드 1위.

STORY

Qwen 한국어 벤치마크 (강사 대응용). Hugging Face Open Korean LLM Leaderboard 2025년 초 — Qwen2.5 72B가 1~2위 차지. Llama 3.3 70B와 0.5~1.5점 차이로 우세. ‘한국어 자연스러움’ 정성 평가도 우수. URL: huggingface.co/spaces/upstage/open-ko-llm-leaderboard.

STORY

Qwen2.5-Coder 디테일. Alibaba 공식 2024-11 발표. URL: qwenlm.github.io/blog/qwen2.5-coder-family. 1.5B/7B/14B/32B 크기. 코딩 벤치마크 HumanEval에서 GPT-4o 근접. 개발팀 자체 호스팅 시 ‘코딩 어시스턴트’로 권장.

STORY

한국 Qwen 도입 사례 (강사 대응용). 일부 중견 IT 회사가 ‘Llama → Qwen 2.5 전환’ 진행. 이유 — 한국어 자연스러움 + 라이선스 자유. 사내 챗봇·RAG·코딩 어시스턴트 3가지 용도.

NOTE

★ 강사 핵심 배경지식 — Qwen 라이선스 디테일: (1) Qwen2.5 0.5B/1.5B — Apache 2.0 완전 자유. (2) Qwen2.5 3B/7B/14B/32B — Qwen License (상업 OK, 월 1억 활성 사용자 미만). (3) Qwen2.5 72B — Qwen License. 한국 회사 99% 자유 사용 가능. Llama 3와 비슷한 ‘대형 사용자 제외 자유 사용’ 패턴.

NOTE

강사 배경지식 — Qwen ‘중국 회사’ 우려와 답변: ‘Alibaba가 중국 회사라 데이터 보안 우려’ 흔한 질문. 답 — (1) 모델 자체는 다운로드 후 사내 사용 — 중국 송신 X. (2) ‘백도어 가능성’은 이론적 — 발견 사례 없음. (3) 보안 강박이면 Llama로 대체 가능. (4) 한국 일부 회사(특히 방산·금융)는 정책상 중국 모델 회피. 정책 결정.

NOTE

강사 배경지식 — Qwen 2.5 vs Qwen 3 시점: Qwen 2.5 = 2024-09 출시 현재 안정. Qwen 3 = 2025년 출시 가능성. ‘새 모델 매년’ — 본격 도입 후 6~12개월마다 ‘업그레이드 검토’. 단 ‘2.5 안정 운영’ 6개월은 권장 — 신규 모델은 첫 3개월 버그 가능성.

NOTE

강사 배경지식 — Qwen2.5-VL (Vision): Qwen 2.5의 비전(이미지) 버전. ‘이미지 첨부 → 분석’ 가능. 사내 문서가 PDF·이미지 많으면 검토. 본 강좌 4편(챗봇·RAG)에서 다룸.

Q

예상 청중 질문 1: ‘우리는 첫 시작 — Qwen 7B 정말 충분?’ → 답: “일반 사내 챗봇·문서 RAG’ 충분. 더 깊은 추론 필요 시 14B·32B. 70B 본격은 ‘충분 답을 본 후.’”

Q

예상 청중 질문 2: ‘Qwen2.5-Coder vs 일반 Qwen2.5?’ → 답: ‘일반 — 종합 사용 (챗봇·RAG·번역 등). Coder — 코딩 특화. 개발팀 별도 도구 권장. 일반 사내는 일반 모델.’

Q

예상 청중 질문 3: ‘Llama로 시작했는데 Qwen으로 갈아там 어렵나?’ → 답: ‘Ollama 사용 시 ‘모델 변경’ 한 줄. 단 RAG 데이터·파인튜닝 결과는 호환 X — 다시 처리. 6개월 운영 후 ‘충분 만족’이면 그대로, ‘한국어 더 잘하는 게 좋다’면 갈아타기.’

TIP

강사 함정 — ‘무조건 Qwen 추천’ X: 사례·튜토리얼은 Llama 1위. ‘안정·사례 우선 — Llama, 한국어 우선 — Qwen’ 메시지.

TIP

강사 진행 팁 — 4분 시간 배분: 0~1분 ‘한국 인기 급증’. 1~2분 7개 크기 옵션. 2~3분 한국어 + 라이선스. 3~4분 청중 질문. Qwen 추천 메시지 강조.

BRIDGE

“Qwen 봤다면 — 유럽발 Mistral·Mixtral입니다.”

MISTRAL

Mistral / Mixtral — 프랑스 · 경량·MoE

■ 불변층 — Mistral의 ‘효율’ 특징

- ★ Mistral 7B — 2023.9 출시, ‘7B 모델의 표준’ 위치
- ★ Mixtral 8x7B — 2023.12, MoE(혼합 전문가) 첫 대중화
- ★ Mixtral 8x22B (Codestral 22B) — 2024 대형·코딩 옵션
- ★ 한국어 능력 ‘준수’ — Llama·Qwen만큼은 X (한국어 학습 데이터 적음)
- ★ 라이선스 — Apache 2.0 (완전 자유)
- ★ 강점 — 경량·MoE로 ‘작은 GPU에서 큰 모델 체감’

🕒 4분 · Mistral

SAY

“세 번째 — Mistral·Mixtral. 유럽발(프랑스) 오픈 LLM의 자존심.”

SAY

“Mistral 7B — 2023년 9월 출시. ‘7B 모델의 표준’ 위치. 그 시점 Llama 2 7B를 압도하며 등장. 작은 모델의 가능성 보여줬어요.”

SAY

“Mixtral 8x7B — 2023년 12월. ‘MoE 첫 대중화’. 8개 7B 전문가 모델 + 라우터. 한 번에 2개만 활성화 — 14B 분량 속도, 56B 분량 메모리. ‘대형의 효율’ 패턴.”

SAY

“2024년 추가 — Mixtral 8x22B (대형), Codestral 22B (코딩 특화), Mistral Nemo 12B 등. 다양한 옵션.”

SAY

“한국어 능력 ‘준수’ — Llama·Qwen만큼은 X. 학습 데이터에 한국어 비중 적음. 영어·프랑스어·독일어는 우수. 한국 회사 ‘한국어 자연스러움’ 추구면 Llama·Qwen 권장.”

SAY

“라이선스 — Apache 2.0 완전 자유. ‘회사 크기 무관 상업 OK’. 가장 자유로운 라이선스.”

STORY

Mistral AI 출처. 2023년 4월 창업. 프랑스 파리. 약 \$25억 가치. URL: mistral.ai. ‘오픈 LLM의 유럽 자존심’. Mistral 7B (2023-09) — 출시 즉시 ‘Llama 2 7B 압도’ 화제.

STORY

Mixtral 8x7B 디테일. 2023-12 발표. 출시 즉시 ‘GPT-3.5 근접’ 화제. MoE 아키텍처 — 8개 7B 전문가 + 라우터. 한 번에 2개 활성화 → 활성화 14B 분량. URL: mistral.ai/news/mixtral-of-experts.

STORY

Codestral 22B 출처. Mistral AI 2024-05. 코딩 특화. 80개 프로그래밍 언어 지원. URL: mistral.ai/news/codestral. 라이선스 — Mistral Non-Production License (비상업 연구만, 상업은 별도 협의) — 단 Codestral Mamba 7B는 Apache 2.0.

NOTE

★ 강사 핵심 배경지식 — MoE의 한국 회사 적용: ‘작은 GPU에서 큰 모델 체감’ 좋아 보이지만 — (1) 메모리는 여전히 큼 (Mixtral 8x7B = 56B 분량 VRAM). (2) 단순 사내 챗봇에는 ‘과잉 복잡’. (3) 7B 또는 14B Dense(보통) 모델로 충분한 경우 다수. MoE는 ‘50명+ 동시 사용’ 같은 규모에서 의미.

NOTE

강사 배경지식 — Mistral 한국 인기 낮은 이유: (1) 한국어 학습 데이터 적음 → 자연스러움 약함. (2) Llama·Qwen 사례 풍부 → ‘안전한 선택’. (3) 사례·튜토리얼 한국어 부족. 단 ‘영어·다국어 중심 회사’ — 글로벌 사업, 영문 보고서 작성 — 예는 Mistral 권장 가능.

NOTE

강사 배경지식 — Mistral Codestral 라이선스 함정: 일반 Mistral은 Apache 2.0 자유. 단 Codestral 22B는 ‘Mistral Non-Production License’ — 상업 사용 협의 필요. ‘코딩 특화 무료 라고 다 자유’ X. 사용 전 라이선스 재확인.

NOTE

강사 배경지식 — Mistral 신규 (2024~2025): Pixtral (비전), Mistral Large 2 (대형, 비상업 라이선스), Codestral Mamba (시퀀스 길이 무제한 아키텍처). 추세 — Mistral 점점 ‘비상업 라이선스’ 모델 증가. 상업 사용은 Mistral 7B·Mixtral 8x7B·Nemo 12B 중심.

Q

예상 청중 질문 1: ‘Mistral 한국 회사에 쓸 만한가?’ → 답: ‘한국어 자연스러움이 부족해서 ‘일반 사내’엔 Llama·Qwen 권장. 단 ‘영어·다국어 중심 업무’ 또는 ‘작은 GPU로 시작’ 경우 Mistral 7B 검토.’

Q

예상 청중 질문 2: ‘MoE가 좋다는 거 같은데 MoE 모델만 쓰면?’ → 답: ‘MoE는 ‘동시 사용자 많은 회사’에 의미. 일반 사내 — Mistral 7B·Llama 8B·Qwen 7B 같은 Dense 모델 충분. ‘작은 도입에 큰 MoE’ = 과잉.’

Q

예상 청중 질문 3: ‘Codestral 한국 개발팀에 쓸 만?’ → 답: ‘기술적으론 우수. 단 라이선스 — 상업 사용 협의 필요. ‘무료 상업 OK’가 우선이면 Qwen2.5-Coder 7B 권장. 무료 + 상업 + 코딩 — 셋 다 충족.’

TIP

강사 함정 — Mistral 디테일 깊이 X: ‘한국 인기 낮음. 단 영어·다국어 회사엔 옵션’ 메시지. 5분 안에.

TIP

강사 진행 팁 — 4분 시간 배분: 0~1분 ‘유럽 자존심’. 1~2분 Mistral 7B + Mixtral 8x7B. 2~3분 한국어 약점. 3~4분 ‘영어·다국어 회사엔 옵션’. ‘한국 인기 낮음’ 솔직히.

DEEPSEEK V3

DeepSeek V3 — 중국 · 가성비 1위

■ 가변층 — 2026.6 시점, 매년 새 버전

- ★ 671B MoE — 표면 거대, 활성 37B만 사용 (실제 메모리 약 380GB)
- ★ 추론·수학·코딩 강점 — GPT-4o·Claude 3.5와 일부 벤치마크 동급
- ★ 한국어 능력 ‘좋은’ — Llama 3.3 수준
- ★ 라이선스 — MIT (완전 자유 + 모델 가중치도 자유)
- ★ ★ 학습 비용 약 \$560만 — GPT-4의 1/20 (가성비 혁명)
- ★ 단점 — 671B는 H100 4~8장 필요, 일반 한국 회사 비현실. DeepSeek 7B·67B는 작음

🕒 4분 · DeepSeek V3

SAY

“네 번째 — DeepSeek V3. 중국 회사 DeepSeek의 모델. 2024년 12월 출시 즉시 ‘가성비 혁명’ 화제.”

SAY

“핵심 — 671B MoE 모델. 표면 거대하지만 ‘활성 37B’만 사용. 즉 ‘대형 모델 + 효율 활성’.”

SAY

“성능 — 추론·수학·코딩에서 GPT-4o·Claude 3.5와 일부 벤치마크 동급. 코딩 HumanEval 90%+. 수학 MATH 60%+. ‘오픈 LLM 1위급’ 위치.”

SAY

“한국어 능력 ‘좋은’ — Llama 3.3 수준. 일반 사내 사용 충분.”

SAY

“라이선스 — MIT. 완전 자유. ‘모델 가중치도 자유 사용’. 가장 자유로운 라이선스.”

SAY

“가성비 — 학습 비용 약 \$560만 (한화 약 80억). GPT-4의 1/20 수준. ‘이렇게 작은 비용으로 GPT-4 근접’ 충격. 단 우리 회사가 학습 X — 다운로드 무료.”

SAY

“현실 — 671B는 H100 4~8장 필요. 일반 한국 회사 비현실. 대신 DeepSeek 7B-67B(이전 버전) 같은 작은 옵션 있어요. ‘체험은 671B, 운영은 7B’ 가능.”

STORY

DeepSeek-V3 출처. DeepSeek 'DeepSeek-V3 Technical Report' 2024-12-26. URL: github.com/deepseek-ai/DeepSeek-V3. 671B 총, 활성 37B. 학습 데이터 14.8조 토큰. 컨텍스트 128K. 학습 비용 '\$5,576,000' 명시.

STORY

DeepSeek 학습 비용 충격 (강사 대응용). 일반 ‘GPT-4 학습 비용’ 추정 약 \$1억+. DeepSeek-V3 \$560만 — 약 1/18. ‘중국 회사가 효율 혁신’. 단 ‘우리가 학습할 일 X’ — 다운로드 + 사용은 무료. 가성비 의미는 ‘DeepSeek가 빠르게 새 버전 낼 수 있음’.

STORY

DeepSeek 시리즈 (강사 대응용). (1) DeepSeek 7B/67B (2024-01) — 첫 출시. (2) DeepSeek-V2 (2024-05) — MoE 도입. (3) DeepSeek-V3 (2024-12) — 671B. (4) DeepSeek-R1 (2025-01) — 추론 특화 (O1 비교). 매 4~6개월 새 버전. ‘급성장’ 모델 계열.

STORY

DeepSeek-R1 (강사 대응용). 2025-01 출시. ‘추론 특화’ — OpenAI o1 비교. 수학·코딩·논리 추론에서 GPT-4o 압도. ‘답하기 전 생각하는 LLM’. 단 응답 시간 길음 (10초~수분). 사내 챗봇 부적합 — 깊은 분석에만.

NOTE

★ 강사 핵심 배경지식 — DeepSeek ‘중국’ 우려 정직 답변: ‘중국 회사 모델 = 보안 우려’ 흔한 질문. 답 — (1) 모델 자체는 다운로드 후 사내 사용 — 중국 송신 X. (2) MIT 라이선스 — 완전 자유. (3) ‘백도어 가능성’ 우려는 이론적. (4) 보안 강박이면 Llama·Qwen 대체 가능. (5) 단 ‘DeepSeek API 사용’은 중국 송신 — 자체 호스팅 과 구분.

NOTE

강사 배경지식 — DeepSeek 671B 운영 비용: H100 8장 = 약 \$250,000 (3억 원+). 일반 중견기업 비현실. 대안 — (1) DeepSeek 7B·67B 사용. (2) DeepSeek-R1 Distill 7B/32B (작은 증류 버전) — 추론 일부 성능 + 작은 GPU. ‘큰 모델은 체험, 운영은 작은 것’.

NOTE

강사 배경지식 — DeepSeek R1 Distill 시리즈: 2025-01 R1 출시 시 ‘작은 증류 버전’ 동시 공개. Llama 8B·14B·32B·70B 기반 + DeepSeek R1 추론 학습. 즉 ‘Llama 8B에 R1 추론 능력 주입’. 일반 한국 회사 도입 가능 — ‘추론 능력’ + ‘작은 GPU’ 조합.

Q

예상 청중 질문 1: ‘671B는 너무 큼. DeepSeek 7B로 충분?’ → 답: ‘DeepSeek 7B(이전 버전)도 우수. Qwen 7B와 비슷 수준. 단 추론 특화 원하면 DeepSeek-R1 Distill 7B 또는 14B 권장.’

Q

예상 청중 질문 2: ‘DeepSeek vs Qwen 사이?’ → 답: ‘일반 사내 — Qwen 7B (한국어 우수). 코딩·추론 — DeepSeek Distill 7B. 한국 회사 대부분 Qwen 시작 권장.’

Q

예상 청중 질문 3: ‘중국 정부가 DeepSeek 모델 통제 가능?’ → 답: ‘기존 출시 모델은 ‘무료 다운로드 + 사내 사용’이라 통제 어려움. 단 향후 ‘새 버전 출시 중단’ 가능성은 있음. 안전 차원에서 ‘1차는 Llama·Qwen, 2차로 DeepSeek 검토’ 패턴 권장.’

TIP

강사 함정 — ‘DeepSeek가 GPT-4 동급’ 과장 X: ‘일부 벤치마크 동급. 일반 사용은 차이 있음’ 솔직히.

TIP

강사 진행 팁 — 4분 시간 배분: 0~1분 ‘가성비 혁명’ 메시지. 1~2분 671B + R1. 2~3분 R1 Distill 작은 옵션. 3~4분 ‘중국 우려’ 정직 답변. 청중 우려 정면 대응.

BRIDGE

“DeepSeek 봤다면 — 마지막. 2025.8 신규 GPT-OSS.”

GPT-OSS

GPT-OSS — OpenAI · 2025.8 신규

■ 가변층 — 신규 모델, 사례 적음

- ★ 20B / 120B 두 크기 — 2025.8.5 OpenAI 발표
- ★ ‘OpenAI 첫 오픈 가중치 모델’ — 역사적 의미
- ★ 영어·추론 강점 — GPT-4o의 약 90% 성능 (자체 발표)
- ★ 한국어 능력 ‘준수’ — Llama 3.1 8B 수준 (한국어 학습 데이터 부족 추정)
- ★ 라이선스 — Apache 2.0 (완전 자유)
- ★ 현재 상태 — 신규라 사례·튜토리얼 적음. 6개월 안정화 후 도입 권장

🕒 4분 · GPT-OSS

SAY

“다섯 번째 마지막 — GPT-OSS. 2025년 8월 OpenAI가 출시한 신규 오픈 LLM이에요.”

SAY

“역사적 의미 — ‘OpenAI 첫 오픈 가중치 모델’. ChatGPT 이후 OpenAI는 ‘클로즈드 LLM’ 노선이었어요. 5년 만에 오픈 가중치 트렌드에 참여한 거예요.”

SAY

“핵심 — 20B와 120B 두 크기. 20B는 일반 사내 챗봇용, 120B는 본격 운영. Apache 2.0 라이선스 — 완전 자유.”

SAY

“성능 — 영어·추론에서 GPT-4o의 약 90% (OpenAI 자체 발표). 한국어 ‘준수’ — Llama 3.1 8B 수준 추정. 한국어 학습 데이터가 적은 듯.”

SAY

“현재 상태 — 2025.8 신규. 사례·튜토리얼·한국어 가이드 아직 적음. 6개월 안정화 후 도입 권장. ‘1순위 시작’은 아님 — Llama·Qwen이 안전.”

STORY

gpt-oss 출처. OpenAI 'Introducing gpt-oss' 2025-08-05. URL: openai.com/index/introducing-gpt-oss. 'gpt-oss-20b'와 'gpt-oss-120b'. Apache 2.0. 'OpenAI 첫 오픈 가중치 모델'. Hugging Face 즉시 출시.

STORY

gpt-oss 출시 배경 (강사 대응용). 2025년 들어 '오픈 LLM 트렌드' 가속 — Meta(Llama), Alibaba(Qwen), Mistral, DeepSeek가 시장 차지. OpenAI 점유율 위협. '오픈 가중치 모델도 출시해야 한다' 내부 결정. 'ChatGPT는 클로즈드 유지, 오픈 모델은 별도' 전략.

STORY

gpt-oss 한국 도입 (강사 대응용). 2025.8 출시라 한국 회사 도입 사례 거의 없음. 대기업·연구실 '검토 단계'. 본격 사례는 2026년 후반 예상. '1순위는 Llama·Qwen, 2~3순위로 GPT-OSS 검토' 권장.

NOTE

★ 강사 핵심 배경지식 — '오픈 가중치' vs '진짜 오픈소스': gpt-oss는 '오픈 가중치' — 모델 파일만 공개. 학습 코드·데이터는 비공개. '진짜 오픈소스'와 다름. 사용에는 차이 X — 다운로드 + 사내 사용 모두 가능. 단 '파인튜닝 학습 방법'은 OpenAI 비공개 — 우리가 '똑같이 학습' X.

NOTE

강사 배경지식 — gpt-oss 20B vs 120B 선택: (1) 20B — VRAM 약 13GB, RTX 4090 가능, 일반 사내 챗봇. (2) 120B — VRAM 약 72GB, H100 또는 RTX 4090×3, 본격 운영. 한국 중견기업 '20B 시작' 권장.

NOTE

강사 배경지식 — gpt-oss 한국어 강화 가능성: 출시 시점 한국어 '준수' 수준. 향후 OpenAI 또는 커뮤니티가 '한국어 파인튜닝 버전' 출시 가능. Hugging Face 'gpt-oss-ko' 같은 한국어 강화 모델 검색 권장 (출시 6개월 ~1년 후).

NOTE

강사 배경지식 — 2026.6 시점 'gpt-oss 도입 권장' 여부: '1순위 시작' X. 'Llama·Qwen 6개월 운영 + 안정 후 gpt-oss 검토' 패턴. 신규 모델은 '버그·튜토리얼 부족·라이선스 해석 모호' 등 첫 6개월 위험 — 안전 시작이 정석.

Q

예상 청중 질문 1: ‘우리는 처음부터 gpt-oss 시도?’ → 답: ‘권장 X. 신규 모델은 운영 안정성 검증 안 됨. Llama 8B 또는 Qwen 7B로 시작 → 6개월 후 gpt-oss 검토.’

Q

예상 청중 질문 2: ‘gpt-oss가 ChatGPT만큼?’ → 답: ‘OpenAI 자체 발표 GPT-4o의 90% 수준. 단 ‘발표’와 ‘실전’ 차이. 영어는 우수, 한국어는 미흡. 사내 한국어 사용에는 Llama·Qwen 우선.’

Q

예상 청중 질문 3: ‘ChatGPT도 그냥 OpenAI 클라우드 쓰는데 gpt-oss는 왜?’ → 답: “‘ChatGPT 클라우드’ = 데이터 외부 + 토큰당 비용. ‘gpt-oss 자체’ = 데이터 사내 + 토큰 비용 0. 4질문 답에 따라 결정.’

TIP

강사 함정 — ‘OpenAI 출신이라 무조건 좋다’ X: 신규 모델은 안정성 미검증. Llama·Qwen 우선.

TIP

강사 진행 팁 — 4분 시간 배분: 0~1분 ‘OpenAI 첫 오픈’. 1~2분 사양 + 성능. 2~3분 ‘6개월 후 도입 권장’ 메시지. 3~4분 청중 질문. 안정성 강조.

BRIDGE

“5개 모델 다 봤다면 — 라이선스 매트릭스로 정리. 우리 회사 상업 사용 가능 여부 확인.”

LICENSE MATRIX

라이선스 · 상업 이용 매트릭스

■ 불변증 — 라이선스 확인 안 하면 법적 위험

- Apache 2.0 완전 자유 · 회사 크기 무관 — Qwen 2.5 (0.5B/1.5B), Mistral 7B/Mixtral, GPT-OSS. 상업 사용 100% 자유. 가장 안전.
- MIT 완전 자유 · 가장 자유 — DeepSeek V3, DeepSeek R1. ‘모델 가중치도 자유 사용’. Apache 2.0과 동급 자유.
- Llama 3 License 월 활성 사용자 7억 이하 자유 — Llama 3.3 70B, Llama 3.1 8B 등. 한국 99% 회사 자유 사용. 단 ‘Llama 출력으로 다른 모델 학습’ 시 표기 의무.
- Qwen License 월 활성 사용자 1억 이하 자유 — Qwen 2.5 3B+. Llama와 비슷. 한국 99% 회사 자유. 일부 빅테크는 협의.

🕒 5분 · 라이선스

SAY

“5개 모델 다 봤다면 — 라이선스 정리. 라이선스 확인 안 하면 법적 위험.”

SAY

“라이선스 4종으로 정리됩니다. Apache 2.0, MIT, Llama License, Qwen License.”

SAY

“Apache 2.0 — 완전 자유. 회사 크기 무관. Qwen 2.5(0.5B·1.5B), Mistral 7B·Mixtral, gpt-oss. 상업 사용 100% 자유. ‘가장 안전한 선택’.”

SAY

“MIT — 더 자유. DeepSeek V3·R1. ‘모델 가중치도 자유 사용’. ‘우리 회사 자체 변형 + 재배포’도 OK.”

SAY

“Llama 3 License — 약간 제약. ‘월 활성 사용자 7억 이하 회사’ 자유. 한국 99% 회사 해당. 단 ‘Llama 출력으로 다른 모델 학습 시 Llama 표기’ 의무 — 우리 회사가 ‘Llama 기반 자체 모델 만들기’ 시 Llama 명시.”

SAY

“Qwen License — Llama와 비슷. ‘월 활성 사용자 1억 이하’ 자유. 한국 99% 회사 해당. 일부 빅테크만 협의 필요.”

SAY

“실전 — Llama·Qwen 모두 ‘한국 회사 자유 사용 OK’. 단 ‘우리가 빅테크 인수’ 같은 미래 변수 있으면 협의 가능성. 99% 안전.”

STORY

Apache 2.0 풀이. Apache Software Foundation 2004 출시. 가장 인기 오픈소스 라이선스. 상업 사용·수정·재배포·특허 모두 자유. ‘저작권 표기 + 변경 사항 명시’ 의무. URL: apache.org/licenses/LICENSE-2.0.

STORY

MIT 풀이. MIT 대학 발. 가장 짧은 라이선스 (200자 미만). 상업·수정·재배포 모두 자유. ‘저작권 표기’만 의무. ‘Apache보다 더 짧고 더 자유’.

STORY

Llama 3 Community License 핵심 조항. (1) 월 활성 사용자 7억 이하 회사 무료 상업 OK. (2) Llama 3 모델 또는 출력을 사용한 다른 모델은 ‘Llama 3’ 표기. (3) Meta 정책 준수 — 인종·성·정치 차별 등 금지. (4) ‘Llama 3’를 사용해 만든 모델은 ‘동일 라이선스 + 표기’ 의무. URL: llama.com/llama3/license.

STORY

Qwen License 핵심 조항. (1) 상업 사용 무료 (월 1억 활성 사용자 이하). (2) Qwen 표기 의무 — 우리 모델이 Qwen 기반이면 명시. (3) 사용 정책 준수. (4) Qwen 2.5 0.5B·1.5B만 Apache 2.0, 나머지는 Qwen License. URL: huggingface.co/Qwen/Qwen2.5-72B-Instruct/blob/main/LICENSE.

NOTE

★ 강사 핵심 배경지식 — 라이선스 확인 5단계: (1) 다운로드 전 라이선스 페이지 확인. (2) ‘월 활성 사용자’ 조건 우리 회사 해당 여부. (3) ‘출력 기반 모델 학습 시 표기 의무’ 확인. (4) ‘회사 정책’ — 인종·성·정치 차별 금지 등 우리 사용 케이스 적합 여부. (5) 법무 검토 (대기업) 또는 외주 컨설팅(중견기업). 본 강좌 9편 보안·법무 자세히.

NOTE

강사 배경지식 — ‘Llama 표기 의무’ 실전 예시: 우리 회사가 Llama 3.3 70B로 사내 챗봇 만들면 — (1) 챗봇 약관에 ‘Built with Llama 3’ 명시. (2) Llama 라이선스 사본 사내 보관. (3) ‘파인튜닝 시 우리 모델 이름’은 ‘회사이름-Llama-기반’ 같은 명시 권장. ‘우리 자체 모델’이라 주장 X.

NOTE

강사 배경지식 — ‘비상업 라이선스’ 모델 주의: 일부 모델 — Solar 10.7B (CC-BY-NC 4.0), EXAONE (LG 별도), Mistral Large 2 (비상업) — ‘비상업 연구’만 무료, 상업 사용 협의. ‘다운로드 무료’가 아니라 ‘비상업 사용 무료’. 다운로드 전 확인 필수. 2강에서 자세히.

NOTE

강사 배경지식 — 라이선스 위반 시 위험: (1) 저작권 침해 — 손해배상. (2) 라이선스 권리 자동 종료 — 즉시 사용 중단 요구. (3) 평판 — ‘오픈소스 위반 회사’ 평판. 한국 회사 사례 — 아직 큰 사례 없음, 단 ‘AI 라이선스 위반 첫 사례’ 가능성 6~12개월 안 예상.

Q

예상 청중 질문 1: ‘우리 회사 법무 검토 어디?’ → 답: ‘대기업 — 사내 법무팀. 중견 — 외주 법무 컨설팅 (회 30~100만 원). 중소 — 라이선스 페이지 직접 읽기 + 명시된 조항 준수. 본 강좌 9편 보안 편이 가이드.’

Q

예상 청중 질문 2: ‘Apache 2.0이 가장 안전이면 그것만 쓰면?’ → 답: ‘맞아요. Qwen 0.5/1.5, Mistral, gpt-oss는 Apache 2.0. 단 한국어 우수성 — Qwen 7B+ 또는 Llama 8B 권장. 라이선스 vs 한국어 우수성 트레이드오프.’

Q

예상 청중 질문 3: ‘Llama로 만든 우리 모델 외부 판매?’ → 답: ‘가능. 단 Llama 표기 + 라이선스 의무 준수. ‘Llama 기반’임 명시 + 라이선스 함께 배포. 사내 사용보다 외부 판매에 의무 더 큼.’

TIP

강사 함정 — ‘라이선스 다 어렵다’ 분위기 X: ‘기본 한국 99% 자유 사용. 단 표기 의무는 지킬 것’ 메시지.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 4종 라이선스. 1~3분 각 디테일. 3~4분 ‘비상업 라이선스 주의’ (2강 연결). 4~5분 청중 질문.

BRIDGE

“1강 마지막 — 실습. 우리 회사 1순위 모델 결정.”

WORKSHOP 1

실습 — 우리 회사 1순위 모델 결정서

■ 적용 + 1강 정리 (워크시트)

- Q1 · 한국어 우선도? (높음 / 보통 / 낮음 · 영어 중심)
- Q2 · 코딩 비중? (개발팀 중심 / 일반 사내)
- Q3 · 라이선스 제약? (완전 자유 필수 / 99% 회사 자유 OK)
- Q4 · GPU 예산? (200만 / 800만 / 6,000만+)
- ★ 종합 → 우리 회사 1순위 모델 = ____
- ★ 다음 액션 — 견적 의뢰 시 ‘이 모델 명시’

🕒 9분 · 실습 · 마무리

SAY

“1강 마지막 — 실습. 60분 동안 들은 내용을 한 장에 응축. 우리 회사 1순위 모델 결정서.”

DO

조별 실습 (5분, 3~4인 1조). 4질문 + 종합 + 다음 액션. Q1~Q4 답에 따라 매트릭스로 결정.

SAY

“판단 매트릭스. (1) 한국어 높음 + 일반 사내 — Qwen 2.5 7B. (2) 한국어 높음 + 사례 우선 — Llama 3.1 8B. (3) 한국어 보통 + 영어 우수 — Mistral 7B 또는 gpt-oss 20B. (4) 코딩 + 추론 — DeepSeek R1 Distill 14B. (5) 본격 운영 + 큰 GPU — Qwen 72B 또는 Llama 70B.”

SAY

“다음 액션 — 결정서를 IT부에 전달. 견적 의뢰 시 ‘이 모델·이 크기’ 명시. 2편 ‘장비 구매서’와 합쳐서 전달.”

Q

발표 요청: “1~2조 발표. 종합 결과만 한 줄.” → 보통 ‘Qwen 7B’ 또는 ‘Llama 8B’ 다수. → ‘좋습니다. 첫 시작에 가장 권장.’

Q

발표 요청 2: “‘70B+’ 답 나온 조 있나?” → 1~2조. → ‘본격 운영 검토 단계. 2편 인프라 결정서가 ‘예 3~4개’인 회사. 본 강좌 3편 3강 추론 엔진이 70B 운영에 핵심.’

NOTE

★ 강사 핵심 배경지식 — 1순위 모델 결정 가이드 (Q1~Q4): (1) Q1 한국어 — 사내 챗봇·문서가 한국어면 ‘높음’. 영문 보고서·다국어가 많으면 ‘낮음’. (2) Q2 코딩 — 개발팀 중심이면 ‘개발팀’, 일반 직원이면 ‘일반’. (3) Q3 라이선스 — ‘완전 자유 필수’면 Apache 2.0/MIT만, 그 외 한국 회사 99% 자유. (4) Q4 GPU 예산 — 200만 = 4070, 800만 = 4090×2, 6,000만+ = H100.

NOTE

강사 배경지식 — 다음 주 액션 권장 3가지: (1) 1순위 모델 결정서 IT부 전달. (2) IT부에서 모델 다운로드 + 테스트 환경 — 1주. (3) 결과 보고 + ‘본격 도입 결정’ 회의 — 2주. 셋 다 2주 안에 가능.

NOTE

강사 배경지식 — ‘1순위 + 2순위’ 권장: 첫 도입은 1순위만. 단 6개월 후 ‘부족 부분’ 확인되면 2순위로 갈아타기 또는 추가. 예 — ‘Llama 8B 시작 → 한국어 부족 → Qwen 7B로 갈아타기’ 또는 ‘Qwen 7B + DeepSeek R1 Distill 7B 2개 운영’ 등.

Q

예상 청중 질문 1: ‘결정 안 됨. Q1·Q2 모호.’ → 답: “Qwen 2.5 7B’가 ‘안전한 기본값’. 한국어·코딩 모두 우수, 라이선스 자유. ‘결정 못 했어요’면 Qwen 7B 시작 권장.’

Q

예상 청중 질문 2: ‘2개 모델 동시 가능?’ → 답: ‘가능. 단 첫 시작은 1개. 운영 안정 후 2개 — 일반 사내 + 코딩 어시스턴트 같은 분리. Ollama·vLLM은 ‘여러 모델 동시 운영’ 지원.’

Q

예상 청중 질문 3: ‘우리 회사 IT 직접 다운로드 가능?’ → 답: ‘가능. Hugging Face 무료 가입 + 모델 페이지에서 다운로드 (단 일부 모델은 사용 동의 클릭 필요). 또는 Ollama가 한 줄 명령으로 다운로드 자동.’

TIP

강사 함정 — ‘완벽 결정 압박’ X: ‘60% 답으로 시작. 운영하면서 보완’ 메시지.

TIP

강사 진행 팁 — 9분 시간 배분: 0~5분 개별 작성. 5~7분 발표. 7~9분 다음 주 액션. Qwen 7B를 ‘안전한 기본값’으로 강조.

BRIDGE

“1강 끝. 잠깐 쉬고 2강 ‘한국어 특화 LLM’에서. ‘한국어 더 잘하는 모델 없을까’ 답.”

INTRO · TITLE

한국어 특화 LLM

2강 — Solar · EXAONE · KULLM · Bllossom

🕒 3분 · 시작

SAY

“2강입니다. ‘한국어 특화 LLM’. 1강에서 ‘글로벌 5종’ 봤다면 2강은 ‘한국에서 만든 한국어 특화 4종’입니다.”

SAY

“2강 60분 동안 다섯 가지를 봅니다 — (1) ‘한국어 능력 차이’ 정량 데이터, (2) Solar(Upstage), (3) EXAONE(LG), (4) KULLM(고려대) + Bllossom, (5) 파인튜닝. 이 다섯이 합쳐지면 ‘우리 회사 한국어 모델 결정서’.”

SAY

“2강 약속 — ‘한국어 1위 모델은 OO다’ 같은 단정 X. 정량 벤치마크 + 각 모델 강점·약점 + 라이선스 정직 비교.”

Q

도입 질문 1: “한국어 LLM이 영어보다 어려운 이유 아시나요?” → 보통 모름. → ‘한글은 ‘교착어’ — 어미 변화가 많아요. 영어 ‘run/ran/run’ 같은 단순 변화 vs 한국어 ‘달리다/달렸다/달리겠다/달리면/달려가다...’ 같은 복잡. AI 학습 어려움. 그래서 한국어 특화 모델이 의미 있어요.’

Q

도입 질문 2: “1강 1순위가 ‘Qwen 7B’ 또는 ‘Llama 8B’였던 분?” → 보통 다수. → ‘좋아요. 2강 후 ‘한국어 특화로 갈아탈지’ 결정. 결정 답이 ‘갈아탐’이면 Solar 또는 EXAONE으로 전환, ‘유지’면 1강 선택 그대로.’

NOTE

★ 강사 핵심 배경지식 — ‘한국어 특화’의 의미: 두 종류. (1) ‘한국어 전용 학습’ — 처음부터 한국어 위주로 학습. KULLM, Bllossom 일부. (2) ‘한국어 강화 파인튜닝’ — 글로벌 모델 베이스 + 한국어 추가 학습. Solar, EXAONE, Bllossom 일부. 둘 다 ‘한국어 자연스러움 우수’ 효과.

NOTE

강사 배경지식 — 1강 ‘Qwen 한국어 1위’와 2강 ‘한국어 특화 모델’의 관계: Qwen·Llama가 한국어 ‘좋은’이지만 ‘한국 회사 특수 용어·문화’엔 미흡. ‘영업·법무·인사’ 같은 도메인 한국어는 한국어 특화 모델이 우수. 본격 사내 사용 시 의미.

NOTE

강사 배경지식 — 2강 60분 시간 배분: 0~3분 인트로. 3~6분 학습목표. 6~14분 ‘한국어 능력 정량 차이’. 14~24분 Solar (가장 인기). 24~32분 EXAONE. 32~40분 KULLM + Bllossom. 40~48분 한국어 LLM 선택 4 질문. 48~54분 파인튜닝. 54~58분 실습. 58~60분 마무리.

TIP

강사 함정 — ‘한국어 특화가 항상 우수’ X: 영어·코딩·다국어는 글로벌 모델 우수. ‘한국어 사내’엔 특화, ‘다국어·코딩’엔 글로벌.

OBJECTIVES

60분 후, 이 3가지를 한다

- ① 한국어 특화 LLM 4종(Solar·EXAONE·KULLM·Bllossom)의 차이를 안다
- ② ‘1강 글로벌 vs 2강 특화’ 중 우리 회사 선택을 결정한다
- ③ ‘파인튜닝으로 우리 회사 전용 AI 만들기’ 가능성을 안다

🕒 3분 · 학습목표

SAY

“60분 후 셋. 첫째, 한국어 특화 LLM 4종 — Solar, EXAONE, KULLM, Bllossom — 의 차이. 둘째, ‘1강 글로벌 vs 2강 특화’ 중 우리 회사 선택. 셋째, ‘파인튜닝’ — 우리 회사 데이터로 학습 — 가능성.”

SAY

“2강 끝 메시지 — ‘한국어 특화는 좋은 옵션, 단 라이선스 제약 있음’. Solar는 비영리만, EXAONE은 LG 협의, KULLM·Bllossom은 자유. 라이선스가 결정 핵심.”

NOTE

★ 강사 핵심 배경지식 — 2강 성공 기준: 청중이 ‘우리 회사 1순위는 한국어 특화인가 글로벌인가’ 명확히 결정. ‘부분 답’도 OK — ‘일반은 글로벌, 임원 보고서는 한국어 특화’ 같은 분리.

NOTE

강사 배경지식 — 한국 한국어 LLM 현황: 한국 R&D 활발한 분야. 매년 1~2개 새 한국어 LLM 출시. 2025년 EXAONE 3.5 출시, Bllossom 8B 인기. 본 강좌 2026.6 기준 — 6개월 후 새 모델 가능성.

TIP

강사 진행 팁 — 학습 목표 3분 안에.

KO BENCHMARK

한국어 능력 차이 — 정량 벤치마크

■ 가변층 — 2026.6 시점, 분기별 변동

- Qwen 2.5 72B 한국어 종합 1위 — Open Korean LLM Leaderboard 2025년 초 약 65점. 글로벌 모델 중 한국어 가장 우수. 단 ‘한국 회사 특수 용어’엔 미흡.
- Llama 3.3 70B 한국어 종합 2위 — 약 62점. Qwen과 거의 동급. 사례·튜토리얼 풍부.
- Solar 10.7B (Upstage) 한국어 특화 + 작은 모델 — 약 58점. ‘10.7B에서 Llama 70B 근접’. 한국 회사 특수 용어 자연스러움 + 작은 GPU 동시.
- EXAONE 3.5 32B (LG) 한국어 + 산업 도메인 — 약 60점. 산업·기술·법무 도메인 강점. LG 자체 사용 + 일부 외부 공개.

⌚ 6분 · 한국어 벤치마크

SAY

“한국어 능력 정량 비교부터. Open Korean LLM Leaderboard 데이터입니다.”

SAY

“Qwen 2.5 72B — 한국어 종합 1위 약 65점. 글로벌 모델 중 가장 우수.”

SAY

“Llama 3.3 70B — 약 62점. Qwen과 거의 동급.”

SAY

“Solar 10.7B — 한국 Upstage의 한국어 특화 모델. 약 58점. ‘작은 10.7B로 큰 70B 근접’. 단 점수만 보면 Llama·Qwen이 우수.”

SAY

“EXAONE 3.5 32B — LG AI Research. 약 60점. 산업·기술·법무 도메인 강점.”

SAY

“메시지 — ‘점수만 보면 Qwen·Llama가 우수’. 그렇다면 ‘한국어 특화는 의미 X?’ — 아니에요. 점수에 안 잡히는 ‘한국 회사 특수 용어·문화·도메인’이 한국어 특화의 강점. 2개 다 봐야.”

STORY

Open Korean LLM Leaderboard 출처. Upstage·NIA(한국지능정보사회진흥원) 공동 운영. URL: huggingface.co/spaces/upstage/open-ko-llm-leaderboard. 9개 한국어 벤치마크 종합 점수. 매주 업데이트. 모델 누구나 제출 가능.

STORY

‘한국어 점수’의 한계 (강사 대응용). Leaderboard 점수는 객관식·번역 등 표준 테스트. 실제 사내 사용 — ‘영업팀 보고서 다듬기’, ‘법무 계약서 검토’ — 같은 도메인 한국어는 점수에 안 잡힘. ‘점수 1위가 사내 1위’ X. 정성 평가도 필수.

STORY

한국어 모델 추세 (강사 대응용). 2023~2024 한국어 특화 모델 폭증 (Solar, EXAONE, KULLM, Bllossom 등). 2025 추세 — ‘Qwen·Llama 자체가 한국어 잘함’ → 한국어 특화 모델 필요성 약화. 단 ‘한국 회사 특수 도메인’엔 여전히 의미.

NOTE

★ 강사 핵심 배경지식 — ‘점수 vs 실전’ 차이: Leaderboard 점수 — 일반 한국어 처리. 실전 사내 — 회사 용어·문화. 예 — Llama 70B는 ‘과장님’이라는 호칭 자연스러움 부족, ‘협력업체’ ‘외주’ 같은 한국 비즈니스 용어 어색. Solar·EXAONE은 자연스러움. ‘점수’와 ‘느낌’ 둘 다 보세요.

NOTE

강사 배경지식 — Open Korean LLM Leaderboard 9개 벤치마크: (1) KMMLU (한국어 MMLU·종합 지식). (2) HAERAE (한국어 추론). (3) KoBEST (한국어 일반 능력). (4) KOBEST_HellaSwag (상식). (5) KOBEST_BoolQ (예/아니오 추론). (6) KOBEST_SentiNeg (감정 분석). (7) KOBEST_COPA (인과 추론). (8) Belebele (다국어 독해). (9) Belebele_eng. 종합 점수.

NOTE

강사 배경지식 — 정성 평가 방법: 사내 도입 전 ‘비교 테스트’ — (1) 영업팀 실제 사용 문서 10개 준비. (2) Llama 70B vs Qwen 72B vs Solar 10.7B vs EXAONE 32B 같은 답 요청. (3) 영업팀이 ‘가장 자연스러운 답’ 선택. (4) 1주일 반복. 정성 결과 + 점수 종합 결정. ‘우리 회사 진짜 답’ 도출 방법.

NOTE

강사 배경지식 — ‘새 모델 매년’ 함정: 한국어 모델 점수 매년 5~10점 상승. 6개월 후 1위 다룰 가능성. 단 ‘점수 1위 따라가기’ X — 도입은 ‘안정 + 운영’ 우선. 18개월 주기로 업그레이드 검토 권장.

Q

예상 청중 질문 1: ‘우리 회사 진짜 답 어떻게?’ → 답: ‘정성 평가 권장. 영업·법무·인사 부서 챔피언 5명 + 회사 실제 문서 10개 + 모델 3~4개 비교 = 1주일. 정량 + 정성 종합 결정.’

Q

예상 청중 질문 2: ‘점수만 보면 Qwen·Llama인데 그냥 그것만?’ → 답: ‘1순위 선택이면 OK. 단 ‘한국 회사 특수 도메인’ 필요하면 Solar·EXAONE 검토. 추가 도구로 1개 더 운영 가능.’

Q

예상 청중 질문 3: ‘Leaderboard 못 믿겠다는데?’ → 답: ‘Leaderboard도 ‘오버피팅(과적합)’ 우려 있어요. 일부 모델이 ‘벤치마크 위주 학습’해서 점수 부풀림 가능. 정성 평가 + 한국 회사 실제 사례 (사례 발표·논문) 종합 추천.’

TIP

강사 함정 — 벤치마크 수치 외우게 X: ‘60점·65점’ 외우지 마세요. ‘Qwen·Llama 우수 + 한국어 특화는 도메인 강점’ 메시지만.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘점수 vs 실전’. 1~3분 4개 모델 점수. 3~4분 ‘점수 한계’. 4~5분 정성 평가 방법. 5~6분 청중 질문. 정성 평가가 핵심 메시지.

BRIDGE

“점수 정리했다면 — 각 한국어 특화 모델 디테일. 첫 번째 Solar.”

SOLAR

Solar — Upstage · 한국 1위 한국어 모델

■ 불변층 — Solar 강점 + ■ 가변층 — 라이선스 주의

- ★ 10.7B 모델 — 작은 크기 + 한국어 자연스러움
- ★ Upstage(한국 회사) — 2020년 창업, AI 솔루션 전문
- ★ 라이선스 — CC BY-NC 4.0 (비영리 사용만 무료, 영리 협의)
- ★ 강점 — 한국어 + 영어 양쪽 우수, '10.7B에서 70B 근접'
- ★ 한국 회사 자체 호스팅 사례 다수 (단 '비영리·내부 사용' 명목)
- ★ ★ 영리 사용 시 — Upstage 협의 후 라이선스 (월 약 50~500만 원 추정)

🕒 6분 · Solar

SAY

“한국어 특화 첫 번째 — Solar. Upstage라는 한국 AI 회사의 모델입니다. 한국에서 가장 인기.”

SAY

“핵심 — 10.7B. 글로벌 70B에 비해 7배 작음. 그런데 ‘성능은 70B 근접’ — Upstage의 ‘Depth Upscaling’ 기술 덕분.”

SAY

“Upstage — 2020년 창업한 한국 AI 회사. CTO 김성훈 (홍콩과기대 교수). 한국 AI 스타트업 대표 주자. 사내 R&D 모델이 Solar.”

SAY

“라이선스 — ★ 중요. ‘CC BY-NC 4.0’ — Creative Commons Attribution Non-Commercial. ‘비영리 사용만 무료’. ‘영리·상업 사용은 Upstage 협의 필요’.”

SAY

“의미 — ‘우리 회사 사내 사용도 영리’로 볼 수 있어요. ‘직원 생산성 향상 → 회사 수익 증가’ 논리. 안전을 위해 ‘Upstage 협의 후 라이선스’ 권장.”

SAY

“추정 비용 — Upstage 협의 라이선스 월 50~500만 원 (회사 규모·사용량 기준). 단순 ‘공식 가격표’ X — 협의로 결정. 다른 글로벌 모델 ‘무료 + 상업 OK’와 다름.”

STORY

Solar 출처. Upstage 'Solar 10.7B Technical Report' 2023-12-21. URL: huggingface.co/upstage/SOLAR-10.7B-v1.0. ‘Depth Upscaling’ — Llama 2 7B를 깊이 확장해서 10.7B. ‘작은 크기 + 큰 성능’.

STORY

Solar 라이선스 디테일 (강사 대응용). CC BY-NC 4.0 — ‘저작권 표기 + 비영리 사용 + 변경 가능 + 같은 라이선스 의무’. 핵심 ‘비영리(Non-Commercial)’. 회사 사내 사용도 ‘영리 활동의 일환’ 해석 가능 → 안전 차원에서 Upstage 협의 권장. URL: creativecommons.org/licenses/by-nc/4.0.

STORY

Upstage 회사 정보 (강사 대응용). 2020년 김성훈 박사 창업. 한국 AI 솔루션 대표 주자. 매출 약 200억 원 (2024 추정). Solar 외 OCR·문서 처리 솔루션. ‘Solar Pro’ 같은 본격 모델도 출시. URL: upstage.ai.

STORY

한국 Solar 도입 사례 (강사 대응용). 중견·대기업 다수 ‘Solar 자체 호스팅’ 채택. 단 ‘영리 사용 라이선스’ 명시 사례는 비공개 많음. 일부 — KB금융·신한은행 등 금융권에서 Solar 기반 사내 챗봇 운영 (Upstage 솔루션 패키지 일부).

NOTE

★ 강사 핵심 배경지식 — Solar ‘비영리 사용’ 해석의 모호함: ‘우리 회사 사내 사용도 비영리인가?’ 모호. 두 해석. (1) ‘직원 효율 = 회사 수익 = 영리’. (2) ‘사내 도구 = 외부 판매 X = 비영리’. 보수적 해석은 ‘영리’ — 라이선스 협의. 진보적 해석은 ‘비영리’ — 그냥 사용. Upstage 공식 답변 확인 권장.

NOTE

강사 배경지식 — Solar Pro (강사 대응용): 2024년 출시. Solar 10.7B의 본격 버전. 22B 크기. 영리 사용 가능 — 단 Upstage 라이선스 + 솔루션 패키지. 가격 — 견적 (월 100~1,000만 원 추정). 한국 회사 ‘완전 솔루션 패키지’ 원하면 Solar Pro 옵션.

NOTE

강사 배경지식 — Solar의 ‘Depth Upscaling’ 기술: Llama 2 7B를 ‘48 레이어 → 48 레이어 × 2 = 96 레이어’로 깊이 확장. 새로 학습 X — 기존 가중치 복제 후 미세조정. ‘적은 학습 비용 + 큰 모델 효과’ 패턴. 다른 회사도 비슷한 기술 활용 추세.

NOTE

강사 배경지식 — Solar Mini (강사 대응용): 2024년 발표. ‘1B 작은 한국어 모델’. 모바일·임베디드용. 한국 IoT 회사에 인기. 사내 본격 사용 X — 검토만.

Q

예상 청중 질문 1: ‘우리 사내 사용 영리인가 비영리인가?’ → 답: ‘보수적으로 ‘영리’ 해석 권장. Upstage 협의 추천. 협의비 월 50만 원~ 정도 시작 가능.’

Q

예상 청중 질문 2: ‘비영리로 그냥 사용해도 적발 가능?’ → 답: ‘이론적으로 가능. Upstage가 사내 사용 확인 어려움 — 자동 감지 X. 단 ‘라이선스 위반’ 명백 — 발견 시 손해배상 위험. 안전 차원 협의 권장.’

Q

예상 청중 질문 3: ‘Solar vs Qwen 7B 사이?’ → 답: ‘한국어 도메인 자연스러움 — Solar. 라이선스 자유 + 점수 — Qwen. 우리 회사 ‘한국어 도메인 절대’면 Solar 협의, ‘무료 + 안전’ 우선이면 Qwen.’

TIP

강사 함정 — Solar 라이선스 회피 X: 청중에게 ‘이게 가장 어렵다’ 솔직히. 한국 한국어 모델 ‘무료 + 상업 자유’는 적음.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘한국 1위’. 1~2분 사양·기술. 2~4분 라이선스 (★ 가장 중요). 4~5분 도입 사례. 5~6분 청중 질문. 라이선스 명확 강조.

BRIDGE

“Solar 봤다면 — LG의 EXAONE. ‘산업·기술 강점’.”

EXAONE

EXAONE — LG AI Research · 산업·기술 강점

■ 불변층 — EXAONE 강점 + ■ 가변층 — 3.5 모델

- ★ EXAONE 3.5 — 2024.12 출시, 2.4B / 7.8B / 32B 세 크기
- ★ LG AI Research — 2020 LG 그룹 AI 연구소, 약 200명 연구자
- ★ 강점 — 산업·기술·법무·바이오 도메인 우수 (LG 그룹 사업 영역)
- ★ 한국어 능력 — 약 60점 (Qwen·Llama와 거의 동급)
- ★ 라이선스 — EXAONE License (비영리 연구 + 사내 사용 OK, 상업 협의)
- ★ Hugging Face 무료 다운로드 — LG와 협의 시 영리 사용 가능

🕒 5분 · EXAONE

SAY

“한국어 특화 두 번째 — EXAONE. LG AI Research의 모델입니다.”

SAY

“EXAONE 3.5 — 2024년 12월 출시. 2.4B / 7.8B / 32B 세 크기. 7.8B가 가장 인기 (작은 GPU OK).”

SAY

“LG AI Research — 2020년 LG 그룹 AI 연구소. 약 200명 연구자. LG의 산업 데이터(제조·반도체·배터리·디스플레이) 학습. ‘산업·기술 한국어 우수’.”

SAY

“강점 — 산업·기술·법무·바이오 도메인 우수. LG 그룹 사업 영역. ‘일반 한국어’는 Qwen·Llama와 비슷, ‘기술 한국어’는 더 우수.”

SAY

“라이선스 — ‘EXAONE License’. ‘비영리 연구 + 사내 사용 OK, 상업 사용 협의’. Solar와 비슷한 패턴. LG와 협의 시 영리 사용 가능.”

SAY

“Hugging Face 무료 다운로드 — 모델은 자유. 단 ‘영리 사용’ 시 LG 협의 + 라이선스 비용. 추정 월 100~1,000만 원.”

STORY

EXAONE 3.5 출처. LG AI Research 'EXAONE 3.5 Technical Report' 2024-12-09. URL: huggingface.co/LGAI-EXAONE/EXAONE-3.5-7.8B-Instruct. 2.4B/7.8B/32B 세 크기. 컨텍스트 32K (3.0은 4K, 3.5에서 8배 확장). 학습 데이터 약 8조 토큰.

STORY

EXAONE 3.5 한국어 벤치마크 (강사 대응용). 7.8B 한국어 종합 약 55점 (Solar 10.7B 58점 근접). 32B 약 60점 (Llama 70B 62점 근접). ‘작은 모델로 큰 모델 근접’. 단 ‘기술 도메인’ 정성 평가는 Llama·Qwen 우수.

STORY

LG AI Research 사례 (강사 대응용). LG 그룹 사내 LG U+ 콜센터, LG전자 디자인 보조, LG화학 화학 분석 등 EXAONE 적용. ‘LG 자체 사례’가 EXAONE 신뢰의 근거. 일부 외부 회사도 도입 (LG 협의 후).

STORY

EXAONE Path (의료 특화) (강사 대응용). 2024 발표. 의료 영상 + 한국어 진단 보고서 특화. 한국 병원·의료 회사 도입 검토. 일반 사내 사용 X — 의료 도메인 전용.

NOTE

★ 강사 핵심 배경지식 — EXAONE vs Solar 차이: (1) Solar — 한국어 일반 강점 + 작은 모델. (2) EXAONE — 산업·기술 도메인 강점 + LG 데이터. 우리 회사 ‘일반 한국어’ 우선 — Solar, ‘산업·기술’ 우선 — EXAONE. 둘 다 라이선스 협의 필요.

NOTE

강사 배경지식 — EXAONE License 핵심 조항: (1) ‘비영리 연구 + 사내 비공개 사용’ 무료. (2) ‘외부 제공·서비스’는 LG 협의. (3) ‘EXAONE 출력을 다른 모델 학습’ 시 협의. (4) LG의 ‘책임 있는 AI’ 정책 준수. 본 강좌 9편(보안·법무) 자세히.

NOTE

강사 배경지식 — EXAONE의 ‘책임 있는 AI’ 정책: LG AI Research ‘AI 윤리 가이드라인’ 준수 의무. ‘인종·성·정치 차별 금지’, ‘프라이버시 보호’, ‘투명성’. 사내 사용 시 ‘회사 정책에 부합’ 확인 필요. 본 강좌 9편 자세히.

NOTE

강사 배경지식 — 2024.12 EXAONE 3.5 출시 의미: 2023 EXAONE 3.0 (78B 단일) → 2024.12 EXAONE 3.5 (2.4/7.8/32B 다양). ‘크기 옵션 추가’ + ‘작은 GPU 도입 가능’. 한국 중견기업 도입 가능성 확대. 2025년 EXAONE 4.0 예상 — 또 다른 도약 가능성.

Q

예상 청중 질문 1: ‘우리는 산업 회사인데 EXAONE 1순위?’ → 답: ‘산업·기술 한국어 도메인이면 EXAONE 강점. 단 라이선스 협의 부담. ‘협의 가능’이면 EXAONE 추천, ‘무료 우선’이면 Qwen 14B 권장.’

Q

예상 청중 질문 2: ‘LG 협의 어떻게?’ → 답: ‘LG AI Research 공식 홈페이지(lgresearch.ai) 문의 폼. 또는 lg-ai-research@lge.com 메일. 협의 1~3개월. 우리 회사 사용 케이스·규모·예산 제공 후 건적.’

Q

예상 청중 질문 3: ‘EXAONE 출력을 우리 모델 학습?’ → 답: ‘라이선스 협의 필요. ‘파인튜닝으로 우리 회사 전용 모델’ 만들기는 LG와 별도 조항. 단순 ‘사내 챗봇 사용’보다 더 엄격.’

TIP

강사 함정 — EXAONE ‘LG라서 비싸다’ X: LG 협의 가격은 사용량 기반. 작은 규모 시작은 100만 원대 가능. ‘무조건 비쌌’ 잘못.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 LG 신뢰. 1~2분 사양·도메인. 2~3분 라이선스. 3~4분 산업·기술 강점. 4~5분 청중 질문.

BRIDGE

“EXAONE 봤다면 — 대학·연구소발 KULLM·Bllossom.”

KULLM·BLLOSSOM

KULLM · Bllossom — 대학·커뮤니티발

■ 불변층 — 라이선스 자유의 한국어 모델

- 고려대 · 학술 연구 (KULLM) — 고려대학교 NLP&AI 연구실 발. 한국어 instruction 학습 데이터로 Llama·Polyglot 베이스 파인튜닝. 학술용. Apache 2.0 (모델 베이스 라이선스 + KULLM 자체 추가). 한국 회사 자유 사용 OK.
- 커뮤니티 · 한국어 + 영어 균형 (Bllossom) — ETRI·서울과기대 등 한국 NLP 커뮤니티 합작. 한국어 + 영어 균형 학습. Llama 베이스 + 한국어 강화. Llama 라이선스 따름 (한국 99% 회사 자유). 한국어 자연스러움 우수.

🕒 6분 · KULLM·Bllossom

SAY

“한국어 특화 세 번째·네 번째 — KULLM과 Bllossom. 대학·커뮤니티 발입니다.”

SAY

“KULLM — 고려대학교 NLP&AI 연구실 발. ‘Korea University Large Language Model’ 약자. 학술 연구가 출발점.”

SAY

“KULLM 학습 — Llama·Polyglot 베이스 + 한국어 instruction 학습 데이터. ‘instruction 학습’ = ‘질문에 답하는 방법’ 학습. 사내 챗봇용으로 적합.”

SAY

“KULLM 라이선스 — Apache 2.0 (모델 베이스) + KULLM 자체 추가. 한국 회사 자유 사용 OK.”

SAY

“Bllossom — ETRI·서울과기대 등 한국 NLP 커뮤니티 합작. ‘한국어 + 영어 균형 학습’. Llama 베이스 + 한국어 강화. Llama 라이선스 따름 (한국 99% 회사 자유).”

SAY

“Bllossom 강점 — 한국어 자연스러움 우수. KULLM보다 본격 사내 사용에 적합. ‘무료 + 자유 + 한국어 우수’ 균형.”

SAY

“메시지 — Solar·EXAONE 라이선스 부담이면 KULLM·Bllossom 검토. 단 ‘대학·커뮤니티 발’ 특성상 ‘운영 지원·업데이트’가 LG·Upstage보다 약함.”

STORY

KULLM 출처. 고려대학교 NLP&AI 연구실 2023 공개. URL: github.com/nlpai-lab/KULLM. v1 — Polyglot-12.8B 베이스. v2 — Llama 2 13B 베이스. v3 (KULLM-Polyglot 5.8B/Llama-2 13B 등). 학술 논문 발표. 한국어 instruction 데이터셋도 공개.

STORY

Bllossom 출처. ETRI(한국전자통신연구원) + 서울과기대 + 임경태 박사팀 합작. URL: huggingface.co/MLP-KTLim. Bllossom 8B (Llama 3 8B 베이스), 70B (Llama 3 70B 베이스). 2024년 한국어 LLM 인기.

STORY

한국 KULLM·Bllossom 도입 사례 (강사 대응용). KULLM — 대학·연구소 위주, 일부 IT 회사 R&D. Bllossom — 한국 중소·중견기업 자체 호스팅 사례 다수. ‘무료 + 한국어 + Llama 베이스(사례 풍부)’ 조합으로 인기.

STORY

한국어 LLM 커뮤니티 (강사 대응용). 한국 NLP 커뮤니티 (한국정보과학회 NLP 분과, KoreanNLP 그룹 등) 활발. Hugging Face 한국어 모델 페이지 매월 새 모델. 본 강좌 2026.6 기준 — 6개월 후 새 인기 모델 가능성.

NOTE

★ 강사 핵심 배경지식 — KULLM vs Bllossom 선택: (1) KULLM — 학술·연구 중심. 사례 적음. 사내 본격 사용 부담. (2) Bllossom — 본격 사내 사용 적합. 한국어 자연스러움 우수. 사례 풍부. 한국 회사 추천 — Bllossom 8B 우선, KULLM은 ‘학술·연구 회사’만.

NOTE

강사 배경지식 — Bllossom 8B vs 70B: 8B — RTX 4070(12GB) OK. 일반 사내 챗봇. 70B — RTX 4090×2 또는 H100. 본격 운영. 시작은 8B 권장, 6개월 후 70B 업그레이드.

NOTE

강사 배경지식 — KULLM 다양한 버전: KULLM v1·v2·v3 + 베이스 다양. ‘Polyglot 베이스’ vs ‘Llama 베이스’ 차이. Polyglot은 한국어 특화 베이스 모델 (EleutherAI 한국 지부). Llama 베이스는 ‘Llama 라이선스’ 따름. 라이선스 다양 → 도입 전 확인 필수.

NOTE

강사 배경지식 — ‘대학·커뮤니티 모델’ 운영 리스크: (1) 모델 업데이트 자주 X — 1년에 1~2회. (2) 버그·이슈 응답 늦음. (3) 상업 지원 X — 사내 IT가 모든 운영. (4) 단 ‘무료 + 자유’ 강점. 사내 IT 역량 있으면 OK.

Q

예상 청중 질문 1: ‘Bllossom이 무료 + 자유면 그것만 쓰면?’ → 답: ‘좋은 선택. 단 ‘Llama 라이선스 따름’ — Llama 표기 의무. 사용은 자유.’

Q

예상 청중 질문 2: ‘대학·커뮤니티 모델 안정성?’ → 답: “안정성’은 모델 자체 ≠ 운영 지원. Bllossom 8B 모델 자체는 안정. 단 ‘버그 발견 시 커뮤니티 응답 늦음’. 사내 IT가 ‘문제 자체 해결’ 역량 필요.”

Q

예상 청중 질문 3: ‘KULLM·Bllossom 외에 다른 한국어 모델?’ → 답: ‘Polyglot-Ko (EleutherAI 한국, 학술 중심), KoGPT (카카오, 비공개), HyperCLOVA (네이버, 비공개) 등. 자유 사용 가능 — KULLM·Bllossom·Polyglot-Ko 정도. 본격 도입은 Solar·EXAONE·Bllossom 중.’

TIP

강사 함정 — ‘대학 모델은 약하다’ X: Bllossom은 본격 사용 가능. ‘무료 + 자유 + 우수’ 가치 인정.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 두 모델 소개. 1~3분 KULLM 디테일. 3~5분 Bllossom 디테일 (더 본격). 5~6분 청중 질문. Bllossom 추천 메시지.

BRIDGE

“4개 한국어 모델 다 봤다면 — 우리 회사 선택 4질문으로 정리.”

KO LLM CHOICE

한국어 LLM 선택 4질문

■ 불변층 — 결정 프레임

- Q1 · 라이선스 — 완전 자유 필수 / 협의 가능?
- Q2 · 도메인 — 일반 사내 / 산업·기술 / 학술?
- Q3 · 운영 — 사내 IT 역량 강함 / 외주 지원 필요?
- Q4 · 1강 vs 2강 — 글로벌 + 한국어 OK / 한국어 특화 필수?
- ★ 매트릭스 → 우리 회사 한국어 LLM 1순위 = ____
- ★ ‘1강 + 2강’ 2개 모델 운영도 가능 — 일반 + 도메인 분리

🕒 5분 · 4질문

SAY

“4개 한국어 특화 LLM 봤다면 — 4질문으로 결정. 1강 4질문(모델 일반)과는 다른 ‘한국어 특화 4질문’입니다.”

SAY

“Q1 라이선스. 완전 자유 필수면 — Bllossom·KULLM. 협의 가능이면 — Solar·EXAONE 옵션 추가.”

SAY

“Q2 도메인. 일반 사내 — Bllossom·Solar. 산업·기술 — EXAONE. 학술 — KULLM.”

SAY

“Q3 운영. 사내 IT 강함 — 모든 옵션. 외주 지원 필요 — Solar(Upstage)·EXAONE(LG) — 회사 지원 가능. 무료 모델은 사내 IT 부담.”

SAY

“Q4 1강 vs 2강. ‘1강 글로벌(Qwen·Llama)이 한국어 OK’면 1강 선택 유지. ‘한국어 특화 필수’면 2강 모델로 전환.”

SAY

“추천 매트릭스. 무료 + 일반 사내 → Bllossom 8B. 무료 + 자유 + 한국어 도메인 → Bllossom 8B. 라이선스 협의 가능 + 산업 → EXAONE 7.8B. 라이선스 협의 가능 + 일반 → Solar 10.7B. 학술 R&D → KULLM.”

SAY

“1개 + 1개’ 운영도 가능 — 일반은 Qwen 7B(글로벌), 한국어 도메인은 Solar 10.7B(특화). 두 모델 분리.”

STORY

한국 회사 한국어 LLM 도입 분포 (강사 대응용 추정). 무료 한국어 LLM (Bllossom 등) 약 30%. Solar (Upstage 협의) 약 25%. EXAONE (LG 협의) 약 15%. 글로벌 모델 그대로 (Llama·Qwen) 약 30%. ‘한국어 특화 도입’이 약 70%.

STORY

한국어 모델 비용 비교 (강사 대응용). 무료 — Bllossom·KULLM (모델 무료, 운영비만). Solar — Upstage 협의 월 50~500만 원. EXAONE — LG 협의 월 100~1,000만 원. ‘무료 vs 협의’ 비용 차이 큼.

NOTE

★ 강사 핵심 배경지식 — ‘2개 모델 운영’ 권장 패턴: 일반 사내 챗봇 + RAG는 무료 모델(Bllossom 8B) — 라이선스 자유 + 사용량 부담 적음. 특수 도메인(법무·산업·임원 보고) 은 협의 모델(Solar·EXAONE) — 정밀 한국어. 비용 적절 + 품질 우수 균형.

NOTE

강사 배경지식 — 라이선스 협의 부담 정리: Solar·EXAONE 협의 부담 — (1) 시간 1~3개월. (2) 회의 3~5회. (3) 사용 케이스 문서. (4) 연 라이선스 갱신. (5) 라이선스 비용. ‘무료 + 자유’ 모델보다 훨씬 부담. 단 ‘본격 사내 도입’엔 의미.

NOTE

강사 배경지식 — ‘우리 회사 한국어 사용 비중’ 추정 방법: (1) 사내 문서 — 한국어 비중 90%+ 일반. (2) 외국어 회사 — 영어 비중 큼. (3) 한국어 비중 90%+면 한국어 특화 검토 의미. (4) 영어 비중 50%+면 글로벌 모델 권장.

Q

예상 청중 질문 1: ‘Solar·EXAONE 협의 시간 부담.’ → 답: ‘맞아요. 첫 도입은 Bllossom 8B 무료 시작 권장. 6개월 운영 후 ‘한국어 도메인 부족’ 확인되면 Solar·EXAONE 협의.’

Q

예상 청중 질문 2: ‘우리는 사내 IT 약함. 누가 지원?’ → 답: ‘Upstage(Solar)·LG(EXAONE)는 라이선스 + 운영 지원 옵션. MSP(2편 1강) 외주도 가능. ‘무료 모델 + 자체 운영’이 가장 어려움.’

Q

예상 청중 질문 3: ‘2개 모델 동시 운영 부담?’ → 답: ‘운영 부담 약 1.3~1.5배 (2배 X). Ollama·vLLM이 ‘여러 모델 동시’ 지원. 메모리는 합산 — 2개 모델 = VRAM 2배. 작은 모델 2개 권장 — 7B + 10.7B.’

TIP

강사 함정 — ‘무조건 한국어 특화’ X: 1강 글로벌도 한국어 우수. ‘우리 도메인’ 부족할 때만 특화.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 4질문. 1~3분 매트릭스. 3~4분 ‘2개 운영’ 패턴. 4~5분 청중 질문. 실용 매트릭스 강조.

BRIDGE

“선택까지 했다면 — 마지막. ‘파인튜닝’으로 우리 회사 전용 AI 만들기.”

FINE-TUNING

파인튜닝 — 우리 회사 전용 AI

■ 불변층 — 가능성 + ■ 가변층 — 비용

- ★ 파인튜닝(Fine-tuning) — 베이스 모델 + 우리 회사 데이터 추가 학습
- ★ 결과 — ‘우리 회사 용어·문화·도메인 자연스러운 AI’
- ★ 데이터 — 사내 문서·이메일·보고서 약 1,000~10,000건 + 라벨링
- ★ GPU — 클라우드 H100×8 약 20~50시간 (비용 약 100~500만 원)
- ★ 도구 — LoRA·QLoRA로 작은 학습. Hugging Face·Unsloth·Axolotl
- ★ 라이선스 — 베이스 모델 라이선스 따름. 파인튜닝 결과도 표기 의무

🕒 5분 · 파인튜닝

SAY

“2강 마지막 본문 — 파인튜닝. ‘우리 회사 전용 AI’ 만드는 방법.”

SAY

“파인튜닝(Fine-tuning) — 베이스 모델 + 우리 회사 데이터 추가 학습. ‘회사 일반 한국어 → 우리 회사 한국어’ 진화.”

SAY

“결과 — ‘우리 회사 용어·문화·도메인 자연스러운 AI’. 예 — ‘우리 회사 영업 보고서 톤’, ‘우리 회사 코딩 스타일’, ‘우리 회사 임원 문서 양식’. 일반 모델로는 어려움.”

SAY

“데이터 — 사내 문서·이메일·보고서 약 1,000~10,000건. ‘질문 - 답’ 쌍으로 라벨링. 작은 회사도 가능한 규모.”

SAY

“GPU — 자체 GPU로 학습은 시간 큼 (몇 일~몇 주). 클라우드 GPU 임대 — H100×8 약 20~50시간 = 비용 약 100~500만 원. 1회 학습.”

SAY

“도구 — LoRA·QLoRA로 ‘작은 학습’ 가능. 전체 가중치 학습 대신 ‘일부 가중치만 학습’. 비용·시간 1/10. Hugging Face·Unsloth·Axolotl 무료 도구.”

SAY

“라이선스 — 파인튜닝 결과도 베이스 모델 라이선스 따름. ‘Llama 기반 우리 모델’이면 Llama 표기 의무. 자유 사용은 ‘Apache 2.0 베이스’ (Qwen·Blossom 8B·Mistral 등).”

STORY

LoRA 출처. Microsoft 'LoRA: Low-Rank Adaptation of Large Language Models' 2021. URL: arxiv.org/abs/2106.09685. ‘작은 어댑터 매트릭스만 학습’으로 큰 모델 미세조정. 메모리·시간 1/10~1/100. Hugging Face PEFT 라이브러리 표준 지원.

STORY

QLoRA 출처. University of Washington 'QLoRA: Efficient Finetuning of Quantized LLMs' 2023. URL: arxiv.org/abs/2305.14314. ‘LoRA + 4비트 양자화’. 70B 모델 파인튜닝을 24GB GPU에서 가능. 4090 1장으로 70B 파인튜닝.

STORY

Unsloth·Axolotl 출처. (1) Unsloth — github.com/unslothai/unsloth. ‘LoRA 학습 2배 빠름’. 무료 + Pro 옵션. (2) Axolotl — github.com/OpenAccess-AI-Collective/axolotl. ‘YAML 설정 한 줄로 학습’. 한국 회사 ‘초보자용’ 권장.

STORY

한국 회사 파인튜닝 사례 (강사 대응용). 카카오·네이버·LG 같은 대기업은 자체 파인튜닝. 중견기업 — 일부 사내 도메인 (법무·인사·영업) 파인튜닝 사례. 비용 약 100~500만 원 1회 + 운영 별도. ROI는 ‘사내 사용량 큰 회사’에 가시적.

NOTE

★ 강사 핵심 배경지식 — 파인튜닝 5단계: (1) 데이터 수집 — 사내 문서 1,000~10,000건. (2) 라벨링 — ‘질문-답’ 쌍 만들기. 1주~1개월. (3) 학습 — 클라우드 GPU 임대 20~50시간. (4) 평가 — ‘우리 회사 톤 자연스럽게’. (5) 배포 — 사내 모델 교체. 약 1~2개월 1회.

NOTE

강사 배경지식 — 파인튜닝 vs RAG 차이: (1) 파인튜닝 — 모델 자체 학습. ‘회사 톤 자연스럽게’ 강점. ‘새 정보 빠른 반영’ 약점. (2) RAG — 모델 + 사내 문서 검색. ‘새 정보 즉시 반영’ 강점. ‘회사 톤 학습’ 부족. 둘 다 ‘우리 회사 AI 만들기’ 방법. 보통 ‘RAG 우선 → 6개월 후 파인튜닝’ 순서. 본 강좌 4편(챗봇·RAG)에서 자세히.

NOTE

강사 배경지식 — 파인튜닝 위험 4가지: (1) 데이터 품질 X — 잘못된 답 학습. (2) 과적합 — 학습 데이터만 잘하고 새 질문 X. (3) ‘회사 비밀 누설’ — 파인튜닝 데이터에 민감 정보 → 모델이 답에 노출. (4) 학습 비용 — 작은 회사 부담. 본 강좌 9편(보안)에서 자세히.

NOTE

강사 배경지식 — 파인튜닝 클라우드 옵션: (1) AWS SageMaker — GPU 임대 + 학습 도구. (2) Google Cloud Vertex AI — 비슷. (3) Hugging Face Inference Endpoints — 자체 UI. (4) Together AI — 가성비 (Hugging Face보다 50% 싸). 약 시간당 \$5~30 (H100 1장).

Q

예상 청중 질문 1: ‘우리 작은 회사도 파인튜닝 가능?’ → 답: ‘가능. 데이터 1,000건+ + 클라우드 GPU 100만 원이면 시작. 단 ‘ROI’ — 사내 사용량 큰 회사에 의미. 작은 사용량은 ‘일반 모델 그대로’ 충분.’

Q

예상 청중 질문 2: ‘우리 회사 비밀 모델에 학습되면 위험?’ → 답: ‘큰 위험. 파인튜닝 데이터에 ‘인사 평가·연봉·M&A’ 같은 민감 정보 포함 X. 익명화 + 일반화. 본 강좌 9편 자세히.’

Q

예상 청중 질문 3: ‘파인튜닝 vs RAG 우선순위?’ → 답: ‘RAG 우선 권장. RAG가 더 단순 + 새 정보 즉시. 파인튜닝은 ‘RAG 부족 부분’만. 본 강좌 4편이 RAG 자세히.’

TIP

강사 함정 — ‘파인튜닝이 만능’ X: 데이터 품질·비용·위험 모두 큼. ‘우리 회사 필요한가’ 신중.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘우리 회사 전용 AI’. 1~2분 5단계. 2~3분 비용·도구. 3~4분 ‘파인튜닝 vs RAG’. 4~5분 청중 질문. RAG 우선 메시지.

BRIDGE

“2강 마지막 — 실습. 우리 회사 한국어 모델 결정서.”

WORKSHOP 2

실습 — 우리 회사 한국어 모델 결정서

■ 적용 (워크시트)

- Q1 · 1강 글로벌 모델로 한국어 충분? (예 / 아니오)
- Q2 · 한국어 특화 도입한다면? (Bllossom 8B / Solar / EXAONE / KULLM)
- Q3 · 1개 운영 / 2개 운영(글로벌 + 특화)?
- Q4 · 6개월 후 파인튜닝 계획? (예 / 아니오 / 미정)
- ★ 종합 → 한국어 모델 결정 = ____
- ★ 다음 액션 — 결정서 IT부 전달, 모델 다운로드 + 테스트

🕒 9분 · 실습

SAY

“2강 실습 — 한국어 모델 결정서 5칸. 1강 ‘1순위 모델 결정서’ 보완.”

DO

조별 실습 (5분, 3~4인 1조). 5칸. Q1~Q4 + 종합.

SAY

“권장 매트릭스. (1) 1강 글로벌 + 한국어 충분 → 그대로. (2) 특화 필요 + 무료 우선 → Bllossom 8B. (3) 특화 필요 + 산업 → EXAONE 협의. (4) 특화 필요 + 일반 한국어 → Solar 협의. (5) 학술 R&D → KULLM.”

Q

발표 요청: “1~2조 발표. 한국어 모델 결정만.” → 다양한 답.

Q

발표 요청 2: “‘1강 글로벌 그대로’ 답 조? ‘특화 도입’ 답 조?” → 보통 반반. → ‘둘 다 정답. 회사 상황에 맞춰.’

NOTE

★ 강사 핵심 배경지식 — 결정서 5칸 작성 가이드: (1) Q1 — 1강 Qwen·Llama 사용해서 ‘우리 도메인 한국어’ 부족하면 ‘아니오’. (2) Q2 — Bllossom 8B가 ‘안전 기본값’. (3) Q3 — 시작은 1개, 6개월 후 2개 가능. (4) Q4 — 본격 도입 시 ‘6~12개월 후 파인튜닝’ 계획 권장.

NOTE

강사 배경지식 — 다음 주 액션 3가지: (1) 결정서 IT부 전달. (2) 모델 다운로드 + Ollama 설치 (1일). (3) 사내 5명 테스트 → 만족도 평가 (1~2주). 셋 다 2주 안에.

NOTE

강사 배경지식 — ‘테스트 만족도’ 평가 기준: (1) 한국어 자연스러움. (2) 우리 회사 용어 이해도. (3) 답 정확도. (4) 응답 속도. 5점 척도 평가 → 평균 4점+ 도입, 3점대 ‘다른 모델 추가 테스트’.

Q

예상 청중 질문 1: ‘1강 + 2강 동시 결정 어려운데?’ → 답: “1강은 Qwen 7B로 시작. 6개월 운영 후 한국어 도메인 부족 확인되면 Bllossom 8B 추가’ 단계별 권장.”

Q

예상 청중 질문 2: ‘파인튜닝 6개월 후 미정인데?’ → 답: “미정’ 정상. 6개월 운영하면서 ‘우리 도메인 필요한가’ 파악. 미리 결정 X.’

Q

예상 청중 질문 3: ‘우리 회사 한국어 95%인데 글로벌 모델 의미?’ → 답: “한국어 90~95%면 한국어 특화 의미 큼’. 단 1강 Qwen·Llama도 한국어 ‘좋은’ 수준 — 도메인 부족할 때만 특화.’

TIP

강사 함정 — ‘완벽 결정 압박’ X: ‘60% 답으로 시작’ 메시지.

TIP

강사 진행 팁 — 9분 시간 배분: 0~5분 개별. 5~7분 발표. 7~9분 액션. ‘1강 + 2강 종합 결정서’가 결과물.

BRIDGE

“2강 끝. 잠깐 쉬고 3강 ‘추론 엔진·양자화’로. 모델 정했으니 ‘어떻게 굴릴까.’”

WRAP

2강 정리 — 4개 한국어 모델

■ 마무리

- ① Solar (Upstage) — 한국 1위 인기, 라이선스 협의 필요
- ② EXAONE (LG) — 산업·기술 강점, 라이선스 협의
- ③ KULLM (고려대) — 학술·연구, Apache 2.0 자유
- ④ Bllossom (커뮤니티) — 본격 사내 가능, Llama 라이선스 자유
- ★ 추천 시작점 — Bllossom 8B (무료 + 자유 + 한국어 우수)
- ★ 다음 — 3강 추론 엔진·양자화 (Ollama·vLLM·llama.cpp·TGI)

🕒 3분 · 정리

SAY

“2강 정리. 한국어 특화 4종. Solar·EXAONE은 라이선스 협의 + 강점, KULLM·Bllossom은 자유 + 무료. 추천 시작점 — Bllossom 8B.”

SAY

“2강 핵심 메시지 — ‘한국어 특화는 좋은 옵션, 라이선스가 결정 핵심’. Solar·EXAONE은 ‘협업의 부담 + 품질’, Bllossom은 ‘자유 + 충분’.”

SAY

“3강 예고 — 모델 정했으니 ‘어떻게 굴릴까’. Ollama·vLLM·llama.cpp·TGI 4개 추론 엔진. + 양자화 (FP16 · INT8 · Q4) 메모리 절약.”

NOTE

★ 감사 핵심 배경지식 — 2강 끝 메시지: ‘한국어 특화는 무료 옵션도 있다 — Bllossom’. 라이선스 부담으로 ‘우리 못 한다’ 잘못된 결론 막기.

TIP

강사 진행 팁 — 3분 안에. 정리는 메시지 강조.

BRIDGE

“쉬는 시간 10분. 3강에서.”

INTRO · TITLE

추론 엔진 · 양자화

3강 — Ollama · vLLM · llama.cpp · TGI + Q4 양자화

🕒 3분 · 시작

SAY

“3강 ‘추론 엔진·양자화’입니다. 3편의 마지막. 1강 ‘무엇’, 2강 ‘한국어’, 3강 ‘어떻게 굴릴까’.”

SAY

“3강 60분 동안 다섯 가지를 봅니다 — (1) 추론 엔진이 뭐고 왜 필요한가, (2) Ollama, (3) vLLM, (4) llama.cpp + TGI, (5) 양자화 비교. 합쳐서 ‘우리 회사 추론 스택 1페이지’.”

SAY

“3강 약속 — ‘초보자 깊이’ 유지. ‘vLLM 설정 자세히’ X. ‘우리 회사가 어떤 추론 엔진 선택할지’ 결정 가능 수준이 목표.”

Q

도입 질문: “Ollama·vLLM 중 ‘이름은 들어본’ 분?” → 보통 Ollama만 일부. → ‘좋아요. Ollama가 초보자 1위. 단 본격 운영은 vLLM. 4개 다 알아두면 ‘우리에게 맞는 것’ 선택 가능.’

Q

도입 질문 2: “‘양자화’라는 말 들어본 분?” → 보통 거의 없음. → ‘오늘 3강이 ‘파라미터 $\times$ 0.6GB = VRAM’ 공식의 ‘ $\times$ 0.6’ 부분을 자세히. 메모리 절약의 핵심.’

NOTE

★ 강사 핵심 배경지식 — 3강 ‘기술 깊이’ 균형: 4개 추론 엔진 + 양자화 모두 복잡한 기술. 청중 부담 클 가능성. 대응 — (1) ‘우리 IT가 깔고 우리는 선택만’ 분리. (2) 비유 적극 — ‘Ollama = 자동차 자동 변속기, vLLM = 수동 변속기’ 같은. (3) ‘외울 것 5개 이하’.

NOTE

강사 배경지식 — 3강 60분 시간 배분: 0~3분 인트로. 3~6분 학습목표. 6~14분 추론 엔진이 뭐고 왜. 14~22분 Ollama. 22~30분 vLLM. 30~38분 llama.cpp + TGI. 38~48분 양자화. 48~54분 실습. 54~58분 마무리.

TIP

강사 함정 — 설치 명령 자세히 외우게 X: ‘우리는 결정 + 운영자가 설치’ 분리. 명령 디테일은 IT부 학습.

BRIDGE

“학습 목표 빠르게.”

OBJECTIVES

60분 후, 이 3가지를 한다

- ① 추론 엔진 4종(Ollama·vLLM·llama.cpp·TGI)의 차이를 안다
- ② 양자화(FP16·INT8·Q4·Q3) 메모리 절약 원리를 설명한다
- ③ ‘우리 회사 추론 스택 1페이지’ 결정

🕒 3분 · 학습목표

SAY

“60분 후 셋. 추론 엔진 4종 차이, 양자화 4단계, 우리 회사 추론 스택 결정.”

SAY

“3편 전체 마무리 — 모델(1·2강) + 추론 엔진(3강) = ‘완전한 자체 호스팅 스택’. 2편 인프라 + 3편 모델·추론 = ‘자체 호스팅 도입 완성판’.”

NOTE

★ 강사 핵심 배경지식 — 3강 성공 기준: 청중이 ‘우리 사내 IT가 어떤 도구 깔지’ 결정 가능. ‘직접 설치’가 아니라 ‘선택 가능’.

NOTE

강사 배경지식 — 4개 엔진 + 양자화 분담: 추론 엔진은 ‘모델을 어떻게 실행’, 양자화는 ‘모델을 어떻게 줄임’. 둘 다 ‘VRAM·속도’에 영향. 합쳐서 ‘우리 GPU에서 어떤 모델 굴릴 수 있나’ 결정.

TIP

강사 진행 팁 — 학습 목표 3분 안에.

BRIDGE

“본문 시작 — ‘추론 엔진이 뭐고 왜 필요한가’.”

WHY ENGINE

추론 엔진이 뭐고 왜 필요한가

■ 불변층 — 모델 ‘껍데기’의 역할

- PyTorch 직접 (추론 엔진 없이) — Hugging Face Transformers로 직접 로딩. 가능. 단 — 메모리 비효율, 속도 느림, 다중 사용자 처리 X. ‘1명 테스트’만 OK.
- Ollama·vLLM 등 (추론 엔진 사용) — GPU 메모리 효율, 다중 사용자 처리, 자동 양자화. 사내 사용에 필수. ‘챗봇 50명 동시 사용’ 같은 운영 가능.

⌚ 6분 · 추론 엔진 필요성

SAY

“본문 1번 — 추론 엔진이 뭐고 왜 필요한가요입니다.”

SAY

“‘추론(Inference)’ = 학습된 모델이 ‘새 질문에 답 만들기’. ‘학습(Training)’의 반대. 우리가 사내 챗봇 사용 = ‘추론’.”

SAY

“‘추론 엔진’ = 추론을 효율적으로 실행하는 도구. PyTorch 직접 실행도 가능, 단 비효율.”

SAY

“추론 엔진 없이 PyTorch 직접 — 메모리 비효율, 속도 느림, 다중 사용자 처리 X. ‘1명 테스트’만 OK.”

SAY

“추론 엔진 사용 — GPU 메모리 효율, 다중 사용자, 자동 양자화. ‘챗봇 50명 동시’ 같은 운영 가능.”

SAY

“원칙 — 자체 호스팅 본격 운영 시 ‘추론 엔진 필수’. ‘PyTorch만’ 한국 회사 거의 X.”

STORY

추론 엔진 기술 발전 (강사 대응용). 2022~2023 — Hugging Face Transformers가 표준. '1 GPU 1 사용자' 한계. 2023 — vLLM 등장, PagedAttention으로 '1 GPU 여러 사용자' 가능. 2023 후반 — Ollama 등장, '초보자 1줄 설치' 가능. 2024 — TGI 안정화, 엔터프라이즈 운영. 매년 진화.

STORY

PagedAttention 출처. UC Berkeley 'PagedAttention: SOSP 2023 논문'. URL: arxiv.org/abs/2309.06180. 'OS의 메모리 페이징' 아이디어를 GPU KV cache에 적용. 메모리 효율 2~4배. vLLM의 핵심 기술.

STORY

한국 회사 추론 엔진 도입 (강사 대응용 추정). Ollama 약 60% (초보자·소규모). vLLM 약 25% (본격 운영). llama.cpp 약 10% (CPU·맥북). TGI 약 5% (엔터프라이즈). Ollama 1위 — 초보자 진입 장벽 낮음.

NOTE

★ 강사 핵심 배경지식 — 'KV cache' 풀이: AI가 답을 만들 때 '이전 단어 기억' 저장 공간. 'key-value cache'. VRAM 큰 부분 차지 — 모델 자체 외에. 1명 사용자 1MB+, 50명 동시면 50MB+. 추론 엔진의 핵심 효율 포인트.

NOTE

강사 배경지식 — '배치(batch)' 풀이: 여러 사용자 요청을 한 번에 처리. 1명씩 처리 = 1초당 50 토큰. 50명 배치 = 1초당 $50 \times 50 = 2,500$ 토큰. 처리량 50배. 단 '50명 동시 메모리' 필요. 추론 엔진이 '동적 배치' 자동.

NOTE

강사 배경지식 — 4개 엔진 위치: (1) Ollama — 초보자, 1줄 설치, 소규모. (2) vLLM — 본격 운영, 50~500명 동시, '프로페셔널'. (3) llama.cpp — CPU·맥북·임베디드, '저자원'. (4) TGI — Hugging Face, 엔터프라이즈, 클라우드 패키지. 용도별.

NOTE

강사 배경지식 — '서빙(serving)' 풀이: 사용자 요청 받고 답 보내는 '서비스' 운영. '추론 엔진' = 서빙 엔진. 웹 서버(Nginx)와 비슷한 역할 — 단 'AI 모델 전용'. REST API로 응답.

Q

예상 청중 질문 1: ‘PyTorch만으로 안 되나?’ → 답: ‘1명 테스트는 OK. 10명+ 동시 사용은 PyTorch 직접 = 메모리·속도 한계. 추론 엔진 필수.’

Q

예상 청중 질문 2: ‘우리 IT가 모르는 도구다.’ → 답: ‘Ollama 1줄 설치. 1시간 학습으로 시작 가능. 본격 운영 vLLM은 1주 학습. 진입 장벽 낮음.’

Q

예상 청중 질문 3: ‘여러 엔진 동시 운영?’ → 답: ‘권장 X. 첫 도입 1개. 6개월 운영 후 ‘부족’ 확인되면 갈아타기. 동시 운영은 ‘작은 + 큰’ 분리 같은 특수 케이스.’

TIP

강사 함정 — 기술 디테일 깊이 X: ‘추론 엔진 = 운영 도구’ 메시지만. PagedAttention·KV cache 디테일은 강사 배경지식, 청중에게 안 강조.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘추론’ 풀이. 1~3분 ‘없으면 / 있으면’. 3~4분 4개 엔진 위치. 4~5분 한국 분포. 5~6분 청중 질문. 비유 적극.

BRIDGE

“추론 엔진 필요성 봤다면 — 첫 번째 Ollama. 초보자 1위.”

OLLAMA

Ollama — 초보자 1위

■ 불변층 — 가장 단순한 추론 엔진

- ★ 한 줄 설치 — ‘curl -fsSL ollama.ai/install.sh | sh’
- ★ 한 줄 실행 — ‘ollama run llama3.3’ → 모델 자동 다운로드 + 챗봇 시작
- ★ 모델 라이브러리 — Llama·Qwen·Mistral·DeepSeek·Solar·Blossom 다 지원
- ★ 자동 양자화 — Q4 기본, GPU 메모리 맞춤
- ★ REST API 자동 제공 — Open WebUI·Dify 같은 UI와 즉시 연결
- ★ 한계 — 동시 50명+ 본격 운영엔 부족. vLLM으로 갈아탐

SAY

“추론 엔진 첫 번째 — Ollama. 초보자에게 가장 적합.”

SAY

“핵심 — ‘한 줄 설치 + 한 줄 실행’. ‘curl -fsSL ollama.ai/install.sh | sh’ 한 줄 설치. ‘ollama run llama3.3’ 한 줄로 모델 다운로드 + 챗봇 시작.”

SAY

“모델 라이브러리 풍부 — Llama, Qwen, Mistral, DeepSeek, Solar, Bllossom 다 지원. Hugging Face 모델 거의 다 ‘Ollama 호환 변환’ 가능.”

SAY

“자동 양자화 — Q4 기본. ‘파라미터 × 0.6GB = VRAM’ 공식이 Ollama 기본값. GPU 메모리에 맞춰 자동.”

SAY

“REST API 자동 제공 — Ollama가 백엔드 서버 역할. Open WebUI·Dify 같은 챗봇 UI에 즉시 연결. ‘Ollama + Open WebUI’ = 한국 자체 호스팅 표준 시작점.”

SAY

“한계 — ‘동시 50명+ 본격 운영’엔 부족. 처리량 한계. 50명 동시 = 응답 느림. 본격 운영은 vLLM 권장.”

STORY

Ollama 출처. 2023 출시. URL: ollama.ai, github.com/ollama/ollama. ‘로컬에서 LLM을 쉽게’ 컨셉. llama.cpp 기반 + 한 줄 인터페이스. 한국 자체 호스팅 도입 시 약 60% 점유.

STORY

Ollama 사용 시나리오 (강사 대응용). (1) 첫 도입 — ‘Ollama + Open WebUI = 5명 사내 챗봇’. (2) 개발팀 — ‘Ollama + 자체 코딩’ 어시스턴트. (3) 데모 — ‘1시간 만에 ChatGPT 같은 UI’. 단 ‘50명+ 운영’은 vLLM 갈아타기 추세.

STORY

Ollama 모델 라이브러리 (강사 대응용). URL: ollama.ai/library. 약 200개+ 모델. Llama 3.3 70B, Qwen 2.5 7B/14B/32B/72B, Mistral 7B, Mixtral 8x7B, DeepSeek-R1, Phi 3, Gemma 2, Solar 10.7B, Blllossom 8B 등. 한 줄로 다운로드.

NOTE

★ 강사 핵심 배경지식 — Ollama의 ‘자동’ 4가지: (1) 자동 다운로드 — 모델 자동 받음. (2) 자동 양자화 — Q4 기본. (3) 자동 메모리 관리 — GPU/CPU 자동 분배. (4) 자동 API 제공 — REST 즉시. 초보자 진입 장벽 최소화.

NOTE

강사 배경지식 — Ollama 한계 시점: 동시 사용자 약 10~20명까지 OK. 30명+ 시작 — 응답 느려짐 + GPU 메모리 초과. ‘우리 회사 30명+ 챗봇’ 예상되면 vLLM 시작 권장. ‘Ollama 시작 → vLLM 갈아타기’ 패턴.

NOTE

강사 배경지식 — Open WebUI 풀이: Ollama 위에 ‘ChatGPT 같은 UI’. 무료 오픈소스. Docker 한 줄 설치. ‘Ollama + Open WebUI’가 한국 자체 호스팅 ‘기본 셋’. 본 강좌 4편(챗봇·RAG)에서 자세히. URL: openwebui.com.

NOTE

강사 배경지식 — Ollama 일상 명령 (강사 대응용): (1) ‘ollama list’ — 설치된 모델. (2) ‘ollama run <모델>’ — 실행. (3) ‘ollama pull <모델>’ — 다운로드만. (4) ‘ollama rm <모델>’ — 삭제. (5) ‘systemctl status ollama’ — 서버 상태. 5개 명령으로 일상 운영.

Q

예상 청중 질문 1: ‘Ollama vs vLLM 우리 회사?’ → 답: ‘5~20명이면 Ollama, 30명+면 vLLM. 시작은 Ollama 권장 — 빠른 시작 + 운영 학습.’

Q

예상 청중 질문 2: ‘Ollama Windows에서 가능?’ → 답: ‘Windows 가능 — 단 WSL2(Windows Subsystem for Linux) 권장. macOS도 가능. Linux가 가장 안정.’

Q

예상 청중 질문 3: ‘Ollama 모델 수동 추가 가능?’ → 답: ‘가능. Hugging Face에서 다운 + Modelfile 작성 + ollama create. 약간 학습 필요 (1시간). 기본 200개 모델로 시작 권장.’

TIP

강사 함정 — Ollama 디테일 깊이 X: ‘한 줄 설치 가능’ 메시지만. 디테일은 IT부.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘초보자 1위’. 1~2분 한 줄 설치·실행. 2~3분 자동 4가지. 3~4분 한계. 4~5분 ‘Ollama + Open WebUI 셋’. 5~6분 청중 질문. ‘우리 시작 도구’ 강조.

BRIDGE

“Ollama 봤다면 — 본격 운영용 vLLM. 동시 50~500명.”

vLLM

vLLM — 본격 운영용

■ 불변증 — PagedAttention으로 효율 혁신

- ★ UC Berkeley 발 (2023) — ‘PagedAttention’ 핵심 기술
- ★ 처리량 — Hugging Face Transformers 대비 2~4배
- ★ 동시 사용자 — 50~500명 OK (GPU·모델 크기 의존)
- ★ 양자화 지원 — FP16·INT8·AWQ·GPTQ·FP8 다양
- ★ OpenAI API 호환 — ‘OpenAI 클라이언트 코드 그대로’ 사내 사용
- ★ 한계 — 설치·운영 학습 1~2주, Linux + CUDA 필수

🕒 6분 · vLLM

SAY

“추론 엔진 두 번째 — vLLM. 본격 운영용. UC Berkeley 발입니다.”

SAY

“핵심 기술 — PagedAttention. ‘OS의 메모리 페이징’ 아이디어를 GPU KV cache에 적용. 메모리 효율 2~4배. 같은 GPU에 50명+ 동시.”

SAY

“처리량 — Hugging Face Transformers 대비 2~4배. ‘1초당 100명 답’ 같은 성능 가능. 동시 50~500명 (GPU·모델 크기 의존).”

SAY

“양자화 지원 — FP16(원본), INT8, AWQ(가중치 양자화), GPTQ(다른 양자화), FP8(엔비디아 H100 신규) 다양. ‘우리 GPU에 맞는 양자화’ 선택.”

SAY

“OpenAI API 호환 — ‘OpenAI 클라이언트 코드 그대로’ 사내 사용. 즉 — 외부 ChatGPT 호출 코드를 ‘API 주소만 사내 vLLM으로 변경’하면 동작. 빠른 전환.”

SAY

“한계 — Ollama처럼 한 줄 X. 설치·운영 학습 1~2주. Linux + CUDA 필수. Windows·macOS는 지원 약함.”

STORY

vLLM 출처. UC Berkeley Sky Computing Lab 2023. 'PagedAttention' 논문 SOSP 2023 발표. URL: vllm.ai, github.com/vllm-project/vllm. 'LMSYS Chatbot Arena' 엔진도 vLLM. 2024년 본격 인기.

STORY

PagedAttention 디테일 (강사 대응용). 기존 — KV cache가 ‘연속 메모리 블록’ — 메모리 단편화. 새 사용자 추가 시 효율 X. PagedAttention — ‘작은 블록(페이지)’으로 나눠 관리. OS 가상 메모리 아이디어. 메모리 효율 2~4배. 동시 사용자 5~10배.

STORY

한국 vLLM 도입 사례 (강사 대응용). 카카오·네이버 같은 대기업 사내 챗봇·코드 어시스턴트 vLLM 운영. 중견 기업 — ‘본격 사내 챗봇 + RAG’ 시작 시 Ollama → vLLM 갈아타기. ‘50명+ 동시’ 운영의 표준.

STORY

vLLM 설치 (강사 대응용). ‘pip install vllm’ 명령 시작 — 단 CUDA·PyTorch 의존성 복잡. 권장 — Docker 이미지 사용 (vllm/vllm-openai). ‘docker run vllm/vllm-openai --model meta-llama/Llama-3.3-70B-Instruct’ 식. 약 1시간 첫 설치.

NOTE

★ 강사 핵심 배경지식 — vLLM vs Ollama 결정 기준: (1) 동시 사용자 < 20명 — Ollama. (2) 20~50명 — 양쪽 가능, IT 역량 보고. (3) 50명+ — vLLM. (4) IT 학습 시간 부족 — Ollama. (5) 본격 사내 표준 — vLLM. ‘시작 Ollama → 본격 vLLM’ 표준 패턴.

NOTE

강사 배경지식 — vLLM ‘OpenAI 호환 API’의 의미: 기존 — ChatGPT 사용 회사가 ‘chatgpt_api_call(prompt)’ 코드 다수. 클라우드 → 자체 호스팅 전환 시 ‘코드 다 다시 작성’? — vLLM이 OpenAI API 응답 형식 동일 제공 → ‘API URL만 사내’로 변경. 코드 그대로. 마이그레이션 비용 최소.

NOTE

강사 배경지식 — vLLM ‘다중 GPU’ 지원: 큰 모델 (70B+) 1 GPU 안 들어감. vLLM이 ‘여러 GPU에 모델 나누기’ 지원. ‘Tensor Parallelism’ 자동. 4090 4장 + Llama 70B 분산 가능. 설정 ‘--tensor-parallel-size 4’ 한 줄.

NOTE

강사 배경지식 — vLLM 양자화 옵션 디테일: (1) FP16 — 원본, 큰 메모리. (2) INT8 — 약간 압축. (3) AWQ — 가중치만 양자화, 정확도 우수. (4) GPTQ — 다른 가중치 양자화, 빠름. (5) FP8 — H100 신규 옵션. ‘AWQ Q4’가 ‘품질·메모리 균형 최적’ — 본격 운영 권장.

Q

예상 청중 질문 1: ‘우리 시작은 Ollama, 6개월 후 vLLM 갈아탐 자연스러운가?’ → 답: ‘자연스러움. 단 ‘모델 변경’ 시 RAG 데이터 호환 X — 다시 처리. 갈아탐은 IT부 1주 작업.’

Q

예상 청중 질문 2: ‘vLLM 직접 설치 vs Docker?’ → 답: ‘Docker 권장. vLLM 의존성(CUDA·PyTorch) 복잡 — Docker가 ‘완성된 환경’. 한 번에 실행 가능.’

Q

예상 청중 질문 3: ‘vLLM 한국어 모델 OK?’ → 답: ‘완전 지원. Hugging Face 모델 거의 다 vLLM 호환. Qwen·Llama·Solar·Bllossom 모두 OK.’

TIP

강사 함정 — vLLM 설정 디테일 X: ‘본격 운영용’ 메시지만. 설치는 IT부.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘본격 운영용’. 1~2분 PagedAttention. 2~3분 처리량 + 양자화. 3~4분 OpenAI 호환. 4~5분 한계 + 학습 시간. 5~6분 청중 질문. 50명+ 메시지.

BRIDGE

“vLLM 봤다면 — llama.cpp(CPU·맥북) + TGI(엔터프라이즈) 빠르게.”

LLAMACPP·TGI

llama.cpp · TGI — 특수 용도

■ 불변증 — 두 옵션의 위치

- CPU · 맥북 · 임베디드 (llama.cpp) — GGUF 포맷, CPU 추론 1위, Apple Silicon(M1·M2·M3) 최적화. 무료 + 오픈소스. ‘GPU 없는 환경’에 핵심. 맥북에서 Llama 70B 가능. Ollama의 백엔드.
- Hugging Face · 엔터프라이즈 (TGI (Text Generation Inference)) — Hugging Face 공식 추론 엔진. 클라우드 · Inference Endpoints 백엔드. vLLM과 경쟁. 안정성 · 문서 풍부, 엔터프라이즈 운영. 단 사내 학습 부담은 vLLM과 비슷.

⌚ 6분 · llama.cpp + TGI

SAY

“추론 엔진 셋째·넷째 — llama.cpp와 TGI. 특수 용도.”

SAY

“llama.cpp — Gerganov(개인 개발자) 발. ‘CPU에서 LLM 실행’ 컨셉. C++로 작성, GGUF 양자화 포맷. ‘CPU 추론 1위’ 위치.”

SAY

“llama.cpp 강점 — Apple Silicon(M1·M2·M3) 최적화. 맥북에서 Llama 70B 가능. ‘GPU 없는 환경’ 핵심. Ollama의 실제 백엔드.”

SAY

“llama.cpp 용도 — (1) 맥북 사내 AI. (2) IoT·임베디드. (3) ‘GPU 없는 사무실 PC에서 Llama 8B’. 특수 환경.”

SAY

“TGI (Text Generation Inference) — Hugging Face 공식 추론 엔진. ‘Hugging Face Inference Endpoints’의 백엔드. vLLM과 경쟁 위치.”

SAY

“TGI 강점 — 안정성 + 문서 풍부. Hugging Face 생태계 통합. 단 ‘사내 학습 부담’은 vLLM과 비슷 — 1~2주.”

SAY

“TGI vs vLLM — 둘 다 본격 운영. 차이 — vLLM이 ‘오픈소스 1위·커뮤니티 활발·연구 트렌드’, TGI가 ‘엔터프라이즈 안정·Hugging Face 통합·문서’. 한국 회사 ‘vLLM 도입’이 약 5배 더 많음.”

STORY

llama.cpp 출처. Ggerganov 개인 개발자 2023 시작. URL: github.com/ggerganov/llama.cpp. C++ 작성, CPU·GPU·Apple Silicon 다 지원. GGUF(GPT-Generated Unified Format) 양자화 표준. Ollama의 백엔드. 별 80,000+ (GitHub 인기 상위).

STORY

TGI 출처. Hugging Face 공식 2022 시작. URL: github.com/huggingface/text-generation-inference. Rust 작성, 엔터프라이즈 안정성. Hugging Face Inference Endpoints (클라우드 추론 서비스) 백엔드. URL: huggingface.co/inference-endpoints.

STORY

한국 llama.cpp 사례 (강사 대응용). 맥북 개발자 자체 사용 + 개인 자체 호스팅 위주. 사내 본격 도입 사례 적음 — 단 ‘CPU 사내 PC + Llama 8B’ 같은 특수 케이스. Ollama 통해 간접 사용 흔함.

STORY

한국 TGI 사례 (강사 대응용). 카카오·네이버 일부 사내 배포. ‘Hugging Face 클라우드’ 사용 회사가 ‘자체 호스팅 전환’ 시 TGI 자연스러움. 단 한국 ‘vLLM 채택률’이 더 큼.

NOTE

★ 강사 핵심 배경지식 — llama.cpp ‘GGUF’ 풀이: GGUF = ‘GPT-Generated Unified Format’.
llama.cpp의 양자화 포맷. ‘모델 1개 파일’ 형식. (1) Q4_K_M — 4비트, 중간 품질, 가장 인기. (2) Q5_K_M — 5비트, 더 높은 품질. (3) Q8_0 — 8비트, 거의 원본. Hugging Face에서 ‘GGUF’ 검색 → 다양한 양자화 다운로드.

NOTE

강사 배경지식 — Apple Silicon (M1·M2·M3) LLM 효율: Apple Silicon ‘통합 메모리 아키텍처(Unified Memory)’. CPU·GPU·NPU가 같은 메모리. 32GB·64GB·128GB·192GB 옵션. ‘맥북 64GB로 Llama 70B GGUF Q4 가능’. M2 Ultra·M3 Max는 ‘Mini PC’ 자체 호스팅 대안. 단 — 일반 사내 운영에는 Linux + NVIDIA가 표준.

NOTE

강사 배경지식 — TGI vs vLLM 비교 디테일: (1) 처리량 — 비슷 (둘 다 본격). (2) 안정성 — TGI 약간 우수 (Hugging Face 운영). (3) 양자화 — vLLM 더 다양. (4) 커뮤니티 — vLLM이 더 활발. (5) 문서 — TGI 우수. (6) 한국어 모델 호환 — 둘 다 OK. 한국 추세 — vLLM.

NOTE

강사 배경지식 — ‘Triton Inference Server’ (강사 대응용): NVIDIA의 엔터프라이즈 추론 서버. TGI·vLLM 같은 위치. NVIDIA GPU 풀스택 통합. 대기업 도입 추세. 본 강좌 11편(관리자) 자세히. 일반 한국 회사는 vLLM·Ollama 중심.

Q

예상 청중 질문 1: ‘우리는 맥북 사무실인데 llama.cpp?’ → 답: ‘맥북 사내 사용은 llama.cpp 직접 또는 Ollama(llama.cpp 백엔드) 권장. 64GB M2/M3 Pro면 Llama 70B 가능.’

Q

예상 청중 질문 2: ‘TGI Hugging Face라서 신뢰?’ → 답: ‘맞아요. 단 vLLM도 충분히 안정. ‘Hugging Face 통합’ 우선이면 TGI, ‘오픈소스 표준’ 우선이면 vLLM. 한국은 vLLM 우세.’

Q

예상 청중 질문 3: ‘4개 엔진 외 다른 옵션?’ → 답: ‘NVIDIA Triton, TensorRT-LLM, FasterTransformer, Hugging Face Text Embeddings Inference 등. 본격 엔터프라이즈에 검토. 본 강좌 11편 자세히. 일반 사내 — 4개로 충분.’

TIP

강사 함정 — llama.cpp·TGI 디테일 X: ‘위치만 알면 됨’ 메시지. 시작은 Ollama·vLLM.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 두 옵션 위치. 1~3분 llama.cpp (CPU·맥북). 3~5분 TGI (엔터프라이즈). 5~6분 청중 질문. ‘특수 용도’ 강조.

BRIDGE

“4개 추론 엔진 다 봤다면 — 마지막. ‘양자화’ 4단계로 메모리 절약.”

QUANTIZATION

양자화 — FP16 · INT8 · Q4 · Q3

■ 불변증 — 메모리 절약의 핵심

- FP16 원본 정확도 · 70B = 140GB — 16비트 부동소수점. 모델 원본 정확도. 70B 모델 = 140GB VRAM. H100 2장 필수. 정밀도 우선·연구·R&D.
- INT8 95% 정확도 · 70B = 70GB — 8비트 정수. 약 5% 정확도 감소. 70B = 70GB. H100 1장. 본격 운영에 ‘안전 균형’.
- Q4 90% 정확도 · 70B = 42GB — 4비트. ‘파라미터 × 0.6GB’ 공식의 기준. 90% 정확도. 70B = 42GB. RTX 4090×2 가능. ‘한국 자체 호스팅 표준’.
- Q3 / Q2 85·75% 정확도 · 70B = 32·22GB — 3·2비트. ‘극단 양자화’. 정확도 감소 큼. ‘맥북·임베디드 등 메모리 절대 부족’ 환경. 일반 사내 비권장.

🕒 6분 · 양자화

SAY

“추론 엔진 다 봤다면 — 마지막. 양자화로 메모리 절약. 4단계 — FP16, INT8, Q4, Q3.”

SAY

“원리 — 모델 가중치를 ‘몇 비트로 표현’하는가. 비트 적을수록 메모리 적음 + 정확도 감소.”

SAY

“FP16 — 16비트. 원본 정확도. 70B 모델 = 140GB. H100 2장. 정밀도 우선·연구·R&D.”

SAY

“INT8 — 8비트. 약 5% 정확도 감소. 70B = 70GB. H100 1장. 본격 운영 ‘안전 균형’.”

SAY

“Q4 — 4비트. ‘파라미터 × 0.6GB’ 공식 기준. 90% 정확도. 70B = 42GB. RTX 4090×2 가능. ‘한국 자체 호스팅 표준’.”

SAY

“Q3·Q2 — 3·2비트. 정확도 감소 큼 (15·25%). 맥북·임베디드 ‘메모리 절대 부족’ 환경. 일반 사내 비권장.”

SAY

“권장 — 본격 운영 ‘Q4 또는 INT8’. 둘 사이 — Q4가 메모리 절반 + 90% 정확도. 한국 자체 호스팅 표준은 Q4.”

STORY

양자화 기술 출처. ‘LLM.int8()’ Hugging Face Tim Dettmers 2022. URL: arxiv.org/abs/2208.07339. ‘큰 모델 INT8 양자화 가능’ 첫 입증. 이후 ‘GPTQ’, ‘AWQ’, ‘bitsandbytes’ 등 다양한 4비트 양자화 도구.

STORY

AWQ vs GPTQ 차이 (강사 대응용). 둘 다 4비트. AWQ — Activation-aware Weight Quantization. 정확도 약간 우수. GPTQ — GPT Quantization. 속도 약간 빠름. 일반 사내 — 둘 다 90%+ 정확도, 큰 차이 X. vLLM 은 둘 다 지원.

STORY

‘Q4_K_M’·‘AWQ Q4’ 같은 표기 (강사 대응용). 다양한 양자화 도구별 표기 다름. (1) llama.cpp GGUF — Q4_K_M, Q5_K_M 등. (2) AutoGPTQ — GPTQ 4-bit. (3) AutoAWQ — AWQ 4-bit. 같은 ‘4비트’이지만 알고리즘 다름. Hugging Face 모델 페이지에 명시.

NOTE

★ 강사 핵심 배경지식 — ‘비트’와 메모리 관계: 16비트 = 2바이트. 8비트 = 1바이트. 4비트 = 0.5바이트. 모델 가중치 70B개 × 4비트 = 280억 비트 = 35GB. 거기에 KV cache·overhead = 42GB. ‘파라미터 × 0.6GB’ 공식의 ‘0.6’이 이 계산.

NOTE

강사 배경지식 — 양자화 ‘정확도 감소’ 정성 평가: (1) Q4 — 일반 사용자 ‘차이 거의 못 느낌’. (2) Q3 — ‘약간 어색한 답’ 가끔. (3) Q2 — ‘분명히 못한 답’ 자주. 일반 사내 ‘Q4 충분’ — 정확도 부족 안 느낌. 본 강좌 청중에게 ‘Q4 표준’ 메시지.

NOTE

강사 배경지식 — ‘양자화 비대상’: 모델 가중치만 양자화. KV cache, embedding(임베딩) 등은 보통 원본. 일부 양자화 도구는 KV cache 양자화 옵션도 — 본 강좌에서는 ‘가중치 양자화만’ 가정.

NOTE

강사 배경지식 — 정밀 작업 시 양자화 선택: (1) 사내 챗봇·문서 RAG — Q4 충분. (2) 법무 분석·의료 진단·과학 연구 — INT8 또는 FP16. (3) 코드 어시스턴트 — Q4도 가능, 단 INT8 권장. 도메인 정밀도 요구에 따라 선택.

Q

예상 청중 질문 1: ‘Q4가 표준이라면 그냥 Q4?’ → 답: ‘맞아요. 처음 도입 Q4 시작. 6개월 운영 후 ‘정확도 부족’ 확인되면 INT8 업그레이드.’

Q

예상 청중 질문 2: ‘Q3는 절대 X?’ → 답: ‘맥북·임베디드 메모리 절대 부족 환경에만. 일반 사내 X. ‘Llama 70B를 RTX 4090 1장에서 돌리고 싶다 → Q3’ 정도. 정확도 부족 감수.’

Q

예상 청중 질문 3: ‘양자화 직접 해야?’ → 답: ‘아니. Hugging Face에 ‘이미 양자화된 모델’ 다수. ‘Qwen 2.5 7B AWQ Q4’ 같은 검색 → 다운로드. 또는 Ollama 자동 양자화.’

TIP

강사 함정 — 양자화 알고리즘 디테일 X: ‘Q4 표준’ 메시지만. AWQ·GPTQ 등은 IT부.

TIP

강사 진행 팁 — 6분 시간 배분: 0~1분 ‘4단계 비트’. 1~3분 각 디테일. 3~4분 ‘Q4 표준’ 메시지. 4~5분 도메인 별 선택. 5~6분 청중 질문. ‘Q4’ 외울 한 단어.

WORKSHOP 3

실습 — 우리 회사 추론 스택 1페이지

■ 적용 (워크시트)

- ① 추론 엔진 — Ollama / vLLM / llama.cpp / TGI 중?
- ② 양자화 — FP16 / INT8 / Q4 / Q3 중?
- ③ UI 도구 — Open WebUI / Dify / LibreChat / 자체 개발?
- ④ 동시 사용자 예상 — 5명 / 30명 / 100명+?
- ⑤ 백업 모델 — 1개 운영 / 2개(글로벌 + 한국어)?
- ★ 다음 액션 — IT부 1주 안 Ollama+Open WebUI 설치

🕒 8분 · 실습

SAY

“3강 실습 — 추론 스택 5칸. 3편의 결론 워크시트.”

DO

조별 실습 (5분, 3~4인 1조). 5칸 + 다음 액션.

SAY

“권장 매트릭스. 5~20명 — Ollama + Q4 + Open WebUI. 30~100명 — vLLM + Q4 또는 INT8 + Open WebUI. 100명+ — vLLM + INT8 + 자체 개발 UI. 맥북 — llama.cpp + Q4_K_M.”

Q

발표 요청: “추론 엔진 + UI 한 줄로?” → 보통 ‘Ollama + Open WebUI’. → ‘좋습니다. 한국 자체 호스팅 표준 시작.’

NOTE

★ 강사 핵심 배경지식 — 추론 스택 5칸 작성 가이드: (1) 엔진 — 시작 Ollama 권장. (2) 양자화 — Q4 표준. (3) UI — Open WebUI 무료. (4) 동시 사용자 — 챔피언 5명 → 부서 30명 → 본격 100명+ 단계별. (5) 백업 모델 — 1개 시작, 6개월 후 2개 검토.

NOTE

강사 배경지식 — 다음 주 액션 3가지: (1) IT부에 추론 스택 결정서 전달. (2) Ollama + Open WebUI 1주 안 설치 (Docker 1줄). (3) 챔피언 5명 테스트 + 만족도 평가. 셋 다 2주 안에 시작.

NOTE

강사 배경지식 — Open WebUI 설치 (강사 대응용): ‘docker run -d -p 3000:8080 --add-host=host.docker.internal:host-gateway -v open-webui:/app/backend/data --name open-webui -restart always ghcr.io/open-webui/open-webui:main’. 1줄. 5분에 완료. http://서버:3000 접속 시 ChatGPT 같은 UI.

Q

예상 청중 질문 1: ‘우리는 100명+ 예상인데 처음부터 vLLM?’ → 답: ‘권장 X. Ollama 시작 → 1개월 안에 ‘처리량 한계’ 체감 후 vLLM 갈아탐. ‘바로 vLLM’은 IT 학습 부담 큼. 단 IT 강한 회사면 처음부터 vLLM도 OK.’

Q

예상 청중 질문 2: ‘UI 자체 개발 vs Open WebUI?’ → 답: ‘Open WebUI 권장. 무료 + ChatGPT 같은 UI + RAG·MCP 지원. 자체 개발은 ‘디자인·기능 특수’ 회사에만.’

Q

예상 청중 질문 3: ‘양자화 직접 선택 가능?’ → 답: ‘Ollama 기본 Q4 자동. vLLM은 명령에 ‘--quantization awq’ 지정. Hugging Face ‘Qwen 2.5 7B AWQ Q4’ 같은 모델 직접 다운로드도 OK.’

TIP

강사 함정 — ‘완벽 결정 압박’ X: ‘Ollama + Open WebUI 시작 → 6개월 운영 후 결정’ 메시지.

TIP

강사 진행 팁 — 8분 시간 배분: 0~5분 개별. 5~7분 발표. 7~8분 ‘다음 주 액션’.

PART 3 WRAP

3편 정리 — 모델 + 추론 4장

■ 마무리 + 4편 예고

- 1강 — 1순위 모델 결정서 (Llama·Qwen·Mistral·DeepSeek·GPT-OSS)
- 2강 — 한국어 모델 결정서 (Solar·EXAONE·KULLM·Bllossom)
- 3강 — 추론 스택 1페이지 (Ollama·vLLM + Q4 + Open WebUI)
- ★ 1·2편 + 3편 합치면 ‘자체 호스팅 도입 7장 마스터 계획’
- ★ 추천 시작 셋 — Qwen 7B + Ollama + Q4 + Open WebUI
- ★ 4편(챗봇·RAG) — 사내 직원이 매일 쓰는 UI + 사내 문서 학습

🕒 5분 · 마무리

SAY

“3편 마무리. 3강 동안 ‘1순위 모델 + 한국어 모델 + 추론 스택’ 3장이 손에 남았어요. 1편(왜) + 2편(인프라 3장) + 3편(모델·추론 3장) = ‘자체 호스팅 도입 7장 마스터 계획’.”

SAY

“추천 시작 셋 — Qwen 2.5 7B + Ollama + Q4 + Open WebUI. 4개 결정이 결합된 ‘한국 자체 호스팅 표준 시작’. 약 1주일 안 IT부 설치 가능.”

SAY

“다음 주 액션 3가지. (1) 7장 마스터 계획 사장님 보고. (2) 건적 의뢰 + 발주. (3) 동시에 IT부 Ollama 설치 시작. 셋 다 2주 안에.”

SAY

“4편 예고 — ‘챗봇·RAG 플랫폼’. 3편이 ‘엔진(모델 + 추론)’이었다면 4편은 ‘사용자 인터페이스 + 사내 문서 학습’. Open WebUI 디테일, Dify·LibreChat·AnythingLLM 비교, RAG로 우리 회사 문서 학습, MCP로 ERP·메일 연결. 본격 사용자 대상.”

Q

발표 요청: “3편 끝나니 ‘우리 회사 시작 셋’ 한 줄?” → 보통 ‘Qwen 7B + Ollama + Open WebUI’. → ‘좋습니다. 정답.’

NOTE

★ 강사 핵심 배경지식 — 3편 끝 메시지 톤: ‘오늘 결정한 셋으로 1주일 안 시작 가능’ 안심. 청중에게 ‘즉시 행동’ 동기 부여.

NOTE

강사 배경지식 — 11편 강좌 위치: 3편 ‘기술 스택 결정’. 4편부터는 ‘구체 도구 사용’. 4편 챗봇·RAG, 5편 에이전트 기초, 6편 하네스, 7편 사내 에이전트 배포, 8편 자체 에이전트, 9편 보안, 10편 백업·DR, 11편 관리자. ‘결정 → 구체’ 흐름.

NOTE

강사 배경지식 — 4편 청중 다음 행동: 3편이 ‘기술 결정’이었다면 4편은 ‘사용자가 만나는 화면’. ‘우리 사장님이 사내 챗봇 사용하는 모습’ 4편이 그림. 청중 동기 ‘즉시 사용 가능 도구’.

TIP

강사 함정 — ‘완벽 결정 압박’ X: ‘오늘 60% 결정으로 시작 → 운영 보완’ 마무리.

TIP

강사 진행 팁 — 5분 시간 배분: 0~1분 ‘7장 마스터’. 1~2분 ‘추천 시작 셋’. 2~3분 다음 주 액션. 3~4분 4편 예고. 4~5분 청중 발표.

BRIDGE

“3편 끝. 4편 ‘챗봇·RAG’에서 사내 직원이 매일 쓰는 UI 만들어요. 청중 여러분 고생하셨습니다.”

THANKS

3편 끝 — 4편에서

‘챗봇·RAG 플랫폼’으로 이어집니다

SAY

“3편 마지막 슬라이드입니다. 1·2·3강 180분 고생하셨습니다.”

SAY

“오늘 손에 남은 것 — 1순위 모델 결정서 + 한국어 모델 결정서 + 추론 스택 1페이지. 이 3장이 사장님께 보고 하는 ‘기술 결정 마스터’.”

SAY

“다음 단계 — 4편 ‘챗봇·RAG 플랫폼’. 모델 + 추론은 ‘엔진’입니다. 4편은 ‘사용자가 만나는 화면 + 우리 회사 문서 학습’. 그 다음 5편부터 ‘에이전트’ 시작 — 챗봇이 ‘답하기’에서 ‘일하기’로 진화.”

SAY

“오늘 강의 후기 + 질문은 visionc.co.kr 또는 사내 챔피언과 공유 부탁드립니다. 다음 시간에 만나요.”

NOTE

★ 강사 핵심 배경지식 — 마무리 톤: 청중 피로 인지 + 칭찬 + 다음 동기. ‘오늘 결정 → 다음 주 시작’ 핵심 메시지.

TIP

강사 진행 팁 — 2분 안에 따뜻한 작별. 청중과 눈맞춤.

BRIDGE

“감사합니다.”